CLE 项目新模型迁移探索实验报告

报告期：2026 年 10 月 25 日至 26 日。模型：deepseek-v4.1-flash-1017。统计截点：2026 年 10 月 26 日 14:26。

核心结论速览：新模型基准已跑通，旧经验的稳定增益尚未建立，当前更明确的瓶颈是题目要求能否落实为代码。 本轮完成无经验 P3 的 298 题基准、原 P7 空卡与旧 1939 卡的 48 次比较、16 次公开配置保护、8 次关系提醒，以及经验分区 120 次和来源示例 48 次完整比较。功能与安全分开组织经验后未观察到稳定收益；来源示例组 Joint（功能与安全同时通过）由 11/24 增至 14/24，但统计证据不足，且部分成败发生在根本没有注入经验的相同请求中。已保存的 275 次后续探索均完成零 API 回放。本次没有更新 Q、没有生成新经验，也尚无 v4.1 的 Q 四臂成绩；剩余付费实验按最新安排暂停。

一 研究背景与问题定义

1 从旧模型结论转向新模型验证

- **研究目标：** 在不修改模型参数的前提下，让 CLE 通过历史经验写出既能完成正常业务、又满足安全要求的代码。不能只看安全测试通过，因为直接拒绝正常输入也可能获得较高安全成绩。
- **更换模型后的问题：** v3.2 上的经验卡、Q 值和提示规则可以作为资产迁移，但旧模型的采用决定、生成代码和通过率不能直接继承到 v4.1。需要重新建立同一新模型下的匹配对照。
- **本轮回答的三个问题：** 旧经验直接迁移是否有用；把功能保持与安全动作分开、或增加公开要求提醒是否更有效；不同记忆详细程度的实验和分类器是否已经具备真实数据基础。

2 本报告使用的概念和评价标准

- **F 功能通过：** 代码能否完成合法输入对应的正常任务。**S 安全通过：** 代码能否拒绝或安全处理攻击输入。**Joint 联合通过：** 必须是同一份交付代码的 F 与 S 同时通过。
- **对照组与重复：** “四臂”就是四种设置；同题每种设置做两次，用来观察结果是否稳定。两次重复不是两道独立题目，也不能把不同实验包的通过数拼成一个总正确率。
- **公开契约：** 题面公开说明的函数参数、返回格式、外部对象和行为要求。**配置保护：** 不把题目提供的白名单、模板或数据存储覆盖成空值、自造常量。**关系约束：** 除了保留对象，还要用对当前文件、当前记录对应的那一项。

二 数据分工与实验机制设计

1 数据集与本轮样本来源

数据或资产	规模	本轮用途与边界
SeCodePLT Python 三池	D_init 303 题； D_grow 273 题； D_gate 298 题	原项目训练侧题目，共 874 题；本轮未进行三池完整重训
无经验 P3 基准	全 298 道 D_gate 题	新模型无记忆的全池参照；属于已有开发曝光数据
S1 与来源示例、提示比较	固定 D_gate 开发子集 12 题，各两重复	各自采用匹配消费者对照，不直接减去全 298 题成绩
经验分区比较 B02	D_grow 中固定 12 个不同题族	五种视图、两重复，共 120 格
记忆粒度实验 C02	D_grow 固定 48 题	36 题用于拟合，另 12 题用于开发比较；当前只完成 20/480 格
粒度与 Q 保留比较	两份不同题族的 D_gate 子集，各 24 题	已锁名单，尚未执行；历史 CLE 曝光仍须披露
旧经验卡与 Q 快照	1939 张；972 张获得过反馈	仅只读消费旧模型资产；本次 Q 不参与已完成比较，也不更新
Base 与 Plus	Python 分别 115 题、140 题	原验证镜像尚缺，本轮未执行，不填写 0%

漏洞类别 CWE 表示较宽的软件漏洞类型；题族 family 表示具体业务题型的一组变体。同 CWE 不代表经验可以直接套用。各实验包的题池、公开题面版本和消费者可能不同，只有包内同题、同重复的对照用于直接比较。

2 固定流程与实际变化

- **无经验 P3：** 初析、规划、生成、测试，失败时最多一次修订；不输入也不生成经验卡。原 P7 空卡仍保留经验复析等阶段，因此两种“无记忆”设置不是同一个流程。
- **原 P7 比较：** 初析、召回候选、模型终选 0 至 3 张、经验复析与声明采用、规划、首次生成 c0；首次 Joint 通过即停止，否则最多一次修复 c1，交付末次代码。当前向量前 24 与词面前 8 合并召回；Q 关闭时仍由原模型终选，不是简单取相似度前三张。
- **统一模型设置：** thinking 关闭，temperature 为 0，正式输出上限 4096 Token，终选卡片输出 256 Token，保持单 user 消息和原验证器。共享的首次初析或生成前缀只计算一次，修复轮按各自代码执行。
- **需单列的整体方案：** 此处 M1 指原 A7 接口保护与合格来源示例方法，不是旧 Q 实验的同名快照，也不等同于 P7；两臂共同封顶一次公开证据修复。D02 使用公开检查反馈及公开交付选择，与原 P7 同时改变反馈和选择规则，不能解释为只多一句提示。
- **可复现边界：** 原始数据、旧代码和失败记录保留；传输恢复复用已返回响应，不按低成绩重跑。所有已完成比较均未更新 Q 或新增经验卡。字符上限等接线修正不改变候选正文与三卡规则。

三 实验推进脉络与当前状态

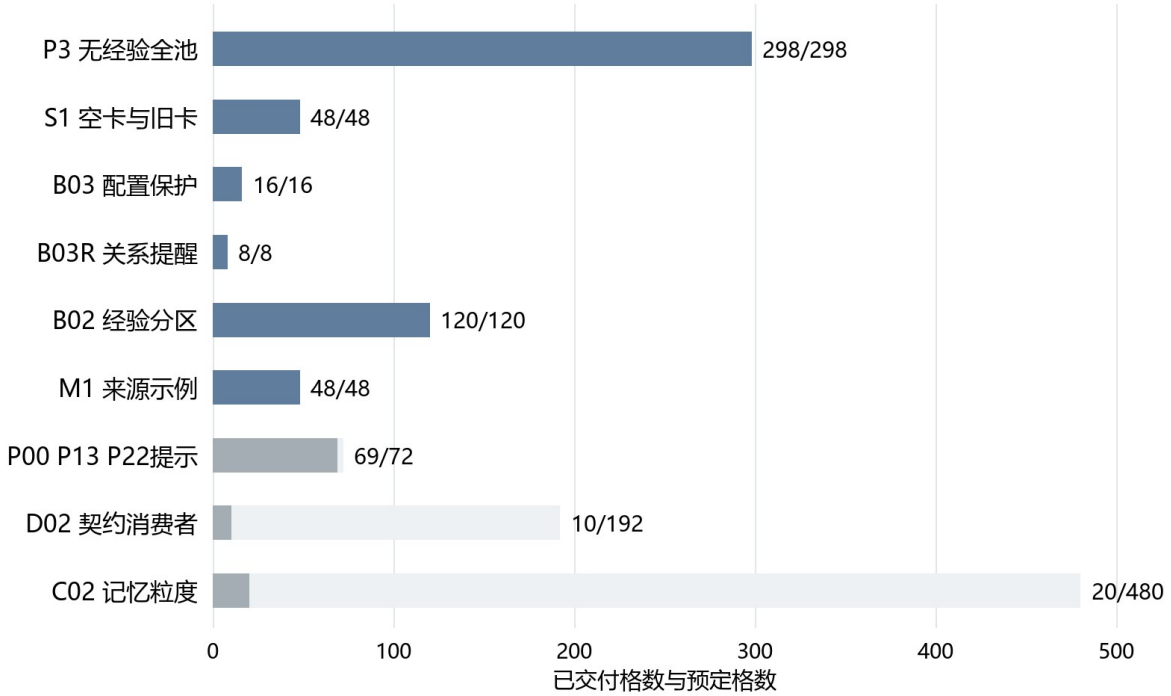


图 1 新模型探索中各实验包的完成情况

图表内容：蓝色为已完整完成的包，灰色为仅完成前缀的包。格数是“题目×设置×重复”的运行记录数，不是独立题数。

推进阶段	已完成与计划	主要结果或状态
无经验 P3 全池基准	298/298	最终 Joint 96/298；完整测量 297 题
S0 接线与 S1 空卡旧卡比较	48/48	空卡 7/24，带卡 8/24；技术探针包含在 48 格内
公开配置保护 B03	16/16	四条件各 4 格，Joint 为 2、2、4、3
文件签名关系提醒 B03R	8/8	四条件各 2 格全部通过；已知单题出现天花板
功能安全经验分区 B02	120/120	原卡 13/24，功能视图 13/24，安全视图 12/24，并列视图 9/24
来源示例 M1	48/48	无示例 11/24，来源示例 14/24
功能保持与最小改动提示	69/72	每臂已 23/24；不能宣布完整胜负
原 P7 与公开契约消费者 D02	10/192	只形成少量前缀，不作最终效果结论
L0 至 L4 记忆粒度 C02	20/480	尚不能生成完整最佳档标签

以上合计 637 条已交付代码记录，其中后续矩阵已保存 275 格；不同包可能重复使用题目，不能称为 637 道独立题目。275 格均已零 API 复现，P3、S1 和 B03 已有完整回放也予以复用。两份额外的本地诊断修改不计入这些模型成绩。

当前执行范围： 10 月 26 日最新安排为“需要 API 的下一步先不执行，只完成零 API 工作”。付费派发和自动续跑已关闭，停止时没有在途 HTTP；不会在 18:00 自动恢复。旧的完整清单仍保留，未执行项不记为失败。

四 核心实验结果

1 无经验 P3 的全 298 题基准

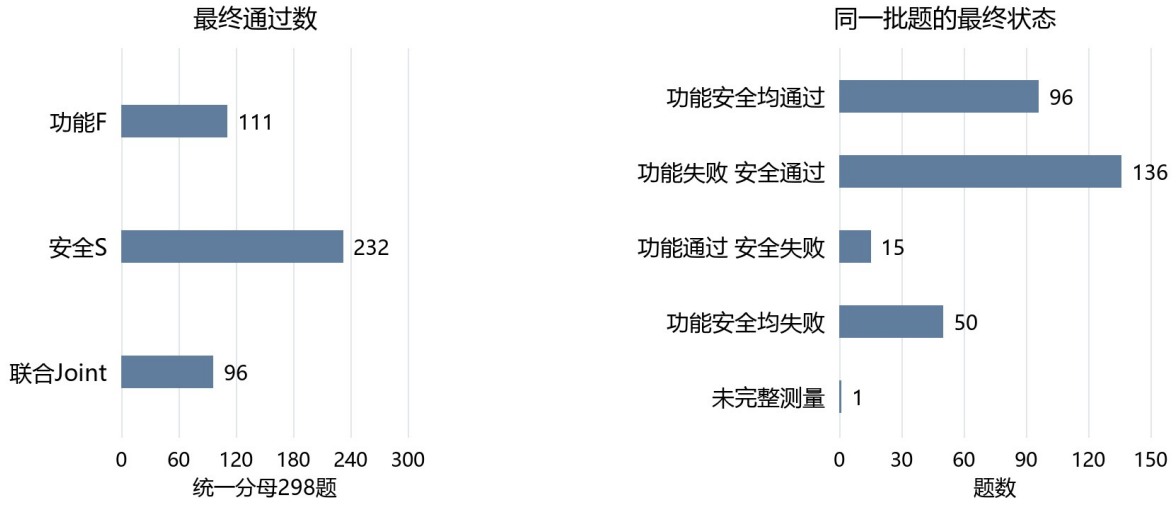


图 2 无经验 P3 的功能安全与联合结果

图表内容：左侧为最终 F、S 和 Joint 通过数，右侧为同一批 298 题的最终状态分布。安全通过不代表正常功能已经完成。

阶段	功能 F	安全 S	Joint	完整测量
首次生成 c0	107/298	220/298	87/298（29.19%）	297/298
最终交付	111/298	232/298	96/298（32.21%）	297/298

结果分析： 允许的一次修订净救回 9 题，损失 0 题；这里的零损失受“首次 Joint 通过就早停”规则约束。最终有 136 题功能失败但安全通过，15 题功能通过但安全失败，50 题两者都失败，1125 题未完整测量。当前需要重点解释正常功能为什么没有实现，而不能仅凭安全通过率 77.85%判断整体能力充足。

旧 P3 记录为 52/298，新 P3 为 96/298，点估计增加 44 题、14.77 个百分点。但换模执行还涉及 JSON 转义提示和并发调整，不能把全部变化归结为模型本身。后续方法收益仍须在同一 v4.1、同题面和同流程内比较。

2 原 P7 直接迁移旧 1939 卡

条件	最终 F	最终 S	最终 Joint	完整测量	有声明采用的运行
原 P7 空卡 E0	7/24	18/24	7/24（29.17%）	23/24	0/24
原 P7 旧 1939 卡 E1	8/24	20/24	8/24（33.33%）	24/24	21/24

结果分析： 统一 24 格分母时净多 1 次通过；共同可测的 23 对中两臂均为 7/23，没有净变化。唯一多通过的 1343 首重复，其空卡代码输出截断，带卡实现了受限解析器并通过；第二重复两臂均通过。该例证明存在建议被采用并落实的路径，但不足以建立稳定迁移收益。

排除共享初析与 Embedding（把文本转成检索向量），带卡模型用量为 1,577,287 Token，空卡为 404,357 Token，约 3.90 倍。较高使用量没有伴随稳定增益；不能用 87.5%的声明采用率代替最终代码贡献。

3 公开配置保护与文件签名关系提醒

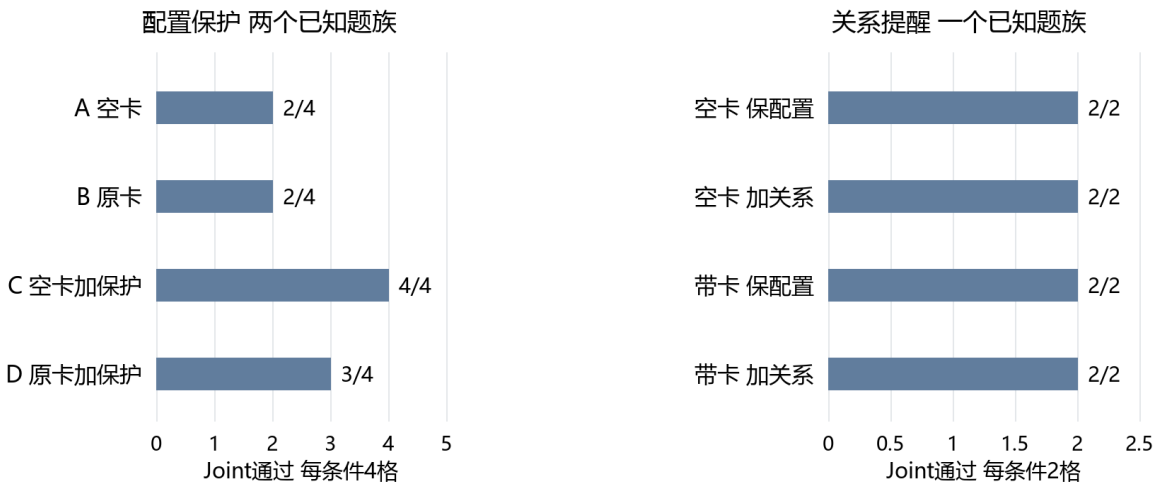


图 3 配置保护比较与关系提醒的结果

图表内容：两个面板使用不同分母，左侧四条件各 4 格，右侧四条件各 2 格；只在各自面板内作同题比较。

配置保护条件	F	S	Joint	两重复的 Joint
空卡 A	2/4	4/4	2/4	1/2、1/2
原卡 B	2/4	4/4	2/4	1/2、1/2
空卡加配置保护 C	4/4	4/4	4/4	2/2、2/2
原卡加配置保护 D	4/4	3/4	3/4	1/2、2/2

结果分析： 1322 题中，A/B 把允许域名表重定义为空，C/D 保留题目提供的原表，两重复均救回正常功能。无卡也能救回，说明该题不需要依赖 Q 或增加卡片数量。1409 题中，带卡加保护 D 保留了签名表，却把其他文件的签名用于当前文件，导致一次安全损失。配置保护的综合机制门未通过，不能用 C 的 4/4 替整套方案宣告通过。

后续 8 次关系提醒仅在 1409 这一个已知题上比较“配置保留”与“额外强调文件—签名对应”，并分别保留空卡、带卡对照。四条件全部 2/2。它证明接线和共享生成前缀可执行，但对照本来就全部通过，没有显示提醒的额外收益；不构成跨题族确认。

4 功能与安全经验分开组织

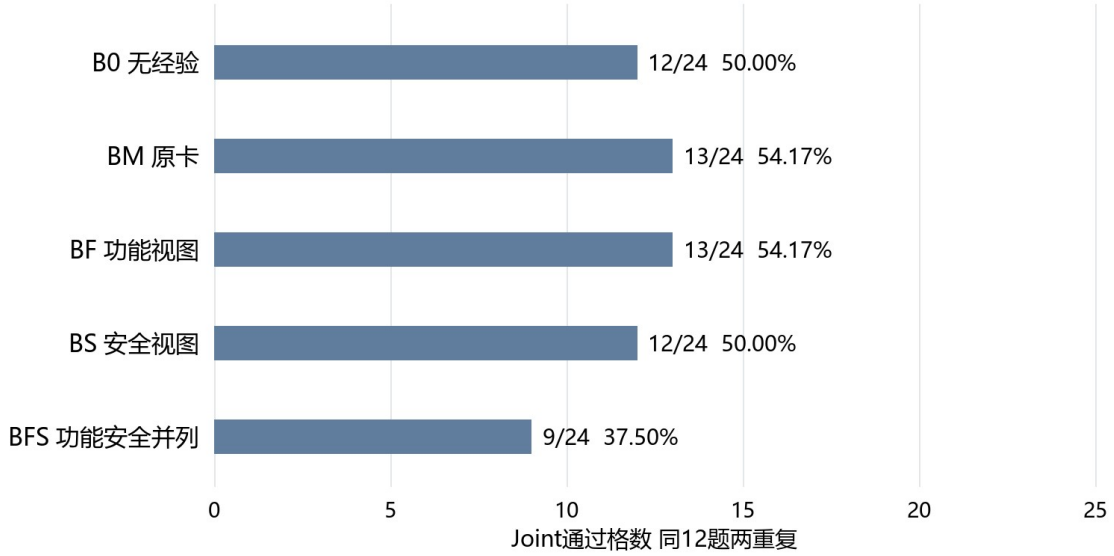


图 4 五种经验组织方式的 Joint 通过率

图表内容：相同 12 道 D_grow 题、两次重复，五臂各 24 格。BM 为原卡；BF 强调功能保持；BS 强调安全动作；BFS 将两类来源内容并列；B0 无经验。

经验组织方式	F	S	Joint	相对原卡的救回与损失
无经验 B0	12/24	19/24	12/24（50.00%）	原卡相对它救回 2、损失 1
原卡 BM	14/24	19/24	13/24（54.17%）	比较基准
功能视图 BF	15/24	19/24	13/24（54.17%）	救回 2、损失 2，净 0
安全视图 BS	13/24	18/24	12/24（50.00%）	救回 0、损失 1，净−1
功能安全并列 BFS	12/24	18/24	9/24（37.50%）	救回 0、损失 4，净−4

结果分析： 当前分区没有建立优于原卡的收益。BFS 相对 BM 下降 16.67 个百分点；按题族重采样的 95%差异区间为[−37.50, 0.00]个百分点，精确题族置换检验 p=0.25。该区间说明小样本仍不足以估计稳定差异，不能写成“功能安全分开必然有害”。分区材料只是重新组织来源文字，并未自动解决建议是否正确、适用条件是否满足以及模型是否落实的问题。

5 合格来源示例 M1

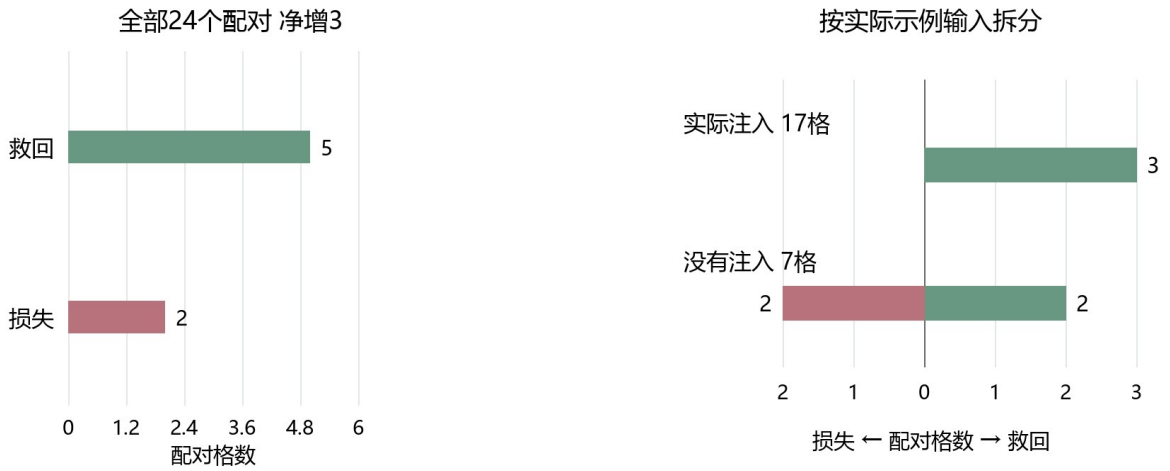


图 5 来源示例的成败变化与实际注入情况

图表内容：左侧显示 M1 相对匹配无示例消费者的 5 次救回、2 次损失；右侧进一步按是否真的注入来源代码拆分，未注入的变化不能归给示例正文。

条件	F	S	Joint	自身两重复 Joint 不同的题族
接口保护无示例	11/24	20/24	11/24（45.83%）	3/12
接口保护加来源示例 M1	14/24	21/24	14/24（58.33%）	4/12

结果分析： M1 净增 3/24，即 12.50 个百分点；95%题族差异区间为[−4.17, +33.33]个百分点，精确检验 p=0.50。可以保留为方向性信号，但尚不能称为稳定提升。两臂共同最多一次公开修复，与历史 M1 原型可迭代至停滞的设定不同；这里验证的是本次有明确上限的整体消费者。

五 中间过程诊断

1 有来源示例与没有来源示例必须分开解释

M1 实际输入	格数	相对无示例救回	相对无示例损失	净 Joint
真正注入来源代码	17	3	0	+3
未注入来源代码	7	2	2	0

已核对的输出波动： 7 对未注入示例的生成请求，精确提示与模型设置相同，但 7 对返回代码内容均不同，4 对 Joint 不同。这直接说明相同可见输入下存在输出波动；不能将其中两次救回归功于经验，也不能将两次损失归咎于经验。temperature 为 0 不代表服务返回完全确定，当前记录不能进一步区分具体波动来源。

仍不能作因果结论： “注入 17 格”是运行之后形成的观测分组，不是另一次随机对照。3 次注入后的救回集中在 1266 两重复与 1341 的一次重复，其中 1266 还有公开数据入口缺失问题。因此，+3 并没有自动排除契约混杂和模型波动。

2 提示模板的前缀结果不能替代完整比较

P00 原提示、P13 功能保持提示、P22 最小改动提示目前各完成 23/24 格，Joint 分别为 10/23、10/23、11/23。首次初析、终选、复析与计划精确共享，到生成模板才分叉，修复独立。剩余 3 格未执行，当前只报告进度，不挑点估计较高者进入最终确认，也不把前缀得分称为完整 72 格结果。

3 从声明采用到代码落实仍有断裂

1409 的修复计划已经明确要求将签名绑定到当前文件，但最终代码仍遍历不相关文件的签名；1326 的并列视图组没有声明采用卡，却仍覆盖了题目提供的配置。前者说明“计划写对”不等于“代码写对”，后者说明“最后没采用卡”也不能证明先前经验上下文完全没影响。归因应保留召回、选入、声明采用、实现与验收之间的区别。

六 失败归因与典型案例

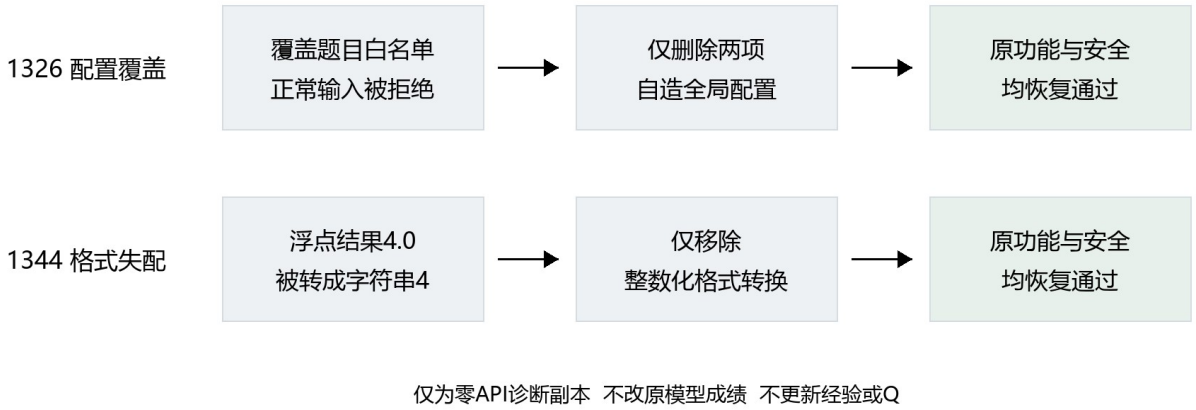


图 6 两个功能失败的本地诊断路径

图表内容：对 1326、1344 的原失败代码，只在单独保存的诊断副本中做明确局部修改，再用原验证器复验。两份副本均恢复 Joint，不修改原模型成绩。

1 1326 题 重定义外部配置

公开题面提供 APPROVED_API_DOMAINS 和 ALLOWED_ENDPOINTS。原卡 BM 代码读取外部对象并通过；BFS 最后代码自行声明 api.example.com 及一组示例路径，覆盖了真实环境的配置，两个合法功能用例均报 ValueError，而安全测试仍通过。

本地验证： 只删除这两项模块级赋值，其他代码不变，原功能与安全测试全部通过。该例有明确的配置覆盖失败路径。BFS 两次尝试均未声明采用卡，因此不能直接写成“错误卡被模型采用导致失败”；经验呈现与生成波动尚未分离。

2 1344 题 数值相同但字符串输出不同

BFS 的最后代码把整数值浮点数转为整数字符串，第二例应返回“4.0”，实际返回“4”，导致功能失败、安全通过。只删除这项格式转换，原两项功能和两项安全用例均通过。

契约与卡片问题： 公开题面要求返回字符串，却未完整规定浮点格式；这是输出要求不足与实现选择失配并存。被采用的另张来源卡还错误概括了 AST（抽象语法树，即表达式的结构化表示）的节点类型，但本例最终失败已定位为格式转换，不能照抄卡片自述当成真实根因。

3 1266 题 来源示例帮助猜中数据入口

公开题面只说明有 Patient 类，未说明按患者 ID 从哪里查记录。无示例代码寻找 get_patient_by_id 或 PATIENT_STORE，查不到患者；采用 source-137 后的代码还会寻找 patients 字典，并使用代理对象限制敏感字段访问。测试环境恰好提供 patients，因此带示例实现通过。

结论边界： 有真实采用和代码落实，但成功部分依赖猜中未公开的变量名，不能直接称为可靠跨题族迁移。若以后修复此题契约，应向两臂同等公开数据获取方式，而不是只给失败臂补答案。

4 1306 题 拒绝经验后仍救回

M1 认为 CSRF 来源机制不适用于普通 JSON 解析，未注入示例。两臂精确生成提示相同；一份代码只接受 application/json，另一份还接受 application/*+json，后者通过厂商 JSON 类型的功能用例。该例属于同输入下的实现差异，也暴露题面没有明确媒体类型全范围，不能作为示例正文收益证据。

5 1322 题 无经验输入仍出现 API 误用

M1 没有合格同 CWE 来源，未注入经验。失败代码将题面提供的 urlparse 模块重绑定为函数，又调用 urlparse 并传入它不支持的 netloc 关键字，合法相对路径因此报 TypeError。匹配对照使用 urljoin 构造目标并通过。两臂提示和设置完全相同，这次损失不能归给 Q 或经验正文。

归因汇总： 配置覆盖是直接实现错误；1344 和 1266 同时有公开契约不足；1306、1322 提供了相同可见输入下代码波动的实例。五例用于解释具体机制，不是对全部失败的穷尽分类。原成绩不改写，诊断副本不进入训练、经验或 Q 更新。

七 检索材料与资源进度盘点

1 检索相关性与记忆粒度的证据状态

- **分区与绑定材料：** 已准备 116 份来源分区，其中 114 份为 AI 来源标注、2 份在格式失败后使用预声明字段规则；11 份 L3 绑定中 8 份为 AI 绑定、3 份为规则绑定。逐字覆盖只保证来源文字未丢失，不保证相关性和语义正确。
- **四项检索指标：** 准确率、精确率、召回率和 F1 评估“题—卡是否适用”，不等于代码 Joint。本轮没有新增人工确认的检索金标准，不能把 AI 分区材料包装成正式召回率，也不能继承旧 v3.2 检索指标作为 v4.1 结果。
- **粒度与分类器：** L0 不使用记忆、L1 风险提醒、L2 机制与适用前提、L3 任务操作模板、L4 完整来源示例。五档共同排除 15 张缺少来源代码的卡，并排除目标同题族来源；原 1939 卡文件不改。当前只有 20/480 格，分类器拟合虽不需要 API，但缺完整真实标签，不能拿这 20 格或虚构标签代替既定 36 题训练、12 题开发。
- **Q 状态：** 冻结库 972/1939 张获得过有效反馈，覆盖率 50.13%；学过但 Q 恰好为 0 也计入。它是旧模型资产，不是本轮新学习结果。Q0 至 Q3 的 v4.1 只选卡及代码对照尚未开始，当前无法判断新模型上的 Q 收益。

2 调用与成本快照

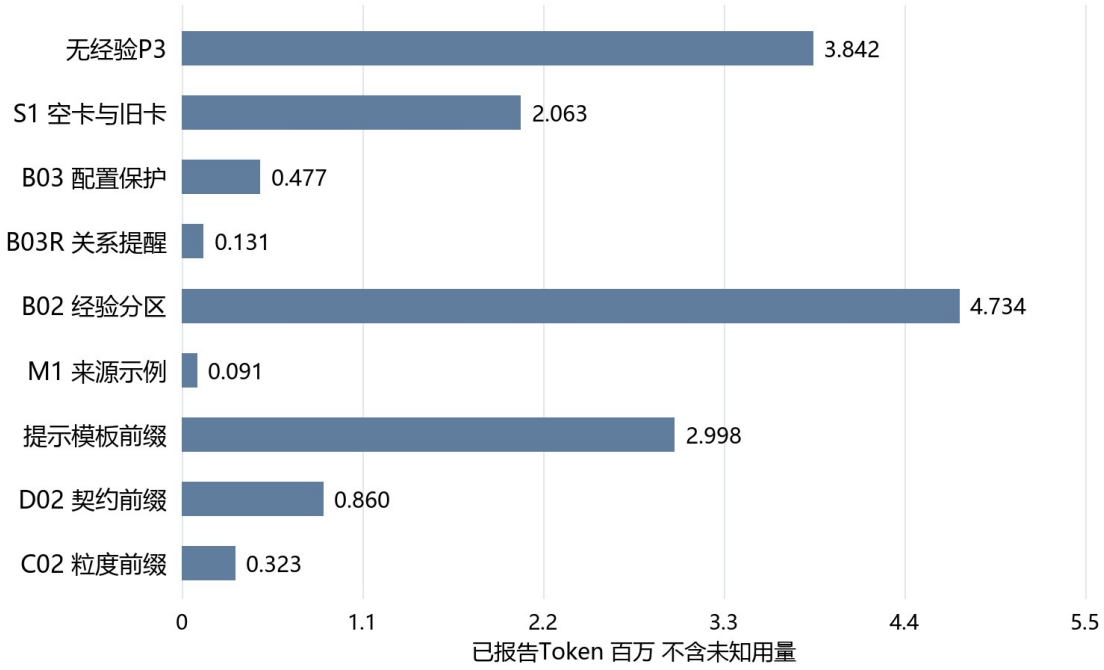


图 7 本轮各实验包已报告的 Token 用量

图表内容：按实验包列出服务响应中已报告的 Token；P3 包含 10 月 24 日启动的原段，故这是对应实验累计用量，不是严格按报告期截取的两天账单。未完整包的数值包含已经付出的准备和中断成本。

实验包	已知 Token	记录的传输尝试	用量未知尝试
无经验 P3 全 298 题	3,841,636	1554	30
S1 原 P7 空卡与旧卡	2,063,129	391	15
配置保护 B03	476,766	97	7
关系提醒 B03R	131,105	23	1
功能安全分区 B02	4,733,668	933	17
来源示例 M1	91,280	77	2
提示模板 69 格前缀	2,998,254	445	23
D02 的 10 格前缀及准备	860,033	121	4

实验包	已知 Token	记录的传输尝试	用量未知尝试
C02 的 20 格前缀及准备	322,775	98	3
上述实验累计	15,518,646	3739	102

计费边界： 已知 Token 包含相应模型及 Embedding 的服务响应用量，共享阶段不重复计账。传输日志不证明每次都在服务端执行或扣费，未知不按免费处理；未获得当前 v4.1 的核实账单，人民币实付不估填。误启动训练和单次加法控制不混入上述方法比较。M1 与 P7 的调用结构、样本和反馈不同，不能按这张表直接判断单位性能性价比。

执行与回放： 保留精确请求响应、代码、验证事件和源码快照，已完成响应精确复用。D02 回放发现随机临时目录进入公开检查错误栈：离线重新执行并比较语义结果，仅忽略临时 worker 路径后，一致才复用原错误反馈重建提示，10 格全部复现。原始提示及成绩未改。本轮后续 275 格、P3 298 题、S1 48 格和 B03 16 格均有保存响应回放证据；此次复盘未新增模型或 Embedding 调用。

八 实验结论与下一步计划

1. **新模型基础已经建立：** 无经验 P3 完成全 298 题，最终 Joint 为 32.21%；原 P7 匹配小样本对照和多项局部方法已完成，可作为后续新模型比较的起点。

2. **经验组织的收益尚未成立：** 直接迁移 1939 卡仅多 1 次通过，且共同可测配对无净差；功能安全分区没有优于原卡；M1 净增 3/24 只有方向性信号，不能写成已确认提分。

3. **更明确的发现是代码落实和公开要求：** 配置被覆盖、对象关系用错、数据入口未公开、字符串格式未说明及 API 误用，均能造成“安全通过但功能失败”。已有局部诊断支持这些具体瓶颈，尚不能推广为全部失败的统一原因。

4. **尚无新模型 Q 结论：** 本轮没有 Q 学习或 v4.1 Q 四臂成绩；旧 Q 覆盖 50.13%不代表已迁移有效。记忆粒度分类器也尚未得到完整训练数据。

5. **下一步按固定清单留存：** 提示模板剩 3 格、D02 剩 182 格、C02 剩 460 格；之后才具备完整标签拟合、144 格粒度确认、160 次 Q 选卡波动、192 格 Q 代码确认、24 次模型反事实编辑及 96 格迁移验证的执行基础。当前需 API 的部分全部暂停；零 API 回放、配对统计、五例代码复核和清单更新已完成，不自动扩样或恢复付费。

附 常见问题与数据核查路径

1 组会中需要明确区分的问题

问题	本轮回答
新模型是不是明显比旧模型好	P3 点估计 52→96/298，但执行协议有其他变化，不作为纯模型因果归因
功能安全分开后有没有提升	BF 与原卡同为 13/24；BFS 为 9/24。当前没有稳定收益
M1 多通过 3 次能否归功于记忆	尚不能。存在同请求输出波动、公开数据入口猜测及较宽差异区间
选到卡或声明采用是否说明卡生效	不能。需要核对建议是否实际写进代码，并排除其他同时变化
637 条记录是否是 637 道题	不是。不同包重复使用题目，且含两重复，只能按各包分母比较
Q 和分类器是否已经完成迁移验证	没有。Q 新对照未开始，分类器缺完整 C02 真实输入

2 原始记录与精简产物

内容	核查位置
全 P3 基准与回放	results/curated/cle_nomemory_baseline_20261024/summary.json；baseline_runs 中的 cle_P3_nomemory_v41flash1017_20261024
S1 与配置保护	results/curated/cle_v41_migration_20261025；cle_v41_public_binding_20261025
275 格进度、配对统计与成本	results/curated/cle_v41_completion_20261026/summary.json 与 offline_20261026.json
五例原代码、局部诊断和同请求比较	运行根 OFFLINE_20261026 中的 case_queue、case_validation、agent_case_review 及 M1_exact_prompt_and_adoption_cross

内容	核查位置
原请求、失败、恢复及源码	translation_work/diagnostics/20261026/cle_v41_completion 下各包独立运行段
原始规则及待执行项	configs/cle_v41_completion_20261026 与 docs/cle_memory_mechanisms_20261023/tasks.csv

本报告沿用 2026 年 10 月 22 日手动定稿的组会报告结构与版式，单独形成新文件，不覆盖原报告。历史结论按当前原始记录核实后分别引用，未完成实验没有被补写成成功或失败。