# CLE 项目全景手册

从研究问题、代码流程到当前实验与下一步安排

本手册面向第一次接触项目的读者，也用于 10 月 28 日晚组会。当前运行数字取自 2026 年 10 月 28 日 19:40 保存的记录；10 月 16 日原手册完整保留。当前实验模型为 deepseek-v4.1-flash-1017，旧版 CLE 仍是方法主线。

## 组会速读：现在已经知道什么，还在验证什么？

**课题主线是：经验怎样帮助模型写出功能正常且安全的代码，以及怎样减少经验带来的错误。** 经验卡是外部做题建议；Q 是根据历史反馈更新的卡片评分。项目不训练大模型权重，而是研究如何积累、组织、选择和使用经验。

已有实验确认 Q 会改变实际选卡编号，但没有建立稳定的正确率收益。换到 v4.1 后，旧 Q 四臂实验的 Joint 分别为 11/48、13/48、11/48 和 13/48；学习 Q 没有超过相似度排序和打乱 Q。功能安全拆分的小样本结果为原卡 13/24、拆分 9/24；分类器为 21/48，固定简短提醒为 22/48。它们回答了早期方案的实际表现，本轮继续验证重新学习 Q 和完整功能安全对照。查看 Q 证据与机制；查看后续任务。

本轮 Q 学习已完成 967/1122 次做题：D_init 的 303 题和 D_grow 前两轮各 273 题已完成，第三轮完成 118/273 题。已有 743/1939 张卡获得反馈，覆盖率 38.32%。功能安全五条件对照完成 2104/2980 次。工作台运行学习 1 个 worker 与评价 3 个 worker，总并发 4；这里的 worker 是同时推进任务的执行单元。查看运行情况。

当前决定是：**已启动的两项全量继续；其他思路先做探针并自动分析，遇到排队全量先跳过。** 探针确认流程和局部机制，完整对照检验总体收益。小样本结果不会自动触发全量开跑。v3.2 已停用，新的 v3.2 交叉臂不再执行；Base/Plus 等待原验证镜像。查看自动执行安排。

两项活动实验累计已报告 157,151,120 Token，物理 HTTP 请求 25,174 次，621 次用量未知或仍在途。未知用量保留，不计为零；未根据旧价格或假定缓存比例折算实付人民币。工作台调用 Codex 的用量与实验模型调用分开。

## 阅读地图：按问题找到对应章节

- 一、用一个普通编程任务解释整个课题
- 二、先分清六个最基本的对象
- 三、数据：题目、参考答案和测试各自有什么用
- 四、正确率如何定义：功能、安全、四种状态
- 五、从题目到代码：一次前向过程
- 六、经验表示：系统究竟“记住”了什么
- 七、完整 CLE 的四个阶段
- 八、把设计走一遍：SQL 查询教学案例

- 九、基础设施：代码和运行环境怎样合作
- 十、仓库和二十项代码职责地图
- 十一、工作台怎样监控和接续实验？
- 十二、项目实验体系：为什么需要不同的对照
- 十三、原手册收录的历史研究说明了什么？
- 十四、Q 究竟改变了什么，怎样判断它有没有用？
- 十五、科研基础：怎样自己判断一张实验表
- 十六、参与项目：一次实验从想法到归档
- 十七、九条思路分别怎样推进，现在先做什么？
- 十八、组会怎样用一分钟讲清项目？

# 一、用一个普通编程任务解释整个课题

## 1.1 我们到底要让模型做什么

假设题目要求：**根据用户提供的文件名，读取这个用户有权访问的文件；允许访问其授权目录下的合法子目录。**

如果模型写出的程序直接拼接路径，攻击者可能用特殊路径访问其他目录。这是安全漏洞（程序允许了本不应该发生的行为）。如果模型为了安全，把所有包含斜杠的文件名都拒绝，又会阻止合法子目录访问。这是功能退化（修复之后，原来应该支持的正常行为不能用了）。

项目要的是第三种结果：既保持合法访问，也挡住越权访问。

安全代码生成（根据公开需求自动写出兼顾功能和安全的程序）是本项目研究的任务。它不是简单判断一段代码有没有漏洞，也不是只把已有漏洞代码改好；当前主要流程包括根据题目从零生成，再在许可条件下进行一次修复。

## 1.2 为什么不是直接换更强的模型

更强模型可能改善结果，但那回答的是“模型能力变化有什么影响”。本课题希望研究：**在模型本身不变时，能否通过积累、筛选和使用外部经验，提高生成结果？**

模型权重（模型内部决定其行为的大量数值参数）在当前 CLE 主方法使用过程中固定。系统改变的是模型看到的经验、工作流程和反馈，而不是重新训练一个大模型。

成本也是动机：同一模型多调用几次、增加经验和审查，也会花钱。因此复杂流程不能只看“做了更多工作”，还要看是否获得足够收益。

## 1.3 一句话理解 CLE

CLE（Contrastive Lifecycle Evolution，对比式生命周期演进：比较修改前后的代码经历，提炼经验，再管理经验的使用与退出）尝试建立一个会积累“哪些修法有效、哪些修法会误伤正常功能”的系统。

这里三个词分别表示：

| 名称 | 通俗含义 | 在本项目中的动作 |
| --- | --- | --- |
| Contrastive，对比式 | 不只看最后答案，也比较前后发生了什么 | 比较初次代码、修复代码和两次测试结果 |
| Lifecycle，生命周期 | 笔记不是写进去就永远正确 | 候选、验证、修订、活跃、退役等状态管理 |
| Evolution，演进 | 后续任务可以受之前经验影响 | 新经验进入候选池，经审查后影响之后的检索与生成 |

这些是方法设计，不等于已经证明不断演进一定越做越好。

返回目录

## 二、先分清六个最基本的对象

| 对象 | 专业名称与简单概念 | 项目中的具体例子 |
| --- | --- | --- |
| 写分析和代码的模型 | LLM，大语言模型，根据文字输入生成文字或代码 | 当前实验使用 deepseek-v4.1-flash-1017；历史实验使用 v3.2 |
| 安排工作步骤的程序 | Agent，按流程调用模型、检索和工具的系统 | CLE 的分析、检索、规划、生成链 |
| 发给模型的要求 | Prompt，提示词，告诉模型任务、约束和输出格式的文字 | “保留接口，说明适用经验，输出完整函数” |
| 放在外部的经验 | Memory，记忆，独立于模型权重保存的资料 | 经验卡正文、状态和后来增加的 Q |
| 判断生成代码的程序 | Validator，验证器，实际编译或执行代码并检查结果 | Python 测试执行器、多语言容器验证器 |
| 展示运行情况的网页 | Dashboard，工作台，把已经保存的数据整理成图表 | 旧 CLE 本地看板 |

API（程序调用外部服务的接口）连接本地程序和模型服务。ChatAnywhere 是当前 Q 实验的服务中转渠道，不是生成模型本身。

Embedding（文字向量，把一段文字编码成一串用于比较的数字）用于查找意思相近的经验。Embedding 模型与生成代码的 LLM 是两个角色，也有分别计量的费用。

### 四个 Agent 是否意味着四个模型

不意味着。四类职责可以由同一个模型在不同请求中完成。加入经验复析（拿到候选经验后，再判断它能否用于当前题）以后，实际调用次数也不等于四次。

### “训练”是否都在训练模型

不是。参数微调（改变模型内部权重）、经验学习（改变外部卡片内容和状态）、Q 学习（只更新卡片历史成绩数值）是不同操作。当前 Q 实验做的是第三种；完整 CLE 主要研究第二种。

返回目录

# 三、数据：题目、参考答案和测试各自有什么用

## 3.1 一道任务不是只有一句题目

公开契约（题目明示的接口和行为要求）通常包含函数名、参数、返回形式、已有变量、合法输入和安全要求。模型只能按允许的信息解题。

参考实现（数据集提供的正确解法示例）用来检查测试能否正确接受预期程序，或在允许的训练侧提取经验。隐藏测试（不提供给生成模型的具体测试输入和预期结果）用于评价，不是可以给模型抄的解题材料。

测试夹具（harness，负责准备变量、调用待测函数并检查结果的外围程序）决定代码在什么环境下执行。函数写对了安全思路，却写错参数名、返回类型或已有变量的使用方式，也会失败。

教学例子：题目已经提供 ALLOWED_COMMANDS（允许命令列表），模型应该使用它；自己编一个新的列表并不等价。历史 Q 实验和本轮代码复盘都出现过这个问题。

## 3.2 两类数据承担不同角色

| 数据 | 含义 | 作用 | 不能混淆的地方 |
| --- | --- | --- | --- |
| SeCodePLT，简称 PLT | 外部安全编程训练材料，含漏洞代码和修复对 | 来源经验、学习、开发诊断 | 当前 CLE 主线使用 Python 子集，不是整个多语言最终评测集 |
| CodeSecEval 派生的 SecEvoBasePlus | 项目保存的 Base/Plus 多语言配对数据 | 比较生成方法的功能与安全表现 | 仓库有文件不等于每种语言都已完成同协议验证 |

仓库 PLT 原始 Python 对文件有 1411 组；当前常用可用任务划分合计 874 题。原始记录数、进入某次实验的任务数和最终完成测量的题数是三个不同数字。

按当前数据卡，Base/Plus 的记录数为：

| 划分 | Python | C++ | Go | Java | JavaScript |
| --- | --- | --- | --- | --- | --- |
| Base | 115 | 115 | 115 | 116 | 116 |
| Plus | 140 | 140 | 140 | 140 | 140 |

Python（一种编程语言）是本版 CLE 具体生成模板和主要研究证据所覆盖的语言。C++、Go 的数据来自项目内翻译并检查；Java、JavaScript 有归档材料，但仓库限制文档仍指出其完整冻结验证记录不足。不同语言任务数量也不完全相同。

Secure/Insecure 配对（同一任务的安全与不安全实现材料）用于不同目的。正式公开评测主要使用 Secure 轨（要求模型生成安全实现的任务路线）；Insecure 字段用于来源追溯和训练侧差异分析，不能直接把不安全参考版本的成绩当方法效果。

### 3.3 多语言翻译为什么影响科研结论

跨语言翻译（把题目、代码和测试转换到另一编程语言）不是只翻译自然语言。整数行为、字符串编码、异常类型、标准库、输入输出和执行环境都可能改变。

因此，要区分三种失败：模型写错了；翻译后的任务语义变了；测试环境没有正确运行。只看“通过/不通过”无法区分。

数据集固定后，仍需要确认公开契约与测试一致。必要修正应该标记版本并统一重评；不能只替某个方法修题，也不能把看过最终测试后调整经验的分数称为独立测试成绩。当前研究没有证明旧 CLE 在所有五种语言上都具有同等增益。

### 3.4 三个训练开发池与最终评价

| 名称 | 概念解释 | 当前常用数量 | 允许承担的任务 |
| --- | --- | --- | --- |
| D_init，初始来源池 | 建立第一批经验的题 | 303 | 漏洞—补丁对分析、种子自验证 |
| D_grow，经验增长池 | 做题、修复和学习的题 | 273 | 提炼候选经验；本次学习固定卡 Q |
| D_gate，开发审查池 | 检查候选或比较开发方案的题 | 298 | 门控与开发对照，不冒充最终未知测试 |
| H_pass，通过历史 | 以前已经通过的训练任务及证据 | 随运行形成 | 检查新经验是否让旧能力退化 |
| Base/Plus，独立评价用途的数据 | 方法冻结后评价生成效果 | 按上表 | 不把隐藏反馈用于更新长期经验 |

题族（family，同源或高度相关任务的分组）应跨池隔离，避免改写题分别进入学习和评价。当前清单含推断的来源族，不等于全部原始生成关系已经核实。

数据泄漏（本该只用于评价的信息被拿来改方法）会让成绩看起来比实际泛化能力更好。泛化（在没有用于改进系统的新题上仍然有效）需要独立证据。历史 Base/Plus 已被多次查看；仅把文件夹叫“test”不能恢复从未见过的性质。

返回目录

## 四、正确率如何定义：功能、安全、四种状态

| 指标 | 专业含义与简单解释 |
| --- | --- |
| F，Function | 功能测试通过，正常行为满足题目要求 |
| S，Secure | 安全测试通过，挡住这套测试覆盖的非法行为 |
| Joint，联合通过 | 同一份代码同时通过 F 和 S，是本项目核心结果 |

Joint = F AND S。AND（逻辑“并且”）要求两个条件同时满足。不能拿第一份代码的 F 和第二份代码的 S 拼成成功。

| 状态 | F | S | 代表什么 | 文件读取教学例子 |
|---|---|---|---|---|
| A | 通过 | 通过 | 联合通过 | 合法访问成功，越权访问被阻止 |
| B | 通过 | 不通过 | 能做事，但存在被测试出的安全问题 | 正常文件能读，也能越权读取 |
| C | 不通过 | 通过 | 安全测试过了，但正常功能有问题 | 把所有路径都拒绝，或返回格式写错 |
| D | 不通过 | 不通过 | 两项均失败 | 路径逻辑和正常输出都不正确 |
| U，未测量 | 不确定 | 不确定 | 证据不足，不能硬塞进 A–D | 环境故障，代码未成功进入测试 |

过度防御（为了阻止攻击而拒绝本应允许的行为）只是 C 状态的一种原因。接口错误、异常处理错误或夹具缺陷也会产生 C。旧文档中把 C 直接等同于过度防御的简写不能沿用为结论。

动态测试（实际运行代码检查行为）与静态检查（不执行程序，检查语法或代码结构）也不同。代码能解析、能编译，不代表功能或安全通过。测试通过只覆盖现有测试，不是对全部可能输入的数学证明。

返回目录

# 五、从题目到代码：一次前向过程

前向过程（使用现有模型和经验完成一道题的过程）如下：

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

## 5.1 初析不是把题目缩写一下

初析（第一次分析题目）需要确认不可信输入、敏感操作、合法功能与接口。比如“用户可提供路径”是事实；“某库函数是否自动处理符号链接”可能只是模型假设。分析错了，后面的检索也可能找错方向。

检索查询（用来查找经验的输入文字）可以包含公开要求、弱点类型、语言、初析、当前代码和许可反馈。它不应包含隐藏测试答案。

## 5.2 召回与最终采用是不同环节

召回（从大库挑出一批值得检查的候选）先按 Embedding 相似度取前 24 条，再按词语重合补前 8 条，合并去重。余弦相似度（用向量方向接近程度衡量文字意思相近）不等于经验正确率。

原 semantic_llm（由模型从语义候选中进一步选卡）允许选 0–3 张。随后还要逐卡复析适用条件。程序采纳（按模型声明且经过合法性检查的卡 ID 决定实际传入哪些内容）让拒绝行为真正影响后续输入。

“在候选里”“被选为前三”“实际被采用”“在代码里正确落实”是四层证据。只证明第一层，不能声称经验帮助了代码。

### 5.3 为什么还要规划

规划（生成代码前明确实现步骤）应说明保留哪些正常行为、改动范围、禁止的捷径、安全动作和检查计划。它的价值假设是减少生成时的遗漏；额外调用也有成本，是否净有益必须实验检验。

代码生成输出完整实现。方法中的“局部修改”指约束不必要改动，不表示系统已经具备自动拼接任何语法树补丁的通用能力。

### 5.4 一次修复与长期学习不是同一件事

c0（初次生成代码）如果达到 A，本次 P7 训练开发流程早停（满足目标后停止继续生成）；否则最多生成一次 c1（根据自身代码与许可反馈修复后的版本）。最终统计实际交付版本，不偷偷挑测试最好的一版。

修复当前题叫任务内修复；从这个过程提炼卡片并影响未来题叫跨任务经验学习。修复代码是题目的解答代码，不是对 CLE 框架源码的修理。

不同评价入口允许的反馈不同。PLT 开发可以使用协议许可的测试状态修复；独立 Base/Plus 不能把隐藏测试状态喂回生成器。已有 P0–P7 冻结入口中，第二次生成只看自己的代码，不能与 PLT 的反馈修复成绩混作同一个指标。

返回目录

## 六、经验表示：系统究竟“记住”了什么

### 6.1 一张经验卡的内容

经验卡（把过去编程经历提炼成带适用边界的建议）应同时回答“为什么危险”“怎样改”“什么时候不能这样改”。下面是结构说明，不是实验结果：

| 字段或内容 | 简单概念 | 教学例子 |
| --- | --- | --- |
| high_level_invariant | 安全不变量，始终应保持的安全条件 | 最终访问位置必须在授权目录内 |
| positive_principle | 正向原则，建议怎么做 | 解析路径后检查授权边界 |
| negative_guardrail | 负向护栏，指出有害的修改捷径 | 允许子目录时，不要一律拒绝路径分隔符 |
| applicability | 适用条件 | 用户控制输入路径 |
| exclusion_conditions | 不宜照搬的条件 | 处理的不是本地文件路径 |

| 字段或内容 | 简单概念 | 教学例子 |
| --- | --- | --- |
| root_cause | 根因解释，为什么发生失败 | 输入影响了文件访问边界；须区分观察与模型猜测 |
| fix_directive | 具体修复方向 | 在访问前核对解析后的路径归属 |
| safe_apis、语言说明 | 实现提示 | 特定库函数的语义和使用条件 |
| 来源、状态、支持与回归记录 | 经验的来历及使用资格 | 哪类训练经历形成，是否已有验证 |
| q_value、q_visits | 后来接入的效用估计与更新次数 | 本次 Q 篇章详述 |

太抽象的“注意输入安全”难以执行；太具体的源题答案不一定能迁移。经验粒度（建议保留多少具体细节）需要在两者之间寻找合适范围。

## 6.2 HSK 树与统一池

HSK Tree（分层安全知识树，按类别组织经验）在当前方法说明中按 CWE（常见软件弱点分类）、安全不变量、正向原则/负向护栏组织。语言 API 提示属于卡片内容，不要求再展开成一个额外树层。

统一经验池（保存所有卡片及状态的集合）与树不是概念上完全相同的对象。池保存卡，树组织卡；检索器决定当前可读哪些卡。源码和旧看板仍有语言叶及历史层级表示，不能用旧图形外观反推当前方法已经完成跨语言机制验证。

## 6.3 状态有什么用

| 状态 | 简单解释 | 应怎样理解 |
| --- | --- | --- |
| provisional | 待验证候选 | 可以按当前配置试用，不等于已经有效 |
| active | 已获得当前门控支持的活跃卡 | 仅代表当前有限检查通过，不是普适真理 |
| revised | 需要或已经进入修订处理 | 查看具体原因和正文版本 |
| retired | 退役，不参与正常使用 | 保留历史证据，不等于物理删除 |
| consolidated | 被归并处理的旧节点 | 是否仍可召回要看具体实现 |
| unmeasured | 尚未获得足够有效性证据 | 该字段有历史复用，必须结合 reason 原因字段解释 |

源任务能用该卡通过，叫自验证（在产生经验的来源任务附近检查可用性）；另一道隔离任务获得收益，才提供迁移效果证据。1939 张 Phase 1 卡不等于 1939 条经独立证明的规则。

## 6.4 错题本不是另一套标准答案

Error Ledger（错题本，记录失败类别与停滞情况的旁路记忆）用于三个设计方向：影响任务调度、给分析提供常见陷阱提醒、为经验归并提供负向边界。

原方法说明指出，归并提示对错题本负证据的接入还不完整。因此可以说相关数据结构与接口存在，不能把“全部归并都被失败证据约束”写成已经完整兑现的能力。

返回目录

# 七、完整 CLE 的四个阶段

Phase（方法中的大阶段）与页面标签、单题步骤、实验臂编号不是同一套计数。

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

## 7.1 Phase 1：建立最初的经验

输入是训练侧漏洞—补丁对（有问题的代码与参考修复之间的对应材料）。模型分析差异，提取种子经验，再检查其能否用于来源题的生成或修复。

输出包含卡片、来源验证结果和失败记录。源题通过不自动晋升为独立有效经验；种子仍可标记待验证。当前接收并用于 Q 探索的是 1939 卡 M0（初始经验库）。

## 7.2 Phase 2：选择任务、做题、提炼

主动回放（根据薄弱类别和过去失败选择训练任务再次处理）不是每轮机械重跑全部题。规则先关注覆盖不足与失败密集的类别，再由有界模型选择（限定候选与预算后让模型选任务）给出选择理由。

同一题产生 c0、测试、c1、测试和分析计划，这叫轨迹（一次任务执行过程的完整记录）。轨迹对比提炼（观察前后代码及成绩变化并总结经验）不应只看成功样本：

| 转移例子 | 教学含义 | 可形成的内容 |
| --- | --- | --- |
| B→A | 功能保住，同时修好安全 | 有条件的正向原则 |
| B→C | 堵住攻击，却破坏正常功能 | 负向护栏及适用边界 |
| C→A | 恢复功能且保持安全 | 避免过度限制或接口错误的经验 |
| D→D | 修改后仍双失败 | 停滞记录、待验证根因与盲区 |

根因解释来自模型时仍可能错误。观察到某项测试失败，是证据；“一定因为某个 API”是需要更多证据的解释，二者不要混成一句事实。

未选中的题仍留在 D_grow。外层三轮演进（重复经验增长和门控三次）不等于每题修复三次，也不是已经证明算法收敛。已通过任务通常不优先重放，但现有保底路径并不支持“所有已通过题永远不再出现”的绝对描述。

## 7.3 Phase 3：候选有用吗，会不会修坏旧题

候选门控（用一组检查决定经验是否值得晋升或保留）主要涉及：

1. 内容质量：字段、表达和来源是否足以使用。格式合格不等于事实正确。
2. 召回机会：正常检索能不能选到这张卡。选不到不等于卡的知识必然错误。

3. 增量效果：背景经验与背景加该卡相比，其他任务是否获得更多 Joint。

4. 历史回归：新卡是否使 H_pass 中原本通过的题退化。

增量（加一个因素后相对原来多出来的效果）概念上应只改变待测卡。原完整 CLE 门控实现存在分别重检索背景、候选可能已在背景中等情况，因此保存的差值并非严格隔离的单卡因果效应（只有这张卡造成的独立影响）。

常用审查配置每卡目标至少 3 题、上限 5 题；具体以该次参数为准。少量题正收益只是有限支持。历史回归常每题采样 3 次再按多数结果判定；“允许 1 个安全回归任务”与“3 次里允许失败 1 次”不是一个阈值。

实现还可能把剩余 D_grow 作为审查补充。只有实际审查题均来自隔离的 D_gate，才能声称该卡获得池级独立审查。独立性要检查实际记录，不能只看函数叫 audit。

### 7.4 Phase 4：冻结后评价

冻结（停止改变经验内容、选卡规则和关键参数）是为了看已经确定的方法对评价题表现怎样。冻结文件可能保存全池，包括退役和待验证卡；实际注入范围由状态资格决定。

冻结不仅是复制一个卡片文件，还需要保存模型、提示、检索模式、卡上限、反馈权限、生成预算和源码版本。否则同一个文件也可能运行成不同方法。

Base/Plus 的失败可以用于写分析，但不能再反馈改卡、调提示后仍称同一次独立最终评价。不同运行协议的首次结果、修复后结果要分列。

返回目录

## 八、把设计走一遍：SQL 查询教学案例

以下是说明方法的虚构案例，不是实验结果。

SQL（数据库查询语言）任务要求按姓名查询用户。合法姓名可能包含引号，程序需要保留这类正常输入。

5. 初次生成直接把姓名拼进查询语句，正常查询可用，但恶意输入改变了语句结构，得到 B。

6. 一次修复改为参数绑定（把输入作为独立数据参数交给数据库，而不是拼入查询结构），功能与安全均过，得到 A。

7. 提炼器记录“把不可信输入与查询结构分开”的原则，以及适用的数据库调用条件。

8. 另一条修复轨迹若直接拒绝所有含引号姓名，从 B 变成 C，则应记录“不要用任意字符禁令替代正确参数化”的护栏。

9. 两张卡进入待验证池。D_gate 检查它们是否帮助其他查询题；H_pass 检查是否损害过去正常输入。

10. 通过有限检查后，后续题可以检索并采用；不适用题应拒绝，不因为同属某一弱点类别就强行照搬。

整个项目想增加的不是“更多安全口号”，而是这种同时有机制、边界、功能保护和证据的经验。

返回目录

# 九、基础设施：代码和运行环境怎样合作

基础设施（让研究方法能真正运行、计量和复核的支撑系统）不直接等于论文创新，但缺失会使方法分数无法解释。

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

## 9.1 本地和远程各做什么

本地程序负责加载数据、形成提示、选择经验、发请求、运行测试和写记录。外部模型服务负责返回分析或代码。网络成功返回不代表代码正确；代码正确也不能抹掉工作流中的格式失败。

Python 虚拟环境（把某个项目的解释器和依赖隔离保存的目录）避免不同项目库版本互相干扰。当前 Q 运行使用的现有环境为 translation_work/temp/cle_memory_q_env/Scripts/python.exe，无需为阅读报告重新安装。

requirements.txt（依赖清单）当前列出模型客户端和数值计算依赖。但多语言编译器、Docker 镜像、数据和本地凭据不是单靠这一个文件就全部齐备。

凭据（允许程序访问付费服务的密钥）由已有本地加载器读取；无密钥配置（可以安全保存和协作的参数文件）放在 configs/。报告和 Git 仓库不保存密钥。Token（模型处理文字的计量单位）用量与账户货币账单不同。

## 9.2 为什么有本地 Python 和 Docker 两条验证路

PLT Python 默认在 python -I（减少环境继承影响的 Python 隔离运行模式）及临时子进程中执行。它提供轻量隔离，不等于完整容器安全边界。

Docker（把运行环境打包隔离的容器工具）用于对应正式或多语言验证路径。镜像（容器运行环境的固定模板）需要包含语言运行时、库和测试工具。镜像缺失会导致环境失败，不应被记成模型不会做题。

常驻容器池（预先保持一批容器供任务复用）用于避免每题创建容器造成资源膨胀。历史发生过容器磁盘增长和并行清理互删问题；所以正式 Docker 运行须沿现有执行层和资源监控入口，而不是临时另写一套启动逻辑。

当前外部评价队列仍标记等待原验证镜像；本次手册同步未进行机器全量镜像盘点。Base/Plus 不使用替代验证器。

## 9.3 并发、缓存、重试和断点为什么存在

| 机制 | 简单解释 | 对实验的影响 |
| --- | --- | --- |
| 并发 | 同时处理多个任务 | 减少等待，但可能触发服务限流或资源竞争 |
| 缓存 | 复用没有变化的已计算结果 | 节省向量请求；内容或模型变了不能混用旧值 |
| 重试 | 某次请求失败后再试 | 影响成本；不能只保留成功部分而抹掉失败用量 |

| 机制 | 简单解释 | 对实验的影响 |
| --- | --- | --- |
| 断点续跑 | 从已有记录继续完成未跑任务 | 必须确认输入和协议一致；重跑失败题是另一个决定 |
| 源码快照 | 保存实验发生时实际执行的代码 | 避免后来改代码导致无法解释旧结果 |
| 状态与心跳 | 进程写出的运行状态和近期活动标记 | 工作台据此提示运行、中断等，仍不是方法有效证据 |

温度（控制模型采样随机程度的参数）设为 0，也不能假设所有请求逐字可重复。并行顺序、服务实现和后续上下文都可能影响结果。

返回目录

## 十、仓库和二十项代码职责地图

仓库（由版本管理保存的项目文件集合）包含多代方法。不要因路径仍有 sct 就把所有实验混作一个方法。

| 目录 | 用途 | 当前定位 |
| --- | --- | --- |
| methods/sct_agent/ | 较早的 SCT 经验进化实现 | 历史方法与基础组件 |
| methods/sct_lifecycle_replay/ | 生命周期与主动回放的中间方案 | 历史研究分支 |
| methods/sct_trajectory/ | 四态轨迹对比、当前 CLE 主训练链 | 本手册主线 |
| methods/cle_ablation/ | 独立组件对照与当前 Q 实验 | 当前开发实验入口 |
| methods/workflow_baselines/ | 对照方法真实工作流 | 比较参照，不等于 CLE |
| methods/direction_screening/、methods/a7_exploration/ | 记忆和架构候选研究 | 旁路探索，不是 CLE 的 A7 主配置本身 |
| methods/sct_trajectory/dashboard/ | 旧只读工作台 | 保留 |
| methods/sct_trajectory/dashboard_v2/ | 新版站点 | 暂停推进 |
| src/translation_pipeline/ | 翻译、模型接口、验证执行等基础设施 | 多语言和测试支撑 |
| data/、configs/、tests/ | 数据、无密钥参数、代码测试 | 支撑复现 |
| results/curated/ | 小型精简结果 | 可读、可复核摘要 |
| translation_work/ | 原始运行区、缓存和临时产物 | 通常被 Git 忽略，不能假设克隆仓库就会有 |

下面按当前代码职责划分二十项，**是本手册的教学地图，不冒充此前模块方案的原编号**。除特别注明外，文件位于 methods/sct_trajectory/。

| 序号 | 职责 | 主要源码位置 | 改它通常影响什么 |
| --- | --- | --- | --- |

| 序号 | 职责 | 主要源码位置 | 改它通常影响什么 |
| --- | --- | --- | --- |
| 1 | 分池与题族边界 | split.py | 哪些任务用于学习、审查、评价 |
| 2 | 四态及状态转移 | four_state.py、schemas.py | 如何描述一次成败及修复变化 |
| 3 | 卡片字段、状态和树组织 | hsk_tree.py | 保存什么知识、谁有资格参与 |
| 4 | 初析和上下文生成链 | context_pipeline.py | 如何理解任务并传递约束 |
| 5 | 候选召回 | semantic_retrieval.py | 能找出哪些相关卡 |
| 6 | 检索方式与卡片转换 | retriever.py | 用何种选择规则把节点变成输入卡 |
| 7 | 适用性复析与程序采纳 | context_pipeline.py | 拒绝哪些卡，哪些真正进入下游 |
| 8 | 规划与代码生成 | context_pipeline.py、agent_pipeline.py | 建议能否转成符合要求的实现 |
| 9 | 轨迹和经验提炼 | distillation.py | 怎样从成功、退化和停滞形成候选 |
| 10 | 错题本 | error_ledger.py | 保存哪些失败信号并如何消费 |
| 11 | 主动回放任务选择 | active_replay.py | 有限预算用在哪些学习题上 |
| 12 | 候选增量和回归检查 | gates.py、closed_loop.py | 晋升、修订和退役的证据 |
| 13 | 吸收、合并与剪枝编排 | closed_loop.py、hsk_tree.py | 卡片内容、规模和状态怎样变化 |
| 14 | 完整生命周期主流程 | run_closed_loop.py、closed_loop.py | 各 Phase 与外层轮次如何衔接 |
| 15 | 冻结与消费 | frozen.py、run_plus_frozen_comparison.py | 测试期间固定哪些对象、如何使用 |
| 16 | 成本计量 | cost_tracker.py | 调用、输入输出用量及旧价格估算 |
| 17 | 产物与进度保存 | run_artifacts.py | 运行中保存什么，工作台如何读取 |
| 18 | 工作台读数 | dashboard/server.py、dashboard/static/ | 数据怎样聚合与显示，不负责产生成绩 |

| 序号 | 职责 | 主要源码位置 | 改它通常影响什么 |
| --- | --- | --- | --- |
| 19 | 独立实验编排 | ../cle_ablation/runner.py 等 | 固定任务和实验臂，调用原生成验证链 |
| 20 | Q 值算术与实验 | memory_q.py、../cle_ablation/run_memory_q.py 等 | 按采用结果学习效用、冻结后比较排序 |

这是职责划分，不表示每一项都是独立原创机制。一个文件可能承担多项职责，一个职责也可能跨文件实现。

MASE 的设计允许模型提出流程图，由图执行器（按节点和连接关系执行任务的程序）运行，再比较新旧版本的记忆与结果。它与旧 CLE 的固定职责链是不同研究路线。相关文档记录了流程提案、执行与审阅界面等实现，但小批链路测试不能证明效果。当前任务仍以旧 CLE 为主，不把 MASE 的记录拼入 CLE。

### 10.4 当前运行从哪里找？

| 入口 | 当前用途 |
| --- | --- |
| D:/Agent/sct-security-generation | 源码、配置、小摘要与报告 |
| E:/ResearchRuns/CLE/20261027_full_requirements | 当前原始运行、请求、响应、各恢复段和冻结状态 |
| tools/cle_live_workbench | 工作台、守护和自主执行队列 |
| configs/cle_weekly_full_20261027 | 本轮学习协议与原生入口 |
| docs/research/CLE-TODO-20261022-20261028-v09.md | 当前探针接力与全量暂缓规则 |
| docs/research/CLE-STORY-20261028-nine-ideas.md | 九条思路的起因、实验与结论脉络 |

同一实验的恢复段属于同一研究任务，不另算新实验。保存前缀可复用，累计预算不因恢复重新开始。

返回目录

## 十一、工作台怎样监控和接续实验？

### 11.1 当前使用哪个工作台？

当前入口是本机 CLE 工作台。它显示每项实验的完成量、执行人标签、实际 worker、最近保存时间、错误与接续任务。API 调用负责生成、选卡和向量计算；Codex 分析负责读代码、分析结果及修复执行问题；人工复核负责确认检索标签。这三类工作不能互相冒充完成。

旧手册介绍的只读仪表盘是历史工具。当前工作台增加了本机守护、自主接续和 Codex CLI 修复；它不依赖本聊天窗口定时盯守。修复与分析使用 6.1 Sol、极高推理强度，实验生成仍使用固定 v4.1 模型。维护模型和实验模型是两个不同角色。

当前正式生成设置为 thinking disabled、temperature=0、最大输出 4096 Token、单 user 消息、原 P7 最多三张卡与最多一次修复，沿用原验证器。原 P3 无经验基线与 P7 空卡流程不同，不能互相替代。

## 11.2 现在跑到哪里？

以下是 19:40 的固定快照。完成数是已保存的做题单元；同题不同条件、不同重复分别计单元，不算新题。

| 阶段 | 完成/计划 | 最终 Joint/已测 | 获反馈卡数/1939 |
|---|---|---|---|
| K0：D_init 起点学习 | 303/303 | 148/301 | 445，22.95% |
| K1：D_grow 第一轮 | 273/273 | 133/272 | 610，31.46% |
| K2：D_grow 第二轮 | 273/273 | 124/273 | 702，36.20% |
| K3：D_grow 第三轮 | 118/273 | 56/118 | 743，38.32% |

K0 和 K1 的交付数与已测数不同：完成了代码交付，不等于所有结果都能计入有效测量。覆盖率表示至少获得一次合法反馈，不表示这些卡都是正分卡。K1 和 K2 是在线学习结果，期间 Q 在变化、代码也重新生成，因此 133 降至 124 不能单独归因为 Q；冻结后同题对照才用于判断 Q 收益。

| 功能安全条件 | 已完成 | 已测 | 功能通过 | 安全通过 | Joint |
|---|---|---|---|---|---|
| B0：无卡 | 420 | 419 | 190 | 316 | 162 |
| BM：原始混合卡 | 421 | 421 | 213 | 335 | 182 |
| BF：仅功能内容 | 422 | 419 | 202 | 316 | 165 |
| BS：仅安全内容 | 420 | 419 | 205 | 325 | 174 |
| BFS：功能安全分区呈现 | 421 | 421 | 211 | 330 | 178 |

五条件计划各 596 次，共 2980 次。当前原卡 182 次 Joint、分区 178 次 Joint；各臂完成的具体任务集合尚未完全一致，最终分析按同题同重复配对，不能把当前总数差直接当作拆分造成的净损失。

## 11.3 为什么会暂停或恢复？

11. 先核对真实进程、请求日志、已保存响应和最近写入；题数短时间不变不等于进程中断。

12. 对已授权的 TLS 或网络中断，复用完整题目和请求前缀，只补发缺失响应；原失败和未知费用继续保留。

13. 同一任务的成功响应不重复付费生成；重复实验必须独立生成，不能复制一份响应充当两次重复。

14. 阶段完成后进行零 API 回放、统计和实际代码分析，再由队列接续允许的下一项。排队全量保留为暂缓，不当作已完成。

10 月 28 日 24 点前已获全天实验授权；之后恢复工作日 09:00—12:00、14:00—18:00 禁止新模型和 Embedding 请求的规则，在请求边界等待。学习逐题更新 Q，保持单 worker；学习和评价合计不超过 4 个 worker。

当前配置见工作台自主队列，执行规则见探针接力清单 v09。

返回目录

# 十二、项目实验体系：为什么需要不同的对照

## 12.1 四类核心操作与实际入口

| 操作 | 回答的问题 | 入口 | 是否改变长期经验 |
| --- | --- | --- | --- |
| 完整 CLE 训练 | 整个经验增长与生命周期怎样运行 | methods/sct_trajectory/run_closed_loop.py | 是，按训练协议产生和管理经验 |
| 训练开发池审查或重评价 | 卡或库在开发题上怎样表现 | 主流程 Phase 3；独立开发比较可用 methods/cle_ablation/runner.py 等 | 正式门控可能改变状态；冻结开发对照不改变 |
| 独立冻结评价 | 已确定方法对评价数据怎样表现 | run_plus_frozen_comparison.py、对应冻结实验入口 | 不允许从最终测试更新长期库 |
| 既有结果分析 | 已经发生了什么，差异在哪 | 报告脚本、原始 JSONL 与工作台 | 不生成新模型结果 |

同一个入口可以有不同模式；同一种操作也可能有独立编排脚本。实际启动参数与输出目录比页面按钮数量更能确定实验身份。

## 12.2 对照实验的基础语言

研究问题（希望用证据回答的具体问题）要先确定。自变量（主动改变的因素）可以是“是否使用 Q”；因变量（观察的结果）可以是 Joint；控制变量（保持不变的条件）包括题目、模型、经验正文和修复次数。

基线（用于比较的参考方法）不是一定最弱的方法，而是能解释改动作用的参照。消融（移除一个部件再比较）用于估计该部件是否有帮助。混杂因素（与目标改动一起变化、也能影响结果的因素）例如同时换更强模型，会使归因变难。

## 12.3 九条 baseline 是什么

四条 Prompt baseline（单次模型请求的提示对照）是 Greedy、Greedy+Secure、CoT 和 CoT+Secure。Greedy（直接按模型输出生成）与 CoT（Chain-of-Thought，要求逐步推理的提示方式）主要区别在输入要求。

五条 Agent baseline（带多个执行阶段的对照流程）是 AutoSafeCoder、RA-Gen、SWE-Agent、AgentCoder、SecAwareCoder。项目有对应适配实现；不能把适配叫原作者所有条件下的完全复现。

真实统一运行入口是 methods/workflow_baselines/run_true_agent_workflows.py。methods/prompting_baselines/run_prompt_baseline.py 是提示展示桩，不负责真实完整实验。

忠实性检查（fidelity，核对规定的关键阶段有没有实际执行）要与正确率一起看。历史曾有单提示适配器挂着多阶段 Agent 名称；这些记录不能用来声称五条原工作流的正式排名。

## 12.4 P0–P7 是怎样拆解 CLE 的

P7 是实验臂编号，不是第七阶段。下面是独立消融入口定义，表内“修订”仍需结合 PLT 与 Base/Plus 各自反馈协议解释：

| 臂 | 主要设置 | 意图 |
|---|---|---|
| P0 | 直接提示，无经验 | 最简单参照 |
| P1 | 明确功能与安全契约，无经验 | 检查约束表达的作用 |
| P2 | 初析、规划、生成，无经验 | 检查多步骤流程 |
| P3 | P2 加一次修订 | 检查额外修改机会 |
| P4 | Phase 1 卡，检索、复析、规划、生成 | 检查初始经验配置 |
| P5 | 最终冻结库，生成侧不复析，不注入负向护栏字段 | 部分移除经验适配与负向字段 |
| P6 | P5 加复析和拒绝卡隔离 | 检查复析/采纳的增量 |
| P7 | 完整冻结前向链、完整卡字段 | 当前完整前向参照 |

P5 的语义检索仍可能做模型适用性筛选，不能叫“完全没有适用性判断”。只删 negative_guardrail 字段也不保证其他字段不含负向建议。P5–P7 共用已经门控的库，不能据此证明门控本身的作用。

P4 与 P7 的库既有轮次差异，也有状态和内容差异，不是只改变“卡片数量”。当前 Q 实验复用 P7 生成链，却使用固定 M0+Q，不意味着已经得到完整演进后的最终库。

## 12.5 RQ1–RQ4 与贡献候选

| RQ，研究问题编号 | 关心什么 | 设计贡献候选 | 必须有什么证据 |
|---|---|---|---|
| RQ1 | 完整 CLE 是否更好 | 有边界经验学习改善功能与安全联合结果 | 同题、同信息与明确预算的完整方法比较；独立评价 |
| RQ2 | 哪些组件产生作用 | 正向原则、负向护栏、轨迹提炼、复析与程序采纳 | 部件真实被改变的消融，采用及落实证据 |

| RQ，研究问题编号 | 关心什么 | 设计贡献候选 | 必须有什么证据 |
|---|---|---|---|
| RQ3 | 经验生命周期是否有效 | 候选审查与回归约束减少有害经验 | 晋升和退役记录、增量与回归覆盖、独立迁移 |
| RQ4 | 收益值不值得成本 | 以更少代价取得足够收益，或解释成本边界 | 调用、Token、时间、错误与收益共同报告 |

贡献候选（值得验证的研究主张）不是已被认可的原创贡献。外部记忆、检索、角色分工和反思已有相关研究。项目的差异需要落在具体机制和证据上，不能靠重新命名。

返回目录

# 十三、原手册收录的历史研究说明了什么？

本章保留原手册中的历史实验，其任务、模型和协议按当时版本解释。当前 v4.1 状态见第十一、十四和十七章。

本章数字取自仓库 2026-10-13 实验审计和相关报告，**本次未重新执行或全部重算历史原始记录**。较新的审计修正了早期过强表述；不把早期版本的好看数字直接写成当前性能。

## 13.1 历史主要发现

| 方向 | 已记录结果 | 当前可说的结论 |
|---|---|---|
| 层次与语义检索 | 273 题 Joint：76 与 71，p=0.487；语义组存在筛选失败 | 语义检索没有在该批证明准确率优势 |
| 筛卡协议可靠性修复 | 24 题两组均 7/24 | 可靠性改善不等于已提分 |
| 三候选分支 | 273 题任一候选成功上界：普通采样 87、不同计划 88；实际最终交付 67、61 | 生成更多候选不保证选对；上界不能当交付成绩 |
| 串行一次修复 | 273 题首次 71、最终 95 | 使用训练侧反馈有收益，但反馈与预算不同，不是纯架构比较 |
| 09-25 门控开发评价 | 298 题原库 67、过滤后 80；配对 p≈0.0146 | 同门控池选择并评分，存在选择偏差，不能直接当独立增益 |
| 对齐后的冻结评价 | Base 5→6/115，Plus 40→41/140；Plus p=1 | 上述开发增益没有转化成明确冻结收益 |
| 接口保护加合格代码示例 | 新确认集从 17/50 到 22/50，救回 9、丢失 4，p=0.267 | 有方向性信号，但统计证据不足，且存在功能损害 |
| 提示矩阵中的 P13/P22 | 本地 Plus 从 28/140 到 43、42；多重比较后仍有信号 | 同时改变了经验呈现，不能全归因于某一句话，也不能推广到全部语言 |
| 10 月 16 日前 Q 探索 | 当时三臂 2/8、3/8、2/8，唯一多过题无卡介入 | 已实现并激活部分选择，未证明 Q 提分 |

p 值（在无差异假设和相应统计模型成立时，当前或更极端结果出现的概率）不是“方法无效的概率”。后面会说明怎样阅读。

## 13.2 哪些旧“成功”不能继续这样说

Oracle 上界（看过真实答案或最终成绩后，挑出最有利结果的理想诊断）不是可部署系统的实际选择。某历史 40 题实验直接提供当前题参考答案后分数大幅提高，只说明答案信息帮助很大，不能证明“经验粒度是唯一问题”。

有些历史消融标签不同，但实际启动参数相同。相同方法两次运行分数不同，不能拿来证明某个根本没被关闭的模块有效。

某冻结库有很多卡，但绝大多数是待验证状态，也不能写成“数千条知识都通过严格门控”。参考解全通过是在校准验证器，不是模型生成全通过。

## 13.3 可以如何陈述项目贡献

目前较稳妥的三层表述是：

15. **系统设计与工程实现**：建立围绕功能/安全双维度的生成、修复、轨迹提炼、经验管理与冻结消费链，并保存可定位的运行记录。

16. **实验方法与诊断认识**：通过组件比较、真实采用记录、同题配对和错误分类，发现候选选择、功能契约、奖励归因和评价条件的实际瓶颈。

17. **待证实的效果主张**：完整经验演进、严格门控、跨语言迁移或 Q 是否稳定提高独立正确率，仍需相应实验支持。

“做了系统”不自动等于“提出原创算法”；“做了很多实验”不自动等于“得到充分结论”。负结果（没有支持预期改善的实验结果）也有研究价值，但应清楚限定条件，说明它排除了什么简单解释。

## 13.4 仓库里的 M1–M6、A1–A7 另外在探索什么

这是历史候选筛选（先用开发实验挑选值得继续研究的思路）的一组编号，不是前面二十项职责模块，也不是 CLE 树配置中同名的 A1–A7。

| 编号 | 思路与简单解释 | 已有证据边界 |
|---|---|---|
| M1 | 给文字经验配其他训练题的漏洞/修复代码与合法行为说明 | 有值得保留的信号；不能提供当前待测题答案 |
| M2 | 根据历史效用决定是否用经验 | 早期校准没有正效用卡，最终空检索；不等于本次完整 Q 学习 |
| M3 | 先写草稿，再检索经验进行修复 | 有局部开发分差，也有功能损害，未独立确认 |
| M4 | 根据反例修改经验适用与排除条件 | 原型改动有限，未稳定超过未修订的 M1 |
| M5 | 把经验变成可执行检查技能 | 使用覆盖低，当前没有净收益 |

| 编号 | 思路与简单解释 | 已有证据边界 |
| --- | --- | --- |
| M6 | 区分漏洞机制与语言/API 知识 | Python 原型不能证明跨语言迁移，尚未验证 |
| A1 | 分别让功能和安全角色审查 | 增加流程，当前未见可靠收益 |
| A2 | 根据失败类型选择修复路线 | 开发未见净收益，且依赖训练侧反馈 |
| A3 | 简化流程并明确接口清单 | 有保留价值，但简化与契约同时变化，不能全部归因于减少阶段 |
| A4 | 调整不同审查角色的输出预算 | 预算变化也是因素，未独立确认 |
| A5 | 根据公开检查决定是否继续修复 | 旧 60 题全部进入修复，没有形成有用提前停止 |
| A6 | 生成两个候选再选择 | 候选中有正确答案不代表选择器能选中 |
| A7 | 外层比较流程、内层调整记忆，再冻结确认 | 是筛选程序，不是一种固定生成方法；不等于任意自动架构搜索 |

CLE 自身的 A7 是 sct_trajectory/ablation.py 中的经验层次配置，当前方法选择它并关闭额外语言叶；上表 A7 则位于旁路研究。通用命令默认配置也未必是 A7，正式运行必须显式核对参数。这是同一个仓库反复使用编号造成的命名歧义，不是七个 Phase。

返回目录

# 十四、Q 究竟改变了什么，怎样判断它有没有用？

## 14.1 Q 是什么，怎样学习？

Q 记录一张经验卡过去被实际采用后，生成代码得到的反馈。当前固定 1939 张卡的正文，Q 和访问次数从零开始；先完成 D_init 的 303 题，再在 D_grow 的 273 题上做三轮，共 1122 次做题。这个固定卡库学习实验不产生新经验卡，也不改变大模型参数。

每次有合法反馈且卡片被实际采用时，更新公式为：

**Q 新 = Q 旧 + 0.3 ×（奖励 − Q 旧）。**

同一份代码同时通过功能和安全测试，奖励为+1；完整、合格的非 Joint 结果奖励为−1。技术错误、缺测或奖励资格不合格不授予反馈。被采用的卡共享该次代码结果，因而 Q 表示历史关联，不能直接证明每一张卡造成了成功或失败。

例如，从 0 开始连续两次成功，Q 依次变为 0.3、0.51；再失败一次，Q 变为 0.057。近期反馈会改变评分，但不会一次完全覆盖历史。visits 表示更新次数；Q 恰好为 0 与从未更新不是同一概念，覆盖率应按反馈记录或 visits 计算。

本轮 D_init303 题均具备奖励资格；活动 D_grow 学习输入中 232 题合格、41 题仍完整做题但不授予 Q 反馈。后续记忆标签实验使用另存的公开契约修订版，参考实现 273/273 通过，这不会追溯改变正在执行的学习资格。

## 14.2 Q 和相似度分别占多少？

候选卡先由检索获得，再按以下分数调整呈现顺序：

**排序分 = 0.5 × 标准化语义相似度 + 0.5 × 标准化 Q。**

标准化在本次候选组内进行，使两个数值可比较；组内没有差异时该项标准化值为 0。本轮阈值 δ 为−1，排序入口不截成数值前三张，随后仍由原 CLE 的 LLM 判断最终选哪些卡，最多三张。因此“各占 50%”是排序公式的权重，不是模型看 Q 和语义各花一半注意力，也不是一半概率按 Q 选卡。

一次完整流程是：公开题目→初析→检索候选→Q 参与候选排序→LLM 选择 0 至 3 张→复析与采纳→计划→代码→验证→必要时一次修复→对合法且实际采用的卡更新 Q。冻结评价使用已学 Q，但不再更新 Q 或卡片正文。

## 14.3 四臂各自回答什么？

| 条件 | 选择方式 | 用途 |
|---|---|---|
| Q0 | 原 CLE 候选路径和 LLM 终选 | 对照原方法；原候选边界与其余臂的差异单列 |
| Q1 | 相似度呈现，LLM 终选 | 判断 Q 是否胜过只用相似度 |
| Q2 | 相似度与真实学习 Q 联合排序，LLM 终选 | 待检验方法 |
| Q3 | 同 CWE 内打乱 Q 及 visits 配对后排序，LLM 终选 | 判断真实评分信息是否胜过仅扰动顺序 |

Q1、Q2、Q3 使用相同阈值和候选规则；Q3 固定置换种子 20261015。只比较 Q2 和 Q0 不足以排除候选边界变化，因而 Q2 对 Q1 和 Q3 是两个主要比较。

## 14.4 过去的探索已经说明什么？

| 证据 | 实际结果 | 对研究问题的判断 |
|---|---|---|
| v3.2 早期固定库学习 | 297/1939 张卡有反馈，15.32% | 反馈覆盖集中；这不是正分卡比例 |
| 后续放宽选卡和学习探索 | Q 覆盖增加，但没有建立稳定 Joint 收益 | 增加覆盖不是收益证明 |
| v4.1 选择重复实验 | 8 个题族、4 臂、5 重复，共 160 次选择 | Q 改变了具体卡号，变化超过该实验中的重复波动 |
| v4.1 旧冻结 Q 代码对照 | Q0=11/48；Q1=13/48；Q2=11/48；Q3=13/48，其中 Q3 有 1 次缺测 | 学习 Q 没有超过两个主要对照；缺测不记作模型失败 |
| v4.1 本轮重新学习 | 743/1939 张卡获得反馈，第三轮仍在运行 | 证明反馈范围扩大；收益由后续冻结比较回答 |

早期学习曾使用 δ=0.7613717780938312 等历史门槛和不同奖励资格，不能把那些参数当作当前运行参数。详细历史批次保留在 10 月 16 日原手册和本周实验报告。

### 14.5 为什么很多卡仍没有反馈？

一张卡必须依次经过“进入候选、被选中、被采用、获得合法结果”才能更新。没进入候选的卡不会因库中存在而被学习；相关性差或来源前提不符的卡即使进入候选也可能被拒绝；同 CWE 的不同题族不一定需要相同修法。当前代码结果又给多张卡共同记分，无法区分哪张卡真正有效。

因此需要同时看覆盖率、选卡编号、实际采用、代码落实和 Joint。若 Q 提高了某张卡的顺序并被采用，但代码仍覆盖外部配置、误搬来源假设或没有落实建议，瓶颈就在选卡之后。不能把“模型说采用了”直接写成“代码落实了”。

### 14.6 什么结果才支持 Q 收益？

冻结同题比较先排除学习继续变化的影响，再比较 Q2 与 Q1、Q3。两个主要比较按 Holm 方法校正；达到校正后 $p \le 0.05$、按题族计算的 95%差值区间下界大于 0、两次重复净收益均非负，才按预设规则支持稳定提升。未达到门槛时直接报告观察到的增益或损失，不宣布已经稳定提分。

技术探针只检验执行链路；当前 54 题回测用于观察轮次和局部信号。完整 D_gate 四臂仍在队列中暂缓，不会因探针运行成功自动启动。在线学习的成绩变化不能替代这个冻结比较。

返回目录

## 十五、科研基础：怎样自己判断一张实验表

### 15.1 先问“实验单位是什么”

样本单位（独立观察对应的对象）可能是任务、题族、任务×方法记录、代码尝试、模型请求或卡次。8 道题×3 组是 24 条记录，不是 24 道独立题。反复修复同题，也不等于增加独立样本。

配对比较（同一题在两个方法下逐题比较）应报告救回多少、损失多少，再看净差。只看 17→22 会漏掉“救回 9、损失 4”这一更具体的事实。

### 15.2 统计术语应该怎样理解

| 术语 | 简单概念 | 常见误读 |
| --- | --- | --- |
| 效应量 | 改动实际带来多大差异 | 只报显著或不显著，不报改善多少 |
| p 值 | 在指定无差异假设下看到当前或更极端结果的概率 | 把它当成方法无效的概率 |
| 置信区间 | 按同一方法长期重复抽样时，有规定比例的区间覆盖真实差异 | 把很宽区间中的一个正点估计当确定收益 |
| 多重比较校正 | 同时试很多方案时，控制偶然出现好结果的风险 | 只挑几十组中最好的一组报告 |
| 等效性 | 差异小到落入事前规定的可接受范围 | 把“未显著”当“已证明一样” |
| 选择偏差 | 因选择题目或方法的方式而使结果倾向某方向 | 在同一批题上选最好方案又声称独立提升 |

| 术语 | 简单概念 | 常见误读 |
| --- | --- | --- |
| 敏感性分析 | 改变明确的统计口径，看结论依赖什么 | 事后删坏题，只留下最好看的分母 |
| 可复现性 | 别人能找到输入、规则、代码版本和结果并核对 | 只有一个汇总百分比或网页截图 |

统计证据与机制证据相互补充。分数高但没有经过目标机制，不能直接归因；机制激活但总分不高，也不能硬说有效。

### 15.3 四种不同的可信度问题

内部有效性（差异是否由声称的改动造成）：是不是同时换了模型和提示？

测量有效性（所测数字是否对应真正的问题）：安全全过是不是因为所有请求都拒绝？

外部有效性（结论能否推广到其他条件）：Python 的 8 题结果能不能代表其他语言？

统计结论有效性（数据量和分析方法能否支撑结论）：样本是否独立，比较是否太多，缺测如何处理？

这四个问题就是读论文和做组会汇报时的基本检查，而不是额外的术语负担。

返回目录

## 十六、参与项目：一次实验从想法到归档

### 16.1 先判断改动要求重做哪一层

| 想改什么 | 最小必要操作 | 不能直接复用什么结论 |
| --- | --- | --- |
| 报告图表或统计解释 | 读旧记录、离线重算 | 不得把重算当新模型实验 |
| 冻结库的排序公式 | 在固定卡库上重新生成配对评价；若公式不需新学习，可复用既有 Q | 旧生成代码不能代表新排序的真实输出 |
| 复析或生成提示 | 所有相关臂共同固定新版本并重评 | 不能与不同提示版本混作单因素比较 |
| Q 奖励定义 | 若所需证据已完整保存，可重算学习值，再重做生成对照 | 单纯重排不能给出新正确率 |
| 卡片结构、提炼方法 | 重生成对应经验，并重新审查与评价 | 旧卡成绩不能直接验证新卡内容 |
| 门控或生命周期 | 重做受影响的经验审查及冻结后评价 | 开发池筛选成绩不替代独立收益 |
| 更换生成或向量模型 | 固定新模型重新校准相关条件并做同题对照 | 旧模型阈值、用量和效果不自动适用 |

| 想改什么 | 最小必要操作 | 不能直接复用什么结论 |
| --- | --- | --- |
| 翻译数据或验证器 | 先确认契约与参考，再统一重新测量受影响结果 | 不能只重评有利方法 |

这里“重新训练”主要指重新生成/管理外部经验，未必是模型参数训练。

## 16.2 正确的操作顺序

18. 写一句研究问题：只问一个主要机制，说明哪些保持不变。

19. 固定任务清单、数据用途、模型、生成预算、评价规则和输出目录。预算（允许花费的请求、Token 或时间上限）属于实验设计的一部分。

20. 检查公开契约、参考实现、实际运行环境与必要凭据来源；只记录凭据来源标签，不复制内容。

21. 做冒烟测试（用极少任务确认链路能跑通），再进行已批准规模的实验。一次通过只证明该测试链路通过，不证明方法有效。

22. 保留所有已落盘结果，包括失败、缺测和成本。输入变化时建立新运行身份，不混进旧目录。

23. 汇总主结果，再逐题检查机制路径。完成报告、精简摘要和原始文件定位。

本手册不附一个“全部启动”按钮式命令，因为完整训练、Q 学习、冻结评价和旧历史入口需要不同配置，成本和反馈边界也不同。各实际入口已在前文定位；配置应来自对应实验说明，而不是使用碰巧可运行的默认值。

## 16.3 目录和文件怎么读

JSON（键值式结构化文本）适合配置和汇总；JSONL（每行一条 JSON）适合逐题流式保存；CSV（行列表格文本）适合表格软件；Markdown（带轻量排版标记的文本）适合报告。

| 完整 CLE 典型文件 | 含义 |
| --- | --- |
| run_metadata.json | 模型、参数、数据和版本信息 |
| pools.json | 本次三池实际任务名单 |
| phase1_results.jsonl | 来源经验及其生成验证记录 |
| trajectories.jsonl、rounds.jsonl | 逐任务执行与外层轮次 |
| experience_pool.jsonl | 实际经验池 |
| error_ledger.jsonl | 错题本 |
| gate_records.jsonl、audit_detail.jsonl | 候选检查与实际审查对象 |
| frozen/m_star.jsonl | 冻结快照；还须配合配置解释可用集合 |
| final_eval.jsonl、final_eval_summary.json | 收尾评价明细与摘要，需检查是不是独立评价 |
| cost.json、status.json | 用量成本和运行状态 |

Q 独立实验通常使用 rows.jsonl、summary.json、memory_q_events.jsonl 和共享初析文件，不强行改造成完整 Phase 格式。摘要描述现象，原始逐题记录负责证明现象。

Git（代码版本管理工具）主要保存源码、配置和小型精简结果。提交号（某次保存代码状态的标识）如果不包含未提交工作区改动，就不足以代表实验全部源码，所以还要看当次源码快照。

当前本地分支为 fjy/cle-contract-conditional-q-20261023。实验源码、输入和结果以当次保存快照为准；当前工作区存在未提交改动，本次手册更新不提交或推送代码。

返回目录

# 十七、九条思路分别怎样推进，现在先做什么？

当前安排围绕同一个目标展开：先确认经验是否被正确检索、选择和落实，再判断其是否提高同一份代码的功能与安全表现。当前执行以探针接力清单 v09 为准；早先 v08 中的全量安排保留为后续研究设计，不再表示自动启动授权。

| 研究问题 | 当前证据或状态 | 下一项允许执行的工作 |
| --- | --- | --- |
| Q 能否改善选择和 Joint？ | 已改变选卡，稳定提分未建立；本轮 967/1122 | 完成本轮学习，分析与回放后做 54 题五条件两重复，共 540 次 |
| 多轮学习是否更有用？ | K1 与 K2 已完成，K3 运行 | 同 54 题比较各冻结轮次；不用在线成绩差替代配对效果 |
| 功能安全分开能否少误伤？ | 小样本拆分未改善；全量 2104/2980 运行 | 完成五条件对照，分析 Joint 和功能安全四象限 |
| 哪些错误由契约、来源假设或实现造成？ | 已有逐题代码复盘 | 复用差异题；必要时最多 6 题、12 次本地单点验证，无实验模型请求 |
| 不同题适合多具体的经验？ | 五档标签未开始 | 先 82 题×5 档×2 次，共 820 次；必要时按原条件追加 82 题 |
| 分类器能否选对记忆程度？ | 旧分类器 21/48，固定提醒 22/48 | 新真实标签训练完成后，先 6 题×3 策略×2 次，共 36 次 |
| 检索是否找到适用经验？ | 池内标注与人工确认尚未完成 | 先 57 题；按覆盖和区间门槛决定是否追加 57 题，输出人审材料 |
| v4.1 自己积累的卡是否更适合 v4.1？ | 新库尚未建成 | 先 2 道初始化题验证新库流程；完整建库暂缓 |
| 模型与卡库是否存在交叉适配？ | v3.2 停用；v4.1 新库尚缺 | 完整新库就绪后 12 题×3 条件×2 次；精确复用 48 次，最多新生成 24 次 |

## 17.1 哪些全量现在不会自动启动？

已启动的 Q 学习 1122 次和功能安全 2980 次继续执行。未启动的冻结回测剩余 876 次、D_gate 四臂 2384 次中的非探针部分、分类器审计 1788 次中的非探针部分、完整新库、全量卡库交叉及外部验证均先跳过。Q 审计前置技术探针为 2 题×4 臂×2 次，共 16 次；它只验证接线。

“跳过”表示保留任务并继续寻找其他已就绪探针，不表示删除任务，也不表示放弃真实前置条件。例如，两题建库探针不能冒充完整新库供应卡库交叉实验；没有真实完整标签和训练结果，分类器探针也不能借用旧分类器冒充新方案。

### 17.2 什么时候扩大，什么时候收口？

24. 记忆标签先检查是否至少覆盖 30 个训练题族、至少两个有效档位且每档至少 5 个题族，并满足登记的其余训练条件。不满足时最多追加 82 题；到 164 题仍无法形成可用标签则结束本轮分类器分支。

25. 检索 57 题检查主要 CWE 覆盖、至少 20 题含适用卡，以及池内召回率区间半宽不超过 0.10。不足时最多追加 57 题。人工未确认前输出 AI 估计与复核材料，不宣布正式人工指标或全库召回率。

26. 功能安全拆分以 Joint 为主要比较；Joint 提高且安全不下降，支持在保持安全下改善功能。功能提高而安全下降表示权衡，不能写成整体改善。

27. Q 和分类器完整比较使用预设配对统计门槛；至少 2 个百分点的稳定收益用于优先投入，较小但通过门槛的收益如实称为小幅提升。

28. 效率结论要求 Joint 差值区间下界高于−1 个百分点，且可完整核算的 Token 减少至少 20%；未知用量不能逆转这个判断。

小样本扩大条件只决定已登记的小批追加，**不解除当前排队全量暂缓规则**。探针全部完成后应先交付机制判断、成本和建议，再决定哪些全量值得执行。

### 17.3 当前有哪些真实依赖？

v3.2 已不可用，原计划的新 v3.2 交叉臂结束，既有结果继续作为历史证据。Base115 题和 Plus140 题需要原验证镜像；镜像未到位，不用替代验证器。新 v4.1 卡库及相关交叉臂等待真实建库。人审材料可自动整理，人工确认不能由程序代签。

部分新增探针节点已进入自主队列，但仍要完成独立限量入口和离线验证后才能派发；队列里出现任务名不代表模型实验已经运行。当前工作台调度验证与科学结果分开记录。

返回目录

## 十八、组会怎样用一分钟讲清项目？

本课题研究外部经验如何改善安全代码生成。CLE 把做题反馈变成经验卡，再检索、选择和使用这些经验；评价要求同一份代码同时通过功能与安全测试，这就是 Joint。Q 根据被采用卡的历史反馈更新评分，当前参与候选排序，最终仍由模型选择最多三张卡。

已有结果确认 Q 改变了实际选卡，但旧 Q 迁移到 v4.1 没有提高 Joint；功能安全拆分和记忆程度分类器的小样本结果也未胜过各自对照。当前正在完成重新学习 Q 和功能安全完整对照，后续改为探针优先，避免尚未确认机制就启动所有全量。分析重点是区分题面契约、经验来源假设和代码实现问题，再决定哪些方案值得扩大。

### 18.1 阅读实验结果前检查什么？

29. 这是在线学习、冻结评价，还是技术探针？它们回答不同问题。

30. 分母是独立题目、同题重复还是已测代码？缺测不能记成模型失败。

31. 对照是否使用相同题面、模型、候选、尝试预算和验证器？P3 不能代替 P7 空卡。

32. 卡片有没有真正进入代码？选中、口头采用和实际落实分开检查。

33. 新结果改变了哪条主线判断？已经完成、正在运行、等待依赖和暂缓全量分别标明。

返回组会速读 · 返回目录

返回目录

## 证据与进一步阅读

- 本次 19:40 运行快照：当前完成量、成绩、Q 覆盖与用量。
- 当前执行清单 v09：探针规模、全量暂缓和接续规则。
- 全量探索执行记录：协议、故障恢复、回放和分析入口。
- 九条研究叙事：每条研究问题到实验安排的逻辑。
- 10 月 22 日至 28 日实验报告：已完成基础实验和逐题分析。
- Q 更新与排序代码：更新公式、标准化和排序实现。
- 10 月 16 日原手册：首次接触项目时的完整历史说明。