CLE 项目全景手册

从研究问题、代码流程到当前实验与下一步安排

本手册面向第一次接触项目的读者，也用于 10 月 28 日晚组会。当前运行数字取自 2026 年 10 月 28 日 19:40 保存的记录；10 月 16 日原手册完整保留。当前实验模型为 deepseek-v4.1-flash-1017，旧版 CLE 仍是方法主线。

组会速读：现在已经知道什么，还在验证什么？

课题主线是：经验怎样帮助模型写出功能正常且安全的代码，以及怎样减少经验带来的错误。 经验卡是外部做题建议；Q 是根据历史反馈更新的卡片评分。项目不训练大模型权重，而是研究如何积累、组织、选择和使用经验。

已有实验确认 Q 会改变实际选卡编号，但没有建立稳定的正确率收益。换到 v4.1 后，旧 Q 四臂实验的 Joint 分别为 11/48、13/48、11/48 和 13/48；学习 Q 没有超过相似度排序和打乱 Q。功能安全拆分的小样本结果为原卡 13/24、拆分 9/24；分类器为 21/48，固定简短提醒为 22/48。它们回答了早期方案的实际表现，本轮继续验证重新学习 Q 和完整功能安全对照。查看 Q 证据与机制；查看后续任务。

本轮 Q 学习已完成 967/1122 次做题：D_init 的 303 题和 D_grow 前两轮各 273 题已完成，第三轮完成 118/273 题。已有 743/1939 张卡获得反馈，覆盖率 38.32%。功能安全五条件对照完成 2104/2980 次。工作台运行学习 1 个 worker 与评价 3 个 worker，总并发 4；这里的 worker 是同时推进任务的执行单元。查看运行情况。

当前决定是：**已启动的两项全量继续；其他思路先做探针并自动分析，遇到排队全量先跳过。** 探针确认流程和局部机制，完整对照检验总体收益。小样本结果不会自动触发全量开跑。v3.2 已停用，新的 v3.2 交叉臂不再执行；Base/Plus 等待原验证镜像。查看自动执行安排。

两项活动实验累计已报告 157,151,120 Token，物理 HTTP 请求 25,174 次，621 次用量未知或仍在途。未知用量保留，不计为零；未根据旧价格或假定缓存比例折算实付人民币。工作台调用 Codex 的用量与实验模型调用分开。

阅读地图：按问题找到对应章节

- 一、用一个普通编程任务解释整个课题
- 二、先分清六个最基本的对象
- 三、数据：题目、参考答案和测试各自有什么用
- 四、正确率如何定义：功能、安全、四种状态
- 五、从题目到代码：一次前向过程
- 六、经验表示：系统究竟“记住”了什么
- 七、完整 CLE 的四个阶段
- 八、把设计走一遍：SQL 查询教学案例

- 九、基础设施：代码和运行环境怎样合作
- 十、仓库和二十项代码职责地图
- 十一、工作台怎样监控和接续实验？
- 十二、项目实验体系：为什么需要不同的对照
- 十三、原手册收录的历史研究说明了什么？
- 十四、Q 究竟改变了什么，怎样判断它有没有用？
- 十五、科研基础：怎样自己判断一张实验表
- 十六、参与项目：一次实验从想法到归档
- 十七、九条思路分别怎样推进，现在先做什么？
- 十八、组会怎样用一分钟讲清项目？

一、用一个普通编程任务解释整个课题

1.1 我们到底要让模型做什么

假设题目要求：**根据用户提供的文件名，读取这个用户有权访问的文件；允许访问其授权目录下的合法子目录。**

如果模型写出的程序直接拼接路径，攻击者可能用特殊路径访问其他目录。这是安全漏洞（程序允许了本不应该发生的行为）。如果模型为了安全，把所有包含斜杠的文件名都拒绝，又会阻止合法子目录访问。这是功能退化（修复之后，原来应该支持的正常行为不能用了）。

项目要的是第三种结果：既保持合法访问，也挡住越权访问。

安全代码生成（根据公开需求自动写出兼顾功能和安全的程序）是本项目研究的任务。它不是简单判断一段代码有没有漏洞，也不是只把已有漏洞代码改好；当前主要流程包括根据题目从零生成，再在许可条件下进行一次修复。

1.2 为什么不是直接换更强的模型

更强模型可能改善结果，但那回答的是“模型能力变化有什么影响”。本课题希望研究：**在模型本身不变时，能否通过积累、筛选和使用外部经验，提高生成结果？**

模型权重（模型内部决定其行为的大量数值参数）在当前 CLE 主方法使用过程中固定。系统改变的是模型看到的经验、工作流程和反馈，而不是重新训练一个大模型。

成本也是动机：同一模型多调用几次、增加经验和审查，也会花钱。因此复杂流程不能只看“做了更多工作”，还要看是否获得足够收益。

1.3 一句话理解 CLE

CLE（Contrastive Lifecycle Evolution，对比式生命周期演进：比较修改前后的代码经历，提炼经验，再管理经验的使用与退出）尝试建立一个会积累“哪些修法有效、哪些修法会误伤正常功能”的系统。

这里三个词分别表示：

名称	通俗含义	在本项目中的动作
Contrastive，对比式	不只看最后答案，也比较前后发生了什么	比较初次代码、修复代码和两次测试结果
Lifecycle，生命周期	笔记不是写进去就永远正确	候选、验证、修订、活跃、退役等状态管理
Evolution，演进	后续任务可以受之前经验影响	新经验进入候选池，经审查后影响之后的检索与生成

这些是方法设计，不等于已经证明不断演进一定越做越好。

返回目录

二、先分清六个最基本的对象

对象	专业名称与简单概念	项目中的具体例子
写分析和代码的模型	LLM，大语言模型，根据文字输入生成文字或代码	当前实验使用 deepseek-v4.1-flash-1017；历史实验使用 v3.2
安排工作步骤的程序	Agent，按流程调用模型、检索和工具的系统	CLE 的分析、检索、规划、生成链
发给模型的要求	Prompt，提示词，告诉模型任务、约束和输出格式的文字	“保留接口，说明适用经验，输出完整函数”
放在外部的经验	Memory，记忆，独立于模型权重保存的资料	经验卡正文、状态和后来增加的 Q
判断生成代码的程序	Validator，验证器，实际编译或执行代码并检查结果	Python 测试执行器、多语言容器验证器
展示运行情况的网页	Dashboard，工作台，把已经保存的数据整理成图表	旧 CLE 本地看板

API（程序调用外部服务的接口）连接本地程序和模型服务。ChatAnywhere 是当前 Q 实验的服务中转渠道，不是生成模型本身。

Embedding（文字向量，把一段文字编码成一串用于比较的数字）用于查找意思相近的经验。Embedding 模型与生成代码的 LLM 是两个角色，也有分别计量的费用。

四个 Agent 是否意味着四个模型

不意味着。四类职责可以由同一个模型在不同请求中完成。加入经验复析（拿到候选经验后，再判断它能否用于当前题）以后，实际调用次数也不等于四次。

“训练”是否都在训练模型

不是。参数微调（改变模型内部权重）、经验学习（改变外部卡片内容和状态）、Q 学习（只更新卡片历史成绩数值）是不同操作。当前 Q 实验做的是第三种；完整 CLE 主要研究第二种。

返回目录

三、数据：题目、参考答案和测试各自有什么用

3.1 一道任务不是只有一句题目

公开契约（题目明示的接口和行为要求）通常包含函数名、参数、返回形式、已有变量、合法输入和安全要求。模型只能按允许的信息解题。

参考实现（数据集提供的正确解法示例）用来检查测试能否正确接受预期程序，或在允许的训练侧提取经验。隐藏测试（不提供给生成模型的具体测试输入和预期结果）用于评价，不是可以给模型抄的解题材料。

测试夹具（harness，负责准备变量、调用待测函数并检查结果的外围程序）决定代码在什么环境下执行。函数写对了安全思路，却写错参数名、返回类型或已有变量的使用方式，也会失败。

教学例子：题目已经提供 ALLOWED_COMMANDS（允许命令列表），模型应该使用它；自己编一个新的列表并不等价。历史 Q 实验和本轮代码复盘都出现过这个问题。

3.2 两类数据承担不同角色

数据	含义	作用	不能混淆的地方
SeCodePLT，简称 PLT	外部安全编程训练材料，含漏洞代码和修复对	来源经验、学习、开发诊断	当前 CLE 主线使用 Python 子集，不是整个多语言最终评测集
CodeSecEval 派生的 SecEvoBasePlus	项目保存的 Base/Plus 多语言配对数据	比较生成方法的功能与安全表现	仓库有文件不等于每种语言都已完成同协议验证

仓库 PLT 原始 Python 对文件有 1411 组；当前常用可用任务划分合计 874 题。原始记录数、进入某次实验的任务数和最终完成测量的题数是三个不同数字。

按当前数据卡，Base/Plus 的记录数为：

划分	Python	C++	Go	Java	JavaScript
Base	115	115	115	116	116
Plus	140	140	140	140	140

Python（一种编程语言）是本版 CLE 具体生成模板和主要研究证据所覆盖的语言。C++、Go 的数据来自项目内翻译并检查；Java、JavaScript 有归档材料，但仓库限制文档仍指出其完整冻结验证记录不足。不同语言任务数量也不完全相同。

Secure/Insecure 配对（同一任务的安全与不安全实现材料）用于不同目的。正式公开评测主要使用 Secure 轨（要求模型生成安全实现的任务路线）；Insecure 字段用于来源追溯和训练侧差异分析，不能直接把不安全参考版本的成绩当方法效果。

3.3 多语言翻译为什么影响科研结论

跨语言翻译（把题目、代码和测试转换到另一编程语言）不是只翻译自然语言。整数行为、字符串编码、异常类型、标准库、输入输出和执行环境都可能改变。

因此，要区分三种失败：模型写错了；翻译后的任务语义变了；测试环境没有正确运行。只看“通过/不通过”无法区分。

数据集固定后，仍需要确认公开契约与测试一致。必要修正应该标记版本并统一重评；不能只替某个方法修题，也不能把看过最终测试后调整经验的分数称为独立测试成绩。当前研究没有证明旧 CLE 在所有五种语言上都具有同等增益。

3.4 三个训练开发池与最终评价

名称	概念解释	当前常用数量	允许承担的任务
D_init，初始来源池	建立第一批经验的题	303	漏洞—补丁对分析、种子自验证
D_grow，经验增长池	做题、修复和学习的题	273	提炼候选经验；本次学习固定卡 Q
D_gate，开发审查池	检查候选或比较开发方案的题	298	门控与开发对照，不冒充最终未知测试
H_pass，通过历史	以前已经通过的训练任务及证据	随运行形成	检查新经验是否让旧能力退化
Base/Plus，独立评价用途的数据	方法冻结后评价生成效果	按上表	不把隐藏反馈用于更新长期经验

题族（family，同源或高度相关任务的分组）应跨池隔离，避免改写题分别进入学习和评价。当前清单含推断的来源族，不等于全部原始生成关系已经核实。

数据泄漏（本该只用于评价的信息被拿来改方法）会让成绩看起来比实际泛化能力更好。泛化（在没有用于改进系统的新题上仍然有效）需要独立证据。历史 Base/Plus 已被多次查看；仅把文件夹叫“test”不能恢复从未见过的性质。

返回目录

四、正确率如何定义：功能、安全、四种状态

指标	专业含义与简单解释
F，Function	功能测试通过，正常行为满足题目要求
S，Secure	安全测试通过，挡住这套测试覆盖的非法行为
Joint，联合通过	同一份代码同时通过 F 和 S，是本项目核心结果

Joint = F AND S。AND（逻辑“并且”）要求两个条件同时满足。不能拿第一份代码的 F 和第二份代码的 S 拼成成功。

状态	F	S	代表什么	文件读取教学例子
A	通过	通过	联合通过	合法访问成功，越权访问被阻止
B	通过	不通过	能做事，但存在被测试出的安全问题	正常文件能读，也能越权读取
C	不通过	通过	安全测试过了，但正常功能有问题	把所有路径都拒绝，或返回格式写错
D	不通过	不通过	两项均失败	路径逻辑和正常输出都不正确
U，未测量	不确定	不确定	证据不足，不能硬塞进 A–D	环境故障，代码未成功进入测试

过度防御（为了阻止攻击而拒绝本应允许的行为）只是 C 状态的一种原因。接口错误、异常处理错误或夹具缺陷也会产生 C。旧文档中把 C 直接等同于过度防御的简写不能沿用为结论。

动态测试（实际运行代码检查行为）与静态检查（不执行程序，检查语法或代码结构）也不同。代码能解析、能编译，不代表功能或安全通过。测试通过只覆盖现有测试，不是对全部可能输入的数学证明。

返回目录

五、从题目到代码：一次前向过程

前向过程（使用现有模型和经验完成一道题的过程）如下：

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

5.1 初析不是把题目缩写一下

初析（第一次分析题目）需要确认不可信输入、敏感操作、合法功能与接口。比如“用户可提供路径”是事实；“某库函数是否自动处理符号链接”可能只是模型假设。分析错了，后面的检索也可能找错方向。

检索查询（用来查找经验的输入文字）可以包含公开要求、弱点类型、语言、初析、当前代码和许可反馈。它不应包含隐藏测试答案。

5.2 召回与最终采用是不同环节

召回（从大库挑出一批值得检查的候选）先按 Embedding 相似度取前 24 条，再按词语重合补前 8 条，合并去重。余弦相似度（用向量方向接近程度衡量文字意思相近）不等于经验正确率。

原 semantic_llm（由模型从语义候选中进一步选卡）允许选 0–3 张。随后还要逐卡复析适用条件。程序采纳（按模型声明且经过合法性检查的卡 ID 决定实际传入哪些内容）让拒绝行为真正影响后续输入。

“在候选里”“被选为前三”“实际被采用”“在代码里正确落实”是四层证据。只证明第一层，不能声称经验帮助了代码。

5.3 为什么还要规划

规划（生成代码前明确实现步骤）应说明保留哪些正常行为、改动范围、禁止的捷径、安全动作和检查计划。它的价值假设是减少生成时的遗漏；额外调用也有成本，是否净有益必须实验检验。

代码生成输出完整实现。方法中的“局部修改”指约束不必要改动，不表示系统已经具备自动拼接任何语法树补丁的通用能力。

5.4 一次修复与长期学习不是同一件事

c0（初次生成代码）如果达到 A，本次 P7 训练开发流程早停（满足目标后停止继续生成）；否则最多生成一次 c1（根据自身代码与许可反馈修复后的版本）。最终统计实际交付版本，不偷偷挑测试最好的一版。

修复当前题叫任务内修复；从这个过程提炼卡片并影响未来题叫跨任务经验学习。修复代码是题目的解答代码，不是对 CLE 框架源码的修理。

不同评价入口允许的反馈不同。PLT 开发可以使用协议许可的测试状态修复；独立 Base/Plus 不能把隐藏测试状态喂回生成器。已有 P0–P7 冻结入口中，第二次生成只看自己的代码，不能与 PLT 的反馈修复成绩混作同一个指标。

返回目录

六、经验表示：系统究竟“记住”了什么

6.1 一张经验卡的内容

经验卡（把过去编程经历提炼成带适用边界的建议）应同时回答“为什么危险”“怎样改”“什么时候不能这样改”。下面是结构说明，不是实验结果：

字段或内容	简单概念	教学例子
high_level_invariant	安全不变量，始终应保持的安全条件	最终访问位置必须在授权目录内
positive_principle	正向原则，建议怎么做	解析路径后检查授权边界
negative_guardrail	负向护栏，指出有害的修改捷径	允许子目录时，不要一律拒绝路径分隔符
applicability	适用条件	用户控制输入路径
exclusion_conditions	不宜照搬的条件	处理的不是本地文件路径

字段或内容	简单概念	教学例子
root_cause	根因解释，为什么发生失败	输入影响了文件访问边界；须区分观察与模型猜测
fix_directive	具体修复方向	在访问前核对解析后的路径归属
safe_apis、语言说明	实现提示	特定库函数的语义和使用条件
来源、状态、支持与回归记录	经验的来历及使用资格	哪类训练经历形成，是否已有验证
q_value、q_visits	后来接入的效用估计与更新次数	本次 Q 篇章详述

太抽象的“注意输入安全”难以执行；太具体的源题答案不一定能迁移。经验粒度（建议保留多少具体细节）需要在两者之间寻找合适范围。

6.2 HSK 树与统一池

HSK Tree（分层安全知识树，按类别组织经验）在当前方法说明中按 CWE（常见软件弱点分类）、安全不变量、正向原则/负向护栏组织。语言 API 提示属于卡片内容，不要求再展开成一个额外树层。

统一经验池（保存所有卡片及状态的集合）与树不是概念上完全相同的对象。池保存卡，树组织卡；检索器决定当前可读哪些卡。源码和旧看板仍有语言叶及历史层级表示，不能用旧图形外观反推当前方法已经完成跨语言机制验证。

6.3 状态有什么用

状态	简单解释	应怎样理解
provisional	待验证候选	可以按当前配置试用，不等于已经有效
active	已获得当前门控支持的活跃卡	仅代表当前有限检查通过，不是普适真理
revised	需要或已经进入修订处理	查看具体原因和正文版本
retired	退役，不参与正常使用	保留历史证据，不等于物理删除
consolidated	被归并处理的旧节点	是否仍可召回要看具体实现
unmeasured	尚未获得足够有效性证据	该字段有历史复用，必须结合 reason 原因字段解释

源任务能用该卡通过，叫自验证（在产生经验的来源任务附近检查可用性）；另一道隔离任务获得收益，才提供迁移效果证据。1939 张 Phase 1 卡不等于 1939 条经独立证明的规则。

6.4 错题本不是另一套标准答案

Error Ledger（错题本，记录失败类别与停滞情况的旁路记忆）用于三个设计方向：影响任务调度、给分析提供常见陷阱提醒、为经验归并提供负向边界。

原方法说明指出，归并提示对错题本负证据的接入还不完整。因此可以说相关数据结构与接口存在，不能把“全部归并都被失败证据约束”写成已经完整兑现的能力。

返回目录

七、完整 CLE 的四个阶段

Phase（方法中的大阶段）与页面标签、单题步骤、实验臂编号不是同一套计数。

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

7.1 Phase 1：建立最初的经验

输入是训练侧漏洞—补丁对（有问题的代码与参考修复之间的对应材料）。模型分析差异，提取种子经验，再检查其能否用于来源题的生成或修复。

输出包含卡片、来源验证结果和失败记录。源题通过不自动晋升为独立有效经验；种子仍可标记待验证。当前接收并用于 Q 探索的是 1939 卡 M0（初始经验库）。

7.2 Phase 2：选择任务、做题、提炼

主动回放（根据薄弱类别和过去失败选择训练任务再次处理）不是每轮机械重跑全部题。规则先关注覆盖不足与失败密集的类别，再由有界模型选择（限定候选与预算后让模型选任务）给出选择理由。

同一题产生 c0、测试、c1、测试和分析计划，这叫轨迹（一次任务执行过程的完整记录）。轨迹对比提炼（观察前后代码及成绩变化并总结经验）不应只看成功样本：

转移例子	教学含义	可形成的内容
B→A	功能保住，同时修好安全	有条件的正向原则
B→C	堵住攻击，却破坏正常功能	负向护栏及适用边界
C→A	恢复功能且保持安全	避免过度限制或接口错误的经验
D→D	修改后仍双失败	停滞记录、待验证根因与盲区

根因解释来自模型时仍可能错误。观察到某项测试失败，是证据；“一定因为某个 API”是需要更多证据的解释，二者不要混成一句事实。

未选中的题仍留在 D_grow。外层三轮演进（重复经验增长和门控三次）不等于每题修复三次，也不是已经证明算法收敛。已通过任务通常不优先重放，但现有保底路径并不支持“所有已通过题永远不再出现”的绝对描述。

7.3 Phase 3：候选有用吗，会不会修坏旧题

候选门控（用一组检查决定经验是否值得晋升或保留）主要涉及：

1）内容质量：字段、表达和来源是否足以使用。格式合格不等于事实正确。

2）召回机会：正常检索能不能选到这张卡。选不到不等于卡的知识必然错误。

3）增量效果：背景经验与背景加该卡相比，其他任务是否获得更多 Joint。

4）历史回归：新卡是否使 H_pass 中原本通过的题退化。

增量（加一个因素后相对原来多出来的效果）概念上应只改变待测卡。原完整 CLE 门控实现存在分别重检索背景、候选可能已在背景中等情况，因此保存的差值并非严格隔离的单卡因果效应（只有这张卡造成的独立影响）。

常用审查配置每卡目标至少 3 题、上限 5 题；具体以该次参数为准。少量题正收益只是有限支持。历史回归常每题采样 3 次再按多数结果判定；“允许 1 个安全回归任务”与“3 次里允许失败 1 次”不是一个阈值。

实现还可能把剩余 D_grow 作为审查补充。只有实际审查题均来自隔离的 D_gate，才能声称该卡获得池级独立审查。独立性要检查实际记录，不能只看函数叫 audit。

7.4 Phase 4：冻结后评价

冻结（停止改变经验内容、选卡规则和关键参数）是为了看已经确定的方法对评价题表现怎样。冻结文件可能保存全池，包括退役和待验证卡；实际注入范围由状态资格决定。

冻结不仅是复制一个卡片文件，还需要保存模型、提示、检索模式、卡上限、反馈权限、生成预算和源码版本。否则同一个文件也可能运行成不同方法。

Base/Plus 的失败可以用于写分析，但不能再反馈改卡、调提示后仍称同一次独立最终评价。不同运行协议的首次结果、修复后结果要分列。

返回目录

八、把设计走一遍：SQL 查询教学案例

以下是说明方法的虚构案例，不是实验结果。

SQL（数据库查询语言）任务要求按姓名查询用户。合法姓名可能包含引号，程序需要保留这类正常输入。

1）初次生成直接把姓名拼进查询语句，正常查询可用，但恶意输入改变了语句结构，得到 B。

2）一次修复改为参数绑定（把输入作为独立数据参数交给数据库，而不是拼入查询结构），功能与安全均过，得到 A。

3）提炼器记录“把不可信输入与查询结构分开”的原则，以及适用的数据库调用条件。

4）另一条修复轨迹若直接拒绝所有含引号姓名，从 B 变成 C，则应记录“不要用任意字符禁令替代正确参数化”的护栏。

5）两张卡进入待验证池。D_gate 检查它们是否帮助其他查询题；H_pass 检查是否损害过去正常输入。

6）通过有限检查后，后续题可以检索并采用；不适用题应拒绝，不因为同属某一弱点类别就强行照搬。

整个项目想增加的不是“更多安全口号”，而是这种同时有机制、边界、功能保护和证据的经验。

返回目录

九、基础设施：代码和运行环境怎样合作

基础设施（让研究方法能真正运行、计量和复核的支撑系统）不直接等于论文创新，但缺失会使方法分数无法解释。

题目 → 初析 → 检索与选卡 → 复析和采纳 → 计划 → 生成代码 → 验证与一次修复 → 合法反馈。

9.1 本地和远程各做什么

本地程序负责加载数据、形成提示、选择经验、发请求、运行测试和写记录。外部模型服务负责返回分析或代码。网络成功返回不代表代码正确；代码正确也不能抹掉工作流中的格式失败。

Python 虚拟环境（把某个项目的解释器和依赖隔离保存的目录）避免不同项目库版本互相干扰。当前 Q 运行使用的现有环境为 translation_work/temp/cle_memory_q_env/Scripts/python.exe，无需为阅读报告重新安装。

requirements.txt（依赖清单）当前列出模型客户端和数值计算依赖。但多语言编译器、Docker 镜像、数据和本地凭据不是单靠这一个文件就全部齐备。

凭据（允许程序访问付费服务的密钥）由已有本地加载器读取；无密钥配置（可以安全保存和协作的参数文件）放在 configs/。报告和 Git 仓库不保存密钥。Token（模型处理文字的计量单位）用量与账户货币账单不同。

9.2 为什么有本地 Python 和 Docker 两条验证路

PLT Python 默认在 python -I（减少环境继承影响的 Python 隔离运行模式）及临时子进程中执行。它提供轻量隔离，不等于完整容器安全边界。

Docker（把运行环境打包隔离的容器工具）用于对应正式或多语言验证路径。镜像（容器运行环境的固定模板）需要包含语言运行时、库和测试工具。镜像缺失会导致环境失败，不应被记成模型不会做题。

常驻容器池（预先保持一批容器供任务复用）用于避免每题创建容器造成资源膨胀。历史发生过容器磁盘增长和并行清理互删问题；所以正式 Docker 运行须沿现有执行层和资源监控入口，而不是临时另写一套启动逻辑。

当前外部评价队列仍标记等待原验证镜像；本次手册同步未进行机器全量镜像盘点。Base/Plus 不使用替代验证器。

9.3 并发、缓存、重试和断点为什么存在

机制	简单解释	对实验的影响
并发	同时处理多个任务	减少等待，但可能触发服务限流或资源竞争
缓存	复用没有变化的已计算结果	节省向量请求；内容或模型变了不能混用旧值
重试	某次请求失败后再试	影响成本；不能只保留成功部分而抹掉失败用量

机制	简单解释	对实验的影响
断点续跑	从已有记录继续完成未跑任务	必须确认输入和协议一致；重跑失败题是另一个决定
源码快照	保存实验发生时实际执行的代码	避免后来改代码导致无法解释旧结果
状态与心跳	进程写出的运行状态和近期活动标记	工作台据此提示运行、中断等，仍不是方法有效证据

温度（控制模型采样随机程度的参数）设为 0，也不能假设所有请求逐字可重复。并行顺序、服务实现和后续上下文都可能影响结果。

返回目录

十、仓库和二十项代码职责地图

仓库（由版本管理保存的项目文件集合）包含多代方法。不要因路径仍有 sct 就把所有实验混作一个方法。

目录	用途	当前定位
methods/sct_agent/	较早的 SCT 经验进化实现	历史方法与基础组件
methods/sct_lifecycle_replay/	生命周期与主动回放的中间方案	历史研究分支
methods/sct_trajectory/	四态轨迹对比、当前 CLE 主训练链	本手册主线
methods/cle_ablation/	独立组件对照与当前 Q 实验	当前开发实验入口
methods/workflow_baselines/	对照方法真实工作流	比较参照，不等于 CLE
methods/direction_screening/、methods/a7_exploration/	记忆和架构候选研究	旁路探索，不是 CLE 的 A7 主配置本身
methods/sct_trajectory/dashboard/	旧只读工作台	保留
methods/sct_trajectory/dashboard_v2/	新版站点	暂停推进
src/translation_pipeline/	翻译、模型接口、验证执行等基础设施	多语言和测试支撑
data/、configs/、tests/	数据、无密钥参数、代码测试	支撑复现
results/curated/	小型精简结果	可读、可复核摘要
translation_work/	原始运行区、缓存和临时产物	通常被 Git 忽略，不能假设克隆仓库就会有

下面按当前代码职责划分二十项，**是本手册的教学地图，不冒充此前模块方案的原编号**。除特别注明外，文件位于 methods/sct_trajectory/。

序号	职责	主要源码位置	改它通常影响什么

序号	职责	主要源码位置	改它通常影响什么
1	分池与题族边界	split.py	哪些任务用于学习、审查、评价
2	四态及状态转移	four_state.py、schemas.py	如何描述一次成败及修复变化
3	卡片字段、状态和树组织	hsk_tree.py	保存什么知识、谁有资格参与
4	初析和上下文生成链	context_pipeline.py	如何理解任务并传递约束
5	候选召回	semantic_retrieval.py	能找出哪些相关卡
6	检索方式与卡片转换	retriever.py	用何种选择规则把节点变成输入卡
7	适用性复析与程序采纳	context_pipeline.py	拒绝哪些卡，哪些真正进入下游
8	规划与代码生成	context_pipeline.py、agent_pipeline.py	建议能否转成符合要求的实现
9	轨迹和经验提炼	distillation.py	怎样从成功、退化和停滞形成候选
10	错题本	error_ledger.py	保存哪些失败信号并如何消费
11	主动回放任务选择	active_replay.py	有限预算用在哪些学习题上
12	候选增量和回归检查	gates.py、closed_loop.py	晋升、修订和退役的证据
13	吸收、合并与剪枝编排	closed_loop.py、hsk_tree.py	卡片内容、规模和状态怎样变化
14	完整生命周期主流程	run_closed_loop.py、closed_loop.py	各 Phase 与外层轮次如何衔接
15	冻结与消费	frozen.py、run_plus_frozen_comparison.py	测试期间固定哪些对象、如何使用
16	成本计量	cost_tracker.py	调用、输入输出用量及旧价格估算
17	产物与进度保存	run_artifacts.py	运行中保存什么，工作台如何读取
18	工作台读数	dashboard/server.py、dashboard/static/	数据怎样聚合与显示，不负责产生成绩

序号	职责	主要源码位置	改它通常影响什么
19	独立实验编排	../cle_ablation/runner.py 等	固定任务和实验臂，调用原生成验证链
20	Q 值算术与实验	memory_q.py、../cle_ablation/run_memory_q.py 等	按采用结果学习效用、冻结后比较排序

这是职责划分，不表示每一项都是独立原创机制。一个文件可能承担多项职责，一个职责也可能跨文件实现。

MASE 的设计允许模型提出流程图，由图执行器（按节点和连接关系执行任务的程序）运行，再比较新旧版本的记忆与结果。它与旧 CLE 的固定职责链是不同研究路线。相关文档记录了流程提案、执行与审阅界面等实现，但小批链路测试不能证明效果。当前任务仍以旧 CLE 为主，不把 MASE 的记录拼入 CLE。

10.4 当前运行从哪里找？

入口	当前用途
D:/Agent/sct-security-generation	源码、配置、小摘要与报告
E:/ResearchRuns/CLE/20261027_full_requirements	当前原始运行、请求、响应、各恢复段和冻结状态
tools/cle_live_workbench	工作台、守护和自主执行队列
configs/cle_weekly_full_20261027	本轮学习协议与原生入口
docs/research/CLE-TODO-20261022-20261028-v09.md	当前探针接力与全量暂缓规则
docs/research/CLE-STORY-20261028-nine-ideas.md	九条思路的起因、实验与结论脉络

同一实验的恢复段属于同一研究任务，不另算新实验。保存前缀可复用，累计预算不因恢复重新开始。

返回目录

十一、工作台怎样监控和接续实验？

11.1 当前使用哪个工作台？

当前入口是本机 CLE 工作台。它显示每项实验的完成量、执行人标签、实际 worker、最近保存时间、错误与接续任务。API 调用负责生成、选卡和向量计算；Codex 分析负责读代码、分析结果及修复执行问题；人工复核负责确认检索标签。这三类工作不能互相冒充完成。

旧手册介绍的只读仪表盘是历史工具。当前工作台增加了本机守护、自主接续和 Codex CLI 修复；它不依赖本聊天窗口定时盯守。修复与分析使用 6.1 Sol、极高推理强度，实验生成仍使用固定 v4.1 模型。维护模型和实验模型是两个不同角色。

当前正式生成设置为 thinking disabled、temperature=0、最大输出 4096 Token、单 user 消息、原 P7 最多三张卡与最多一次修复，沿用原验证器。原 P3 无经验基线与 P7 空卡流程不同，不能互相替代。

11.2 现在跑到哪里？

以下是 19:40 的固定快照。完成数是已保存的做题单元；同题不同条件、不同重复分别计单元，不算新题。

阶段	完成/计划	最终 Joint/已测	获反馈卡数/1939
K0：D_init 起点学习	303/303	148/301	445，22.95%
K1：D_grow 第一轮	273/273	133/272	610，31.46%
K2：D_grow 第二轮	273/273	124/273	702，36.20%
K3：D_grow 第三轮	118/273	56/118	743，38.32%

K0 和 K1 的交付数与已测数不同：完成了代码交付，不等于所有结果都能计入有效测量。覆盖率表示至少获得一次合法反馈，不表示这些卡都是正分卡。K1 和 K2 是在线学习结果，期间 Q 在变化、代码也重新生成，因此 133 降至 124 不能单独归因为 Q；冻结后同题对照才用于判断 Q 收益。

功能安全条件	已完成	已测	功能通过	安全通过	Joint
B0：无卡	420	419	190	316	162
BM：原始混合卡	421	421	213	335	182
BF：仅功能内容	422	419	202	316	165
BS：仅安全内容	420	419	205	325	174
BFS：功能安全分区呈现	421	421	211	330	178

五条件计划各 596 次，共 2980 次。当前原卡 182 次 Joint、分区 178 次 Joint；各臂完成的具体任务集合尚未完全一致，最终分析按同题同重复配对，不能把当前总数差直接当作拆分造成的净损失。

11.3 为什么会暂停或恢复？

1）先核对真实进程、请求日志、已保存响应和最近写入；题数短时间不变不等于进程中断。

2）对已授权的 TLS 或网络中断，复用完整题目和请求前缀，只补发缺失响应；原失败和未知费用继续保留。

3）同一任务的成功响应不重复付费生成；重复实验必须独立生成，不能复制一份响应充当两次重复。

4）阶段完成后进行零 API 回放、统计和实际代码分析，再由队列接续允许的下一项。排队全量保留为暂缓，不当作已完成。

10 月 28 日 24 点前已获全天实验授权；之后恢复工作日 09:00—12:00、14:00—18:00 禁止新模型和 Embedding 请求的规则，在请求边界等待。学习逐题更新 Q，保持单 worker；学习和评价合计不超过 4 个 worker。

当前配置见工作台自主队列，执行规则见探针接力清单 v09。

返回目录

十二、项目实验体系：为什么需要不同的对照

12.1 四类核心操作与实际入口

操作	回答的问题	入口	是否改变长期经验
完整 CLE 训练	整个经验增长与生命周期怎样运行	methods/sct_trajectory/run_closed_loop.py	是，按训练协议产生和管理经验
训练开发池审查或重评价	卡或库在开发题上怎样表现	主流程 Phase 3；独立开发比较可用 methods/cle_ablation/runner.py 等	正式门控可能改变状态；冻结开发对照不改变
独立冻结评价	已确定方法对评价数据怎样表现	run_plus_frozen_comparison.py、对应冻结实验入口	不允许从最终测试更新长期库
既有结果分析	已经发生了什么，差异在哪	报告脚本、原始 JSONL 与工作台	不生成新模型结果

同一个入口可以有不同模式；同一种操作也可能有独立编排脚本。实际启动参数与输出目录比页面按钮数量更能确定实验身份。

12.2 对照实验的基础语言

研究问题（希望用证据回答的具体问题）要先确定。自变量（主动改变的因素）可以是“是否使用 Q”；因变量（观察的结果）可以是 Joint；控制变量（保持不变的条件）包括题目、模型、经验正文和修复次数。

基线（用于比较的参考方法）不是一定最弱的方法，而是能解释改动作用的参照。消融（移除一个部件再比较）用于估计该部件是否有帮助。混杂因素（与目标改动一起变化、也能影响结果的因素）例如同时换更强模型，会使归因变难。

12.3 九条 baseline 是什么

四条 Prompt baseline（单次模型请求的提示对照）是 Greedy、Greedy+Secure、CoT 和 CoT+Secure。Greedy（直接按模型输出生成）与 CoT（Chain-of-Thought，要求逐步推理的提示方式）主要区别在输入要求。

五条 Agent baseline（带多个执行阶段的对照流程）是 AutoSafeCoder、RA-Gen、SWE-Agent、AgentCoder、SecAwareCoder。项目有对应适配实现；不能把适配叫原作者所有条件下的完全复现。

真实统一运行入口是 methods/workflow_baselines/run_true_agent_workflows.py。methods/prompting_baselines/run_prompt_baseline.py 是提示展示桩，不负责真实完整实验。

忠实性检查（fidelity，核对规定的关键阶段有没有实际执行）要与正确率一起看。历史曾有单提示适配器挂着多阶段 Agent 名称；这些记录不能用来声称五条原工作流的正式排名。

12.4 P0–P7 是怎样拆解 CLE 的

P7 是实验臂编号，不是第七阶段。下面是独立消融入口定义，表内“修订”仍需结合 PLT 与 Base/Plus 各自反馈协议解释：

臂	主要设置	意图
P0	直接提示，无经验	最简单参照
P1	明确功能与安全契约，无经验	检查约束表达的作用
P2	初析、规划、生成，无经验	检查多步骤流程
P3	P2 加一次修订	检查额外修改机会
P4	Phase 1 卡，检索、复析、规划、生成	检查初始经验配置
P5	最终冻结库，生成侧不复析，不注入负向护栏字段	部分移除经验适配与负向字段
P6	P5 加复析和拒绝卡隔离	检查复析/采纳的增量
P7	完整冻结前向链、完整卡字段	当前完整前向参照

P5 的语义检索仍可能做模型适用性筛选，不能叫“完全没有适用性判断”。只删 negative_guardrail 字段也不保证其他字段不含负向建议。P5–P7 共用已经门控的库，不能据此证明门控本身的作用。

P4 与 P7 的库既有轮次差异，也有状态和内容差异，不是只改变“卡片数量”。当前 Q 实验复用 P7 生成链，却使用固定 M0+Q，不意味着已经得到完整演进后的最终库。

12.5 RQ1–RQ4 与贡献候选

RQ，研究问题编号	关心什么	设计贡献候选	必须有什么证据
RQ1	完整 CLE 是否更好	有边界经验学习改善功能与安全联合结果	同题、同信息与明确预算的完整方法比较；独立评价
RQ2	哪些组件产生作用	正向原则、负向护栏、轨迹提炼、复析与程序采纳	部件真实被改变的消融，采用及落实证据

RQ，研究问题编号	关心什么	设计贡献候选	必须有什么证据
RQ3	经验生命周期是否有效	候选审查与回归约束减少有害经验	晋升和退役记录、增量与回归覆盖、独立迁移
RQ4	收益值不值得成本	以更少代价取得足够收益，或解释成本边界	调用、Token、时间、错误与收益共同报告

贡献候选（值得验证的研究主张）不是已被认可的原创贡献。外部记忆、检索、角色分工和反思已有相关研究。项目的差异需要落在具体机制和证据上，不能靠重新命名。

返回目录

十三、原手册收录的历史研究说明了什么？

本章保留原手册中的历史实验，其任务、模型和协议按当时版本解释。当前 v4.1 状态见第十一、十四和十七章。

本章数字取自仓库 2026-10-13 实验审计和相关报告，**本次未重新执行或全部重算历史原始记录**。较新的审计修正了早期过强表述；不把早期版本的好看数字直接写成当前性能。

13.1 历史主要发现

方向	已记录结果	当前可说的结论
层次与语义检索	273 题 Joint：76 与 71，p=0.487；语义组存在筛选失败	语义检索没有在该批证明准确率优势
筛卡协议可靠性修复	24 题两组均 7/24	可靠性改善不等于已提分
三候选分支	273 题任一候选成功上界：普通采样 87、不同计划 88；实际最终交付 67、61	生成更多候选不保证选对；上界不能当交付成绩
串行一次修复	273 题首次 71、最终 95	使用训练侧反馈有收益，但反馈与预算不同，不是纯架构比较
09-25 门控开发评价	298 题原库 67、过滤后 80；配对 p≈0.0146	同门控池选择并评分，存在选择偏差，不能直接当独立增益
对齐后的冻结评价	Base 5→6/115，Plus 40→41/140；Plus p=1	上述开发增益没有转化成明确冻结收益
接口保护加合格代码示例	新确认集从 17/50 到 22/50，救回 9、丢失 4，p=0.267	有方向性信号，但统计证据不足，且存在功能损害
提示矩阵中的 P13/P22	本地 Plus 从 28/140 到 43、42；多重比较后仍有信号	同时改变了经验呈现，不能全归因于某一句话，也不能推广到全部语言
10 月 16 日前 Q 探索	当时三臂 2/8、3/8、2/8，唯一多过题无卡介入	已实现并激活部分选择，未证明 Q 提分

p 值（在无差异假设和相应统计模型成立时，当前或更极端结果出现的概率）不是“方法无效的概率”。后面会说明怎样阅读。

13.2 哪些旧“成功”不能继续这样说

Oracle 上界（看过真实答案或最终成绩后，挑出最有利结果的理想诊断）不是可部署系统的实际选择。某历史 40 题实验直接提供当前题参考答案后分数大幅提高，只说明答案信息帮助很大，不能证明“经验粒度是唯一问题”。

有些历史消融标签不同，但实际启动参数相同。相同方法两次运行分数不同，不能拿来证明某个根本没被关闭的模块有效。

某冻结库有很多卡，但绝大多数是待验证状态，也不能写成“数千条知识都通过严格门控”。参考解全通过是在校准验证器，不是模型生成全通过。

13.3 可以如何陈述项目贡献

目前较稳妥的三层表述是：

1）**系统设计与工程实现**：建立围绕功能/安全双维度的生成、修复、轨迹提炼、经验管理与冻结消费链，并保存可定位的运行记录。

2）**实验方法与诊断认识**：通过组件比较、真实采用记录、同题配对和错误分类，发现候选选择、功能契约、奖励归因和评价条件的实际瓶颈。

3）**待证实的效果主张**：完整经验演进、严格门控、跨语言迁移或 Q 是否稳定提高独立正确率，仍需相应实验支持。

“做了系统”不自动等于“提出原创算法”；“做了很多实验”不自动等于“得到充分结论”。负结果（没有支持预期改善的实验结果）也有研究价值，但应清楚限定条件，说明它排除了什么简单解释。

13.4 仓库里的 M1–M6、A1–A7 另外在探索什么

这是历史候选筛选（先用开发实验挑选值得继续研究的思路）的一组编号，不是前面二十项职责模块，也不是 CLE 树配置中同名的 A1–A7。

编号	思路与简单解释	已有证据边界
M1	给文字经验配其他训练题的漏洞/修复代码与合法行为说明	有值得保留的信号；不能提供当前待测题答案
M2	根据历史效用决定是否用经验	早期校准没有正效用卡，最终空检索；不等于本次完整 Q 学习
M3	先写草稿，再检索经验进行修复	有局部开发分差，也有功能损害，未独立确认
M4	根据反例修改经验适用与排除条件	原型改动有限，未稳定超过未修订的 M1
M5	把经验变成可执行检查技能	使用覆盖低，当前没有净收益

编号	思路与简单解释	已有证据边界
M6	区分漏洞机制与语言/API 知识	Python 原型不能证明跨语言迁移，尚未验证
A1	分别让功能和安全角色审查	增加流程，当前未见可靠收益
A2	根据失败类型选择修复路线	开发未见净收益，且依赖训练侧反馈
A3	简化流程并明确接口清单	有保留价值，但简化与契约同时变化，不能全部归因于减少阶段
A4	调整不同审查角色的输出预算	预算变化也是因素，未独立确认
A5	根据公开检查决定是否继续修复	旧 60 题全部进入修复，没有形成有用提前停止
A6	生成两个候选再选择	候选中有正确答案不代表选择器能选中
A7	外层比较流程、内层调整记忆，再冻结确认	是筛选程序，不是一种固定生成方法；不等于任意自动架构搜索

CLE 自身的 A7 是 sct_trajectory/ablation.py 中的经验层次配置，当前方法选择它并关闭额外语言叶；上表 A7 则位于旁路研究。通用命令默认配置也未必是 A7，正式运行必须显式核对参数。这是同一个仓库反复使用编号造成的命名歧义，不是七个 Phase。

返回目录

十四、Q 究竟改变了什么，怎样判断它有没有用？

14.1 Q 是什么，怎样学习？

Q 记录一张经验卡过去被实际采用后，生成代码得到的反馈。当前固定 1939 张卡的正文，Q 和访问次数从零开始；先完成 D_init 的 303 题，再在 D_grow 的 273 题上做三轮，共 1122 次做题。这个固定卡库学习实验不产生新经验卡，也不改变大模型参数。

每次有合法反馈且卡片被实际采用时，更新公式为：

Q 新 = Q 旧 + 0.3 ×（奖励 − Q 旧）。

同一份代码同时通过功能和安全测试，奖励为+1；完整、合格的非 Joint 结果奖励为−1。技术错误、缺测或奖励资格不合格不授予反馈。被采用的卡共享该次代码结果，因而 Q 表示历史关联，不能直接证明每一张卡造成了成功或失败。

例如，从 0 开始连续两次成功，Q 依次变为 0.3、0.51；再失败一次，Q 变为 0.057。近期反馈会改变评分，但不会一次完全覆盖历史。visits 表示更新次数；Q 恰好为 0 与从未更新不是同一概念，覆盖率应按反馈记录或 visits 计算。

本轮 D_init303 题均具备奖励资格；活动 D_grow 学习输入中 232 题合格、41 题仍完整做题但不授予 Q 反馈。后续记忆标签实验使用另存的公开契约修订版，参考实现 273/273 通过，这不会追溯改变正在执行的学习资格。

14.2 Q 和相似度分别占多少？

候选卡先由检索获得，再按以下分数调整呈现顺序：

排序分 = 0.5 × 标准化语义相似度 + 0.5 × 标准化 Q。

标准化在本次候选组内进行，使两个数值可比较；组内没有差异时该项标准化值为 0。本轮阈值 δ 为−1，排序入口不截成数值前三张，随后仍由原 CLE 的 LLM 判断最终选哪些卡，最多三张。因此“各占 50%”是排序公式的权重，不是模型看 Q 和语义各花一半注意力，也不是一半概率按 Q 选卡。

一次完整流程是：公开题目→初析→检索候选→Q 参与候选排序→LLM 选择 0 至 3 张→复析与采纳→计划→代码→验证→必要时一次修复→对合法且实际采用的卡更新 Q。冻结评价使用已学 Q，但不再更新 Q 或卡片正文。

14.3 四臂各自回答什么？

条件	选择方式	用途
Q0	原 CLE 候选路径和 LLM 终选	对照原方法；原候选边界与其余臂的差异单列
Q1	相似度呈现，LLM 终选	判断 Q 是否胜过只用相似度
Q2	相似度与真实学习 Q 联合排序，LLM 终选	待检验方法
Q3	同 CWE 内打乱 Q 及 visits 配对后排序，LLM 终选	判断真实评分信息是否胜过仅扰动顺序

Q1、Q2、Q3 使用相同阈值和候选规则；Q3 固定置换种子 20261015。只比较 Q2 和 Q0 不足以排除候选边界变化，因而 Q2 对 Q1 和 Q3 是两个主要比较。

14.4 过去的探索已经说明什么？

证据	实际结果	对研究问题的判断
v3.2 早期固定库学习	297/1939 张卡有反馈，15.32%	反馈覆盖集中；这不是正分卡比例
后续放宽选卡和学习探索	Q 覆盖增加，但没有建立稳定 Joint 收益	增加覆盖不是收益证明
v4.1 选择重复实验	8 个题族、4 臂、5 重复，共 160 次选择	Q 改变了具体卡号，变化超过该实验中的重复波动
v4.1 旧冻结 Q 代码对照	Q0=11/48；Q1=13/48；Q2=11/48；Q3=13/48，其中 Q3 有 1 次缺测	学习 Q 没有超过两个主要对照；缺测不记作模型失败
v4.1 本轮重新学习	743/1939 张卡获得反馈，第三轮仍在运行	证明反馈范围扩大；收益由后续冻结比较回答

早期学习曾使用 δ=0.7613717780938312 等历史门槛和不同奖励资格，不能把那些参数当作当前运行参数。详细历史批次保留在 10 月 16 日原手册和本周实验报告。

14.5 为什么很多卡仍没有反馈？

一张卡必须依次经过“进入候选、被选中、被采用、获得合法结果”才能更新。没进入候选的卡不会因库中存在而被学习；相关性差或来源前提不符的卡即使进入候选也可能被拒绝；同 CWE 的不同题族不一定需要相同修法。当前代码结果又给多张卡共同记分，无法区分哪张卡真正有效。

因此需要同时看覆盖率、选卡编号、实际采用、代码落实和 Joint。若 Q 提高了某张卡的顺序并被采用，但代码仍覆盖外部配置、误搬来源假设或没有落实建议，瓶颈就在选卡之后。不能把“模型说采用了”直接写成“代码落实了”。

14.6 什么结果才支持 Q 收益？

冻结同题比较先排除学习继续变化的影响，再比较 Q2 与 Q1、Q3。两个主要比较按 Holm 方法校正；达到校正后 $p \le 0.05$、按题族计算的 95%差值区间下界大于 0、两次重复净收益均非负，才按预设规则支持稳定提升。未达到门槛时直接报告观察到的增益或损失，不宣布已经稳定提分。

技术探针只检验执行链路；当前 54 题回测用于观察轮次和局部信号。完整 D_gate 四臂仍在队列中暂缓，不会因探针运行成功自动启动。在线学习的成绩变化不能替代这个冻结比较。

返回目录

十五、科研基础：怎样自己判断一张实验表

15.1 先问“实验单位是什么”

样本单位（独立观察对应的对象）可能是任务、题族、任务×方法记录、代码尝试、模型请求或卡次。8 道题×3 组是 24 条记录，不是 24 道独立题。反复修复同题，也不等于增加独立样本。

配对比较（同一题在两个方法下逐题比较）应报告救回多少、损失多少，再看净差。只看 17→22 会漏掉“救回 9、损失 4”这一更具体的事实。

15.2 统计术语应该怎样理解

术语	简单概念	常见误读
效应量	改动实际带来多大差异	只报显著或不显著，不报改善多少
p 值	在指定无差异假设下看到当前或更极端结果的概率	把它当成方法无效的概率
置信区间	按同一方法长期重复抽样时，有规定比例的区间覆盖真实差异	把很宽区间中的一个正点估计当确定收益
多重比较校正	同时试很多方案时，控制偶然出现好结果的风险	只挑几十组中最好的一组报告
等效性	差异小到落入事前规定的可接受范围	把“未显著”当“已证明一样”
选择偏差	因选择题目或方法的方式而使结果倾向某方向	在同一批题上选最好方案又声称独立提升

术语	简单概念	常见误读
敏感性分析	改变明确的统计口径，看结论依赖什么	事后删坏题，只留下最好看的分母
可复现性	别人能找到输入、规则、代码版本和结果并核对	只有一个汇总百分比或网页截图

统计证据与机制证据相互补充。分数高但没有经过目标机制，不能直接归因；机制激活但总分不高，也不能硬说有效。

15.3 四种不同的可信度问题

内部有效性（差异是否由声称的改动造成）：是不是同时换了模型和提示？

测量有效性（所测数字是否对应真正的问题）：安全全过是不是因为所有请求都拒绝？

外部有效性（结论能否推广到其他条件）：Python 的 8 题结果能不能代表其他语言？

统计结论有效性（数据量和分析方法能否支撑结论）：样本是否独立，比较是否太多，缺测如何处理？

这四个问题就是读论文和做组会汇报时的基本检查，而不是额外的术语负担。

返回目录

十六、参与项目：一次实验从想法到归档

16.1 先判断改动要求重做哪一层

想改什么	最小必要操作	不能直接复用什么结论
报告图表或统计解释	读旧记录、离线重算	不得把重算当新模型实验
冻结库的排序公式	在固定卡库上重新生成配对评价；若公式不需新学习，可复用既有 Q	旧生成代码不能代表新排序的真实输出
复析或生成提示	所有相关臂共同固定新版本并重评	不能与不同提示版本混作单因素比较
Q 奖励定义	若所需证据已完整保存，可重算学习值，再重做生成对照	单纯重排不能给出新正确率
卡片结构、提炼方法	重生成对应经验，并重新审查与评价	旧卡成绩不能直接验证新卡内容
门控或生命周期	重做受影响的经验审查及冻结后评价	开发池筛选成绩不替代独立收益
更换生成或向量模型	固定新模型重新校准相关条件并做同题对照	旧模型阈值、用量和效果不自动适用

想改什么	最小必要操作	不能直接复用什么结论
翻译数据或验证器	先确认契约与参考，再统一重新测量受影响结果	不能只重评有利方法

这里“重新训练”主要指重新生成/管理外部经验，未必是模型参数训练。

16.2 正确的操作顺序

1）写一句研究问题：只问一个主要机制，说明哪些保持不变。

2）固定任务清单、数据用途、模型、生成预算、评价规则和输出目录。预算（允许花费的请求、Token 或时间上限）属于实验设计的一部分。

3）检查公开契约、参考实现、实际运行环境与必要凭据来源；只记录凭据来源标签，不复制内容。

4）做冒烟测试（用极少任务确认链路能跑通），再进行已批准规模的实验。一次通过只证明该测试链路通过，不证明方法有效。

5）保留所有已落盘结果，包括失败、缺测和成本。输入变化时建立新运行身份，不混进旧目录。

6）汇总主结果，再逐题检查机制路径。完成报告、精简摘要和原始文件定位。

本手册不附一个“全部启动”按钮式命令，因为完整训练、Q 学习、冻结评价和旧历史入口需要不同配置，成本和反馈边界也不同。各实际入口已在前文定位；配置应来自对应实验说明，而不是使用碰巧可运行的默认值。

16.3 目录和文件怎么读

JSON（键值式结构化文本）适合配置和汇总；JSONL（每行一条 JSON）适合逐题流式保存；CSV（行列表格文本）适合表格软件；Markdown（带轻量排版标记的文本）适合报告。

完整 CLE 典型文件	含义
run_metadata.json	模型、参数、数据和版本信息
pools.json	本次三池实际任务名单
phase1_results.jsonl	来源经验及其生成验证记录
trajectories.jsonl、rounds.jsonl	逐任务执行与外层轮次
experience_pool.jsonl	实际经验池
error_ledger.jsonl	错题本
gate_records.jsonl、audit_detail.jsonl	候选检查与实际审查对象
frozen/m_star.jsonl	冻结快照；还须配合配置解释可用集合
final_eval.jsonl、final_eval_summary.json	收尾评价明细与摘要，需检查是不是独立评价
cost.json、status.json	用量成本和运行状态

Q 独立实验通常使用 rows.jsonl、summary.json、memory_q_events.jsonl 和共享初析文件，不强行改造成完整 Phase 格式。摘要描述现象，原始逐题记录负责证明现象。

Git（代码版本管理工具）主要保存源码、配置和小型精简结果。提交号（某次保存代码状态的标识）如果不包含未提交工作区改动，就不足以代表实验全部源码，所以还要看当次源码快照。

当前本地分支为 fjy/cle-contract-conditional-q-20261023。实验源码、输入和结果以当次保存快照为准；当前工作区存在未提交改动，本次手册更新不提交或推送代码。

返回目录

十七、九条思路分别怎样推进，现在先做什么？

当前安排围绕同一个目标展开：先确认经验是否被正确检索、选择和落实，再判断其是否提高同一份代码的功能与安全表现。当前执行以探针接力清单 v09 为准；早先 v08 中的全量安排保留为后续研究设计，不再表示自动启动授权。

研究问题	当前证据或状态	下一项允许执行的工作
Q 能否改善选择和 Joint？	已改变选卡，稳定提分未建立；本轮 967/1122	完成本轮学习，分析与回放后做 54 题五条件两重复，共 540 次
多轮学习是否更有用？	K1 与 K2 已完成，K3 运行	同 54 题比较各冻结轮次；不用在线成绩差替代配对效果
功能安全分开能否少误伤？	小样本拆分未改善；全量 2104/2980 运行	完成五条件对照，分析 Joint 和功能安全四象限
哪些错误由契约、来源假设或实现造成？	已有逐题代码复盘	复用差异题；必要时最多 6 题、12 次本地单点验证，无实验模型请求
不同题适合多具体的经验？	五档标签未开始	先 82 题×5 档×2 次，共 820 次；必要时按原条件追加 82 题
分类器能否选对记忆程度？	旧分类器 21/48，固定提醒 22/48	新真实标签训练完成后，先 6 题×3 策略×2 次，共 36 次
检索是否找到适用经验？	池内标注与人工确认尚未完成	先 57 题；按覆盖和区间门槛决定是否追加 57 题，输出人审材料
v4.1 自己积累的卡是否更适合 v4.1？	新库尚未建成	先 2 道初始化题验证新库流程；完整建库暂缓
模型与卡库是否存在交叉适配？	v3.2 停用；v4.1 新库尚缺	完整新库就绪后 12 题×3 条件×2 次；精确复用 48 次，最多新生成 24 次

17.1 哪些全量现在不会自动启动？

已启动的 Q 学习 1122 次和功能安全 2980 次继续执行。未启动的冻结回测剩余 876 次、D_gate 四臂 2384 次中的非探针部分、分类器审计 1788 次中的非探针部分、完整新库、全量卡库交叉及外部验证均先跳过。Q 审计前置技术探针为 2 题×4 臂×2 次，共 16 次；它只验证接线。

“跳过”表示保留任务并继续寻找其他已就绪探针，不表示删除任务，也不表示放弃真实前置条件。例如，两题建库探针不能冒充完整新库供应卡库交叉实验；没有真实完整标签和训练结果，分类器探针也不能借用旧分类器冒充新方案。

17.2 什么时候扩大，什么时候收口？

1）记忆标签先检查是否至少覆盖 30 个训练题族、至少两个有效档位且每档至少 5 个题族，并满足登记的其余训练条件。不满足时最多追加 82 题；到 164 题仍无法形成可用标签则结束本轮分类器分支。

2）检索 57 题检查主要 CWE 覆盖、至少 20 题含适用卡，以及池内召回率区间半宽不超过 0.10。不足时最多追加 57 题。人工未确认前输出 AI 估计与复核材料，不宣布正式人工指标或全库召回率。

3）功能安全拆分以 Joint 为主要比较；Joint 提高且安全不下降，支持在保持安全下改善功能。功能提高而安全下降表示权衡，不能写成整体改善。

4）Q 和分类器完整比较使用预设配对统计门槛；至少 2 个百分点的稳定收益用于优先投入，较小但通过门槛的收益如实称为小幅提升。

5）效率结论要求 Joint 差值区间下界高于−1 个百分点，且可完整核算的 Token 减少至少 20%；未知用量不能逆转这个判断。

小样本扩大条件只决定已登记的小批追加，**不解除当前排队全量暂缓规则**。探针全部完成后应先交付机制判断、成本和建议，再决定哪些全量值得执行。

17.3 当前有哪些真实依赖？

v3.2 已不可用，原计划的新 v3.2 交叉臂结束，既有结果继续作为历史证据。Base115 题和 Plus140 题需要原验证镜像；镜像未到位，不用替代验证器。新 v4.1 卡库及相关交叉臂等待真实建库。人审材料可自动整理，人工确认不能由程序代签。

部分新增探针节点已进入自主队列，但仍要完成独立限量入口和离线验证后才能派发；队列里出现任务名不代表模型实验已经运行。当前工作台调度验证与科学结果分开记录。

返回目录

十八、组会怎样用一分钟讲清项目？

本课题研究外部经验如何改善安全代码生成。CLE 把做题反馈变成经验卡，再检索、选择和使用这些经验；评价要求同一份代码同时通过功能与安全测试，这就是 Joint。Q 根据被采用卡的历史反馈更新评分，当前参与候选排序，最终仍由模型选择最多三张卡。

已有结果确认 Q 改变了实际选卡，但旧 Q 迁移到 v4.1 没有提高 Joint；功能安全拆分和记忆程度分类器的小样本结果也未胜过各自对照。当前正在完成重新学习 Q 和功能安全完整对照，后续改为探针优先，避免尚未确认机制就启动所有全量。分析重点是区分题面契约、经验来源假设和代码实现问题，再决定哪些方案值得扩大。

18.1 阅读实验结果前检查什么？

1）这是在线学习、冻结评价，还是技术探针？它们回答不同问题。

2）分母是独立题目、同题重复还是已测代码？缺测不能记成模型失败。

3）对照是否使用相同题面、模型、候选、尝试预算和验证器？P3 不能代替 P7 空卡。

4）卡片有没有真正进入代码？选中、口头采用和实际落实分开检查。

5）新结果改变了哪条主线判断？已经完成、正在运行、等待依赖和暂缓全量分别标明。

返回组会速读 · 返回目录

返回目录

证据与进一步阅读

- 本次 19:40 运行快照：当前完成量、成绩、Q 覆盖与用量。
- 当前执行清单 v09：探针规模、全量暂缓和接续规则。
- 全量探索执行记录：协议、故障恢复、回放和分析入口。
- 九条研究叙事：每条研究问题到实验安排的逻辑。
- 10 月 22 日至 28 日实验报告：已完成基础实验和逐题分析。
- Q 更新与排序代码：更新公式、标准化和排序实现。
- 10 月 16 日原手册：首次接触项目时的完整历史说明。