10 月 22 日-10 月 28 日实验探索报告

一、本周实验主线

本周研究经验如何帮助代码同时满足功能与安全要求：先确认旧经验和 Q 评分在新模型上是否有用，再检验追加反馈、经验表达和自动选档，最后比较新旧卡库。检索测量负责查明适用经验在哪里遗漏，代码复盘负责解释选到经验以后为何仍然出错。已启动全量继续，其他思路先做探针和分析，排队全量暂缓。

本报告为周三收尾版，采用 10 月 28 日 23:01 保存的结果。之后新增实质结果作为本周期增补。**确定的进展是 Q 反馈覆盖持续提高；确定的旧实验结论是改选并未带来正确率提升，分栏表达和旧分类器也未胜过其对照。** 本轮学习完成 1092/1122 次，功能安全对照完成 2315/2980 次；已完成结果、正在运行结果和待做方案分别列出。

Joint 指同一份代码同时通过功能和安全测试，F、S 分别表示功能、安全通过。初始化集 303 题建立学习起点，增长集 273 题用于追加反馈，审计集 298 题检验使用效果。CWE 是漏洞类型，family 是同来源或相近结构的题族。两次重复是独立运行，不是两道新题。P3 无经验流程与 P7 空卡对照分别统计。

（1）旧 Q 能否改善新模型的代码？

旧 Q 改变了实际卡号，但代码对照中学习 Q 与原 CLE 同为 11/48，相似度为 13/48。这次实验没有显示学习 Q 的正确率收益。 【A2】

证据对应：选卡变化及代码对照，见【A2】。

（2）追加学习是否形成了更多有效经验？

初始化和前两轮增长学习已经完成，获得反馈的卡依次为 445、610、702 张。第三轮已完成 243 题，覆盖达到 762/1939。覆盖提高已经发生；是否变成更多正确代码，由固定同题回测回答。 【A9】

证据对应：各轮覆盖、在线成绩及实际代码复盘，见【A9】。

（3）Q 收益能否迁移到同漏洞类型的不同题族？

旧结果不能代替本轮新 Q 迁移检验。本轮先完成学习与同题回测，先做 2 题四组两重复的技术探针；298 题四组两重复暂缓，单独分析事先固定的同 CWE、不同反馈题族集合。 【A11】

证据对应：本轮比较范围和执行依赖，见【A11】。

（4）分开功能与安全经验是否更好？

小对照分栏 9/24，原卡 13/24，未改善。全量对照现完成 2315/2980 次；原卡阶段读数 198/462，分栏 194/464。当前各条件已测集合不同，最终按全部同题配对结果判定。 【A3】

证据对应：已完成小对照；全量阶段读数另见【A10】，见【A3】。

（5）自动选择记忆程度值得继续吗？

既有分类器 21/48，固定提醒 22/48，分类器没有胜出。新安排先用 82 题判断能否学到稳定的档位选择，再决定追加一批或进入 6 题策略探针。 【A5】

证据对应：已完成分类器与固定策略比较，见【A5】。

（6）检索遗漏发生在找卡还是选卡？

历史 AI 标签不能替代本轮人工确认。新安排先做 57 题共同候选池，分开计算候选漏失和最终选卡漏失；只对本批候选池作出判断。 【A8】

证据对应：历史测量范围和四指标定义，见【A8】。

（7）新模型自己的卡库是否优于旧库？

旧卡迁移共同可测 23 次，两组各通过 7 次，没有表现出优势。接下来比较 v4.1 的无卡、旧库、新库；v3.2 已停用，其新交叉臂结束。单模型结果不用于声称两模型的交互作用。 【A1】

证据对应：已完成迁移对照及后续建库问题，见【A1】。

（8）如何用更少成本得到有用结论？

保留已启动全量，其余先接探针；排队全量先跳过；技术检查计入正式名单，已返回结果按精确条件复用。新的安排已经进入工作台执行队列。 【A11】

证据对应：规模、扩大条件和实际接线，见【A11】。

（9）具体代码改动真的造成了退步吗？

现有代码复盘已区分题目要求缺项、来源假设带入和实现错误。下一步从功能安全差异题中选最多 6 题，预先写出单处修改的预测，再作最多 12 次本地验证，检验局部原因。 【A9】

证据对应：已完成案例证据；新局部复验见【T5】，见【A9】。

二、本周待做实验

下列安排承接本周已完成结果。正在运行的学习和功能安全全量保持原规则；尚未开始的批次采用新规模。所有技术检查都计入正式名单，重复运行相互独立。工作台按真实前置接续探针和分析；排队全量暂缓，不能因探针通过自动启动。

【T1】共同协议和执行接续如何落实？

实验原因：让计划中的条件、名单和实际执行一致。

1）保留活动学习、功能安全输入及已保存响应。

2）后续评价统一使用修订后的 298 题公开契约；原验证器参考预检 298/298 通过，该数字不是模型成绩。

3）每包完成后回放、统计、实际阅读差异代码，再更新叙事和图，满足交付条件后接续。

预测结果分析：探针接力规则 v09 已安装；40 项离线调度验证通过。成功标准是原生结果、回放和案例分析均有实际产物；入口准备完成不算实验完成。

返回本周主线

【T2】检索标签怎样经过人工确认？

实验原因：把模型估计变成可解释的适用性判断。

1）用 2 题统一“直接适用、附加条件、冲突、不适用”的定义。

2）人工裁决本批共同候选池中的标签，不只复核被选中的卡。

3）汇总池内精确率、召回率等四指标，保留争议和裁决记录。

预测结果分析：人工确认后才给正式池内指标；只有 AI 初标时交付估计和复核材料。该结果不等于 1939 张全库召回率。

返回本周主线

【T3】外部数据集还需什么环境？

实验原因：使用独立外部任务检验卡库效果。

1）补齐原 safecoder-python-validator:local 镜像及原正向校准。

2）新库与原环境就绪后先登记各集 2 题的有界检查；1530 次全量保持暂缓。

3）每集前 2 题计入正式名单，常驻 Docker 和原 watchdog 执行，隐藏测试不回传。

预测结果分析：环境未就绪就保持未执行。两集分别判断新库相对旧库和无卡的收益。原 P3 外部 255 次暂缓，不随镜像到位自动恢复。

返回本周主线

【T4】怎样判断追加 Q 反馈和迁移是否有效？

实验原因：把“覆盖增多”与“正确代码增多”分开验证。

1）完成 K3，冻结 Q，做原生回放与实际案例分析。

2）同 54 题比较 K0、K1、K2、K3 及相似度，两重复；五条件合计 540 次；原 1416 次中的其余 876 次暂缓。

3）完成前置分析后先 2 题四组两重复，共 16 次技术探针；2384 次计划中的其余部分暂缓，异反馈题族子集事先固定。

预测结果分析：同 54 题比较回答追加学习效果，全 273 题最终比较仍待后续启动决定。新 Q 相对相似度和打乱 Q 的两项主要比较经 Holm 校正 $p \le 0.05$、题族 95%差值区间下界>0，且两重复净收益均非负，才称本轮稳定收益；未过门则写本轮未建立稳定收益。达到 2 个百分点优先继续投入，正收益不足 2 个百分点记小幅收益。

返回本周主线

【T5】分栏失败能否定位到具体改动？

实验原因：既检验分栏总体效果，也检验具体退步原因。

1）完成 298 题五条件两重复的 2980 次对照，回放并比较分栏与原卡。

2）阅读救回、损失题的题面、来源卡、计划、代码及原验证证据。

3）选最多 6 道不同题，预先记录一处改动及预测，用独立副本完成最多 12 次本地原验证，不调用实验 API。

预测结果分析：Joint 增加且安全总通过数不降，支持本批兼顾；功能上升而安全下降说明取舍；Joint 无净增则本次未改善。原失败复现且单处修改恢复目标测试才支持该处局部原因，未恢复则单因预测未成立；不得把少数案例比例推广到所有失败。

返回本周主线

【T6】82 题能否训练出有价值的选档器？

实验原因：先验证训练机会，再支付全量策略比较费用。

1）先 82 题五档两重复，共 820 次；L0 无卡，L1 一句提醒，L2 机制前提，L3 加目标模板，L4 加来源示例。

2）按既定可训练门判断：至少 30 个训练题族、至少两档各有 5 个训练题族等条件；必要时只追加 82 题，最多 164 题。

3）满足门槛后用既有 8 特征、逻辑回归和三种参数，按题族留出题的实际 Joint 选模，再先做 6 题三策略两重复，共 36 次；1788 个策略结果的其余部分暂缓。

预测结果分析：最多 164 题仍不满足可训练门，结束分类器支线。稳定胜过固定档和规则才支持提分；Joint 差值 95%下界>−1 个百分点且完整流程已知 Token 减少≥20%、未知用量不足以推翻比较，才支持保质省 Token。两门均未过就结束本轮，不增加分类器复杂度。

返回本周主线

【T7】57 题能否找到检索的主要漏失？

实验原因：以较少标注定位检索瓶颈。

1）固定增长集 27 题、审计集 30 题；各取 1 题检查后接续，共 57 题。

2）三种查询使用共同池：每查询向量 Top24 与词面 Top8 联集，加固定随机 16；同题同卡去重，每对 AI 初标一次。

3）主要 CWE 未覆盖、含正类的有效题不足 20，或召回区间半宽>0.10 时，追加固定 57 题，最多 114 题，再交付人工复核。

预测结果分析：查询差值在人工确认池内成立才支持本批查询改进；无差异保留低成本原查询。缺向量不记空返回，不为拼接采用链追加代码生成，不扩大为全库标注。

返回本周主线

【T8】新模型建立的新库比旧库好吗？

实验原因：把模型本身和经验来源的作用分开。

1）从空库先做 2 道初始化题验证建库流程；完整初始化、三轮主动回放和全局门控暂缓，两题产物不冒充完整库。

2）真实完整新库到位后，先 12 题三条件两重复，共 72 次；48 次精确核准复用，新生成最多 24 次，全 298 题暂缓。

3）新库生成、冻结回放和分析完成后才做三库对照，再按 T3 进入外部集。

预测结果分析：新库稳定胜过旧库与无卡才确认该集额外收益；审计集参与建库门控，跨集推广由 Base/Plus 回答。v3.2 后续臂因模型停用结束，不替换模型，也不把单模型三库称为两模型交互。

返回本周主线

三、实验内容与结果分析

【A1】无经验基线和旧卡迁移说明了什么？

为什么做这项实验

本实验回答两个问题：换成 v4.1 后，不看经验的模型能做对多少题；同一 P7 流程加入旧 1939 卡库后，成绩是否改变。P3 是无经验基线，P7 是另一套包含经验处理的生成流程，两者不能直接相减当作记忆收益。返回要求七

怎样做

1）使用 deepseek-v4.1-flash-1017，保持原 P3 初析、规划、生成和最多一次修订，在 PLT 的 298 道 D_gate 题运行；不输入、不生成经验，不更新 Q。

2）保留原 43 题结果，修复实际 TLS 传输问题后续跑 247 题，再按原实验规则补跑剩余 8 题；保留失败请求和未知用量，最终 298 题保存代码均零 API 回放。

3）另外固定 12 题、每题两次重复，在 P7 中比较空卡与旧 1939 卡库；每个题次共享首次初析，最多三卡、最多一次修复，不学习 Q。

4）对 48 个 P7 单元逐一回放；将技术缺测与模型答错分开，比较完整配对成绩，而不是把单次多通过一题直接归为经验作用。

看到了什么

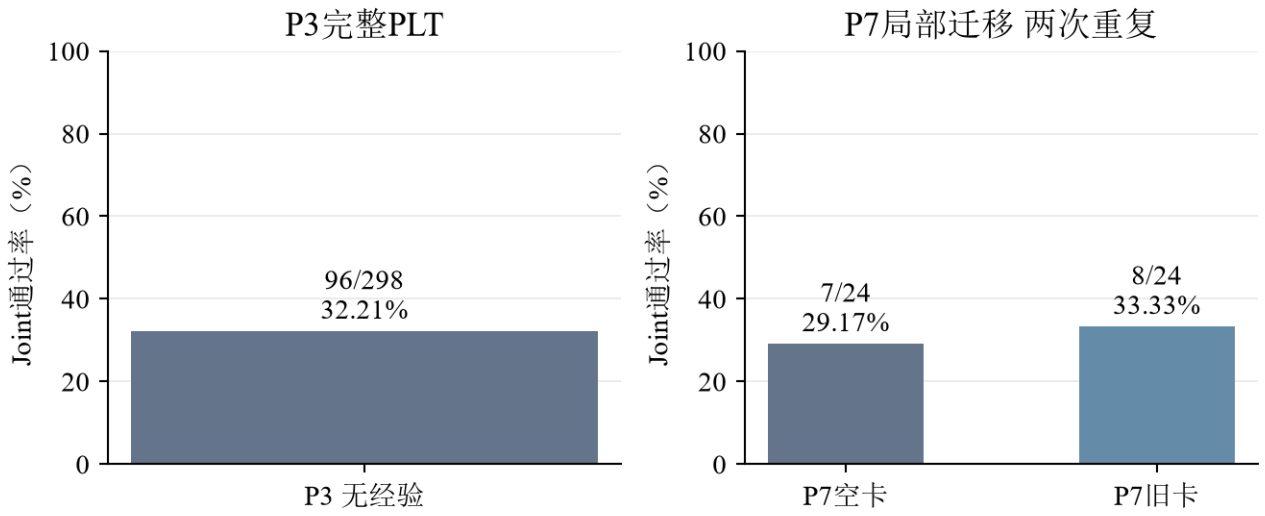


图 1 本周两个起步实验分别统计；P3 与 P7 不是同一流程

实验与条件	执行 / 计划	F 通过	S 通过	Joint 通过
P3 无经验	298 / 298	111 / 298	232 / 298	96 / 298
P7 空卡	24 / 24	7 / 24	18 / 24	7 / 24
P7 1939 卡	24 / 24	8 / 24	20 / 24	8 / 24

P3 完整测量 297 题，最终 Joint 为 32.21%；P7 空卡完整测量 23 个单元，带卡 24 个，双方均完整的 23 对中 Joint 均为 7 / 23。P3 已知 Token 为 3,841,636，30 次物理请求用量未知；P7 合计 2,063,129 Token（其中 Embedding 46,461），另 15 次请求尝试用量未知。两个来源的请求计数口径不同，费用均不写成实付账单，也不与【A8】累计数直接相加。

这些结果说明什么

图 1 左侧给出新模型在无经验完整任务集上的基线；右侧只说明这 12 题两重复的旧卡迁移表现。P7 原始总分带卡多 1 个通过，但唯一差异涉及空卡生成截断；排除不完整配对后双方相同。因此，这一轮建立了可复用的换模起点，尚未证明旧卡能够稳定提分。后续采用同 P7、同名单的 v4.1 三库对照；v3.2 停用后的新增交叉臂已经结束。后续【A2】至【A7】是在此后开展的机制比较，不把这些局部单元追加到 P3 的 298 题分母。

原始证据：10 月 25 日 P3 全量报告、10 月 25 日 P7 迁移报告。原始完成时间分别见各报告；本节属于 10 月 22 日至 28 日这一周。

返回要求七　返回本周实验主线　返回实验导航

【A2】Q 改变选卡后，代码是否更正确？

为什么做这项实验

本实验分两步：先通过重复选卡，判断 Q 有没有改变最终选中的卡，并与模型自身波动比较；再看改变选卡后，功能和安全是否一起通过。Q0 至 Q3 在下表中说明，最终仍由模型选择，不是直接取 Q 最高的三张。返回要求一

选卡方式	给模型的提示顺序是什么
Q0 原 CLE	按原有候选方式呈现，再由模型选择经验
Q1 相似度	优先呈现与当前题目语义相近的卡，再由模型选择
Q2 学习 Q	排序时加入经验卡的历史反馈分数，再由模型选择
Q3 打乱 Q	在同类漏洞中打乱卡与分数的对应关系，再由模型选择

Q0 的候选边界与其他组可能不同；与 Q0 比较时，不能把所有差异都归因于 Q 排序。

怎样做

1）固定 1939 张经验正文和历史 Q 快照。972 张卡的 visits 大于 0，即曾获得反馈，覆盖率为 50.13%；Q 恰好为 0 但有反馈的卡也计入。这个快照包含 v3.2 的部分在线学习状态，不是 v4.1 重新学习的 Q。

2）对 8 个题族的相同查询、候选和余弦相似度，分别运行四种排序，每种重复 5 次，共 160 次选卡。使用排序混合参数 $\lambda=0.5$、相似度阈值 $\delta=-1$ 和置换种子 20261015；这是本轮探索设置，不能写成所有历史 CLE 实验的默认参数。

3）在 24 个预留题族上，每个条件重复 2 次，共 192 个代码单元。首次初析和候选共享，模型最多选三张；后续修复依各组代码独立进行，Q 和经验始终冻结。

4）按相同题目及重复编号配对，比较卡号集合、新增卡采用、F/S/Joint 与救回损失。统计以题族为单位处理相关性，保留缺测及历史技术失败记录。

看到了什么

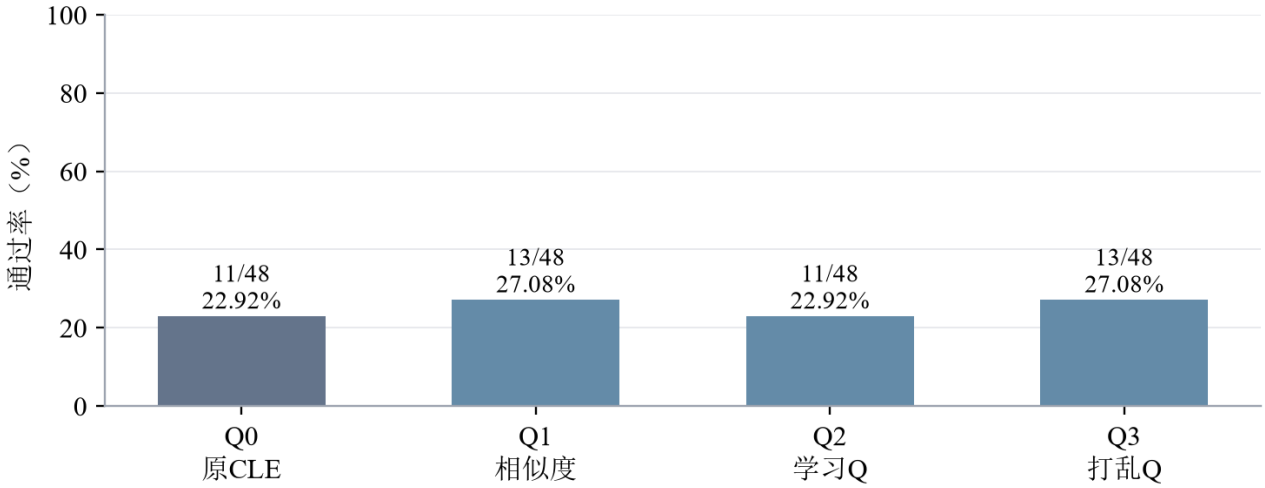


图 2 四种选卡条件的 Joint 通过率，分母各为 48 个代码单元

条件	F 通过数	S 通过数	Joint 通过数	完整测量
Q0 原 CLE	19/48	33/48	11/48	48/48
Q1 相似度	19/48	35/48	13/48	48/48
Q2 学习 Q	18/48	33/48	11/48	48/48
Q3 打乱 Q	20/48	32/48	13/48	47/48

重复选卡的 160 次有效记录显示，Q2 相对 Q0、Q1、Q3 的卡号集合差异超过组内波动，Holm 校正（同时比较多组时减少误判的方法）后的 p 值分别为 0.006、0.0072 和 0.00015。代码实验中，Q2 对 Q0 的首次选卡集合变化 46/48 次，新增卡声明采用 32/48 次。Q2 选中卡片的位置中 134/139 有过 Q 反馈，首次声明采用的位置中 97/97 有过反馈；这些是卡片位置数，不是独立题数。

这些结果说明什么

图 2 中，学习 Q 组与原 CLE 组同为 22.92%，比相似度和打乱 Q 各低 4.17 个百分点。逐题配对后，Q2 相对 Q1 没有救回、损失 2 次；相对 Q3 救回 1 次、损失 3 次；相对 Q0 救回和损失各 2 次。Q2 与 Q1、Q3 的两项成绩比较校正后 p 值均为 1，现有数据未支持学习 Q 提高 Joint。Q3 有一格缺测，不能将这一格解释成模型已被测出失败。

这个结果不能再主要解释为“没有接触到有 Q 的卡”，因为实际选中与声明采用的卡片大多已有反馈。具体失败仍发生在后面的落实环节：1209 采用了算术相关建议，但生成代码错误访问 AST 节点的 left/right 属性；1065 采用了跳过无效字段的建议，却仍然抛出异常；901 还存在公开题面未确定阈值的问题。因此，Q 的选卡作用已有直接证据，旧 Q 迁移适配、卡片适用性和代码实现能力则尚未被独立区分。下一步应完成新模型自己的分轮 Q 学习及 54 题冻结探针；排队全量暂缓，不能凭本轮负结果宣布 Q 普遍无效。

对应原实验：D03a、D03b。数据来源：四臂统计和逐包汇总、选卡波动分析、代码与卡片复核。

返回要求一　返回要求二　返回本周实验主线

【A3】拆分或编辑经验能否兼顾功能与安全？

为什么做这项实验

功能经验帮助代码完成任务，安全经验帮助代码避免风险。本实验使用同一来源卡，比较混合与分栏展示；另从同一段已有代码出发比较有无经验的单次编辑，以减少起始代码不同的影响。分栏展示不等于建立了两套独立卡库。返回要求三

条件	实际给模型的经验内容
B0 无记忆	不提供经验卡
BM 原混合卡	采用原卡中混合的功能与安全建议
BF 功能视图	只呈现整理出的功能相关建议
BS 安全视图	只呈现整理出的安全相关建议
BFS 分区组合	分栏呈现功能和安全建议

怎样做

1）固定 12 个题族、每题 2 次重复和五种条件，共 120 个代码单元：无记忆 B0、原混合卡 BM、仅功能视图 BF、仅安全视图 BS、功能与安全分区组合 BFS。

2）共享首次初析及选卡。分区只读取来源卡正文，不查看目标题答案；分别记录 AI 分区和规则补全，生成模型接收相同公开任务，按原 P7 完成生成和最多一次修复。

3）汇总各条件 F、S 与 Joint，将 BFS 和 BM 按同题配对，查明损失是否来自实际采用的建议或额外改写。

4）补充编辑实验固定 6 个题族、2 次重复，以同一段 BM 首轮代码作为起点，只比较输入经验与不输入经验的单次编辑，共 24 个单元；它不是另一轮完整 P7 成绩。

看到了什么

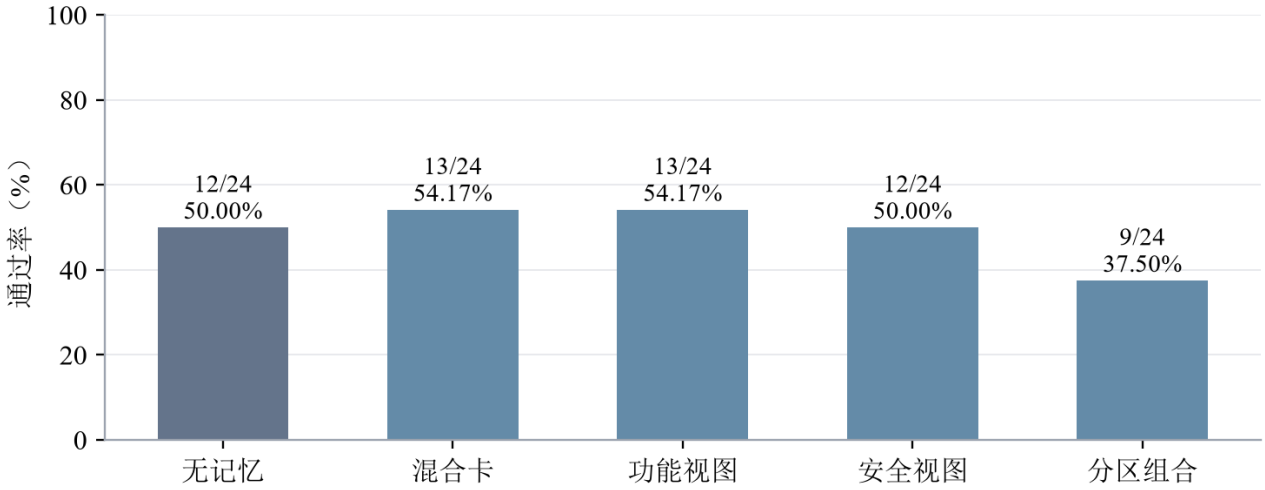


图 3 五种经验表达条件的 Joint 通过率，各为 12 题族两重复

条件	F 通过数	S 通过数	Joint 通过数
无记忆 B0	12/24	19/24	12/24
原混合卡 BM	14/24	19/24	13/24
功能视图 BF	15/24	19/24	13/24
安全视图 BS	13/24	18/24	12/24
分区组合 BFS	12/24	18/24	9/24

五组均完成完整测量。BFS 相对 BM 救回 0 次、损失 4 次。补充编辑中，无卡与带卡均为 F 7/12、S 9/12、Joint 6/12，救回和损失均为 0；带卡条件实际有 9/12 次输入经验，其余起点没有可用的采用卡列表。

这些结果说明什么

图 3 显示，分区组合的 Joint 为 37.50%，低于原混合卡的 54.17%。仅功能视图的功能通过数增加 1 次，但 Joint 没有增加，这说明改善功能的题目与安全通过的题目不一定重合。研究目标要求同一份代码同时满足两方面，因而不能用 F 单独增加替代 Joint 改善。

1326 的分区组合代码改写了白名单，破坏原有功能，但没有声明采用相关卡片。这说明“看到了不同的经验文本”和“明确使用某张卡导致错误”仍需区分。另一组编辑没有改变结果，也只说明这 6 个题族的单步编辑未产生收益；编辑输出格式不包含采用声明，不能把汇总中的采用数 0 解释为没有记忆输入。当前证据不支持直接推广这一拆分方式，后续全量实验应保留功能保持、来源假设迁移和实际代码改动三类分析，检验功能损失具体发生在哪里。

对应原实验：B02、B05。数据来源：逐包汇总、实际案例复核。

返回要求三　返回本周实验主线

【A4】经验越详细，代码就越好吗？

为什么做这项实验

要训练分类器，先要看同一道题在不同经验详细程度下是否真的有差别。如果大多数题各档表现相同，就缺少选择档位的学习信号。五档从不提供经验，到提供风险提醒、原理、任务模板或来源示例。返回要求四

档位	模型能看到什么
L0 无记忆	不提供经验
L1 风险提醒	一句话指出需要注意的风险
L2 机制前提	解释安全机制及适用条件
L3 操作模板	提供面向当前任务的操作模板
L4 来源示例	提供来源任务中的完整示例

怎样做

1）固定 48 个 D_grow 题族，每题五档、每档两次重复，共 480 个单元；事先分为 36 个训练题族和 12 个开发题族。D_grow 是用于积累经验和反馈的任务池，不是最终独立测试集。

2）从相同来源材料形成不同档位，排除同题族来源。15 张缺少来源代码的卡在所有档位共同排除，避免只有 L4 可用卡范围不同。

3）各档按原 P7 预算生成和验证，记录真实采用、交付成绩和输入 Token。按题族查看两次重复是否支持同一档位，而不根据一次偶然成功指定标签。

4）先报告五档完整结果，再将训练题族中具有可靠成功证据的记录交给【A5】；开发题族结果用于检验，不回填训练标签。

看到了什么

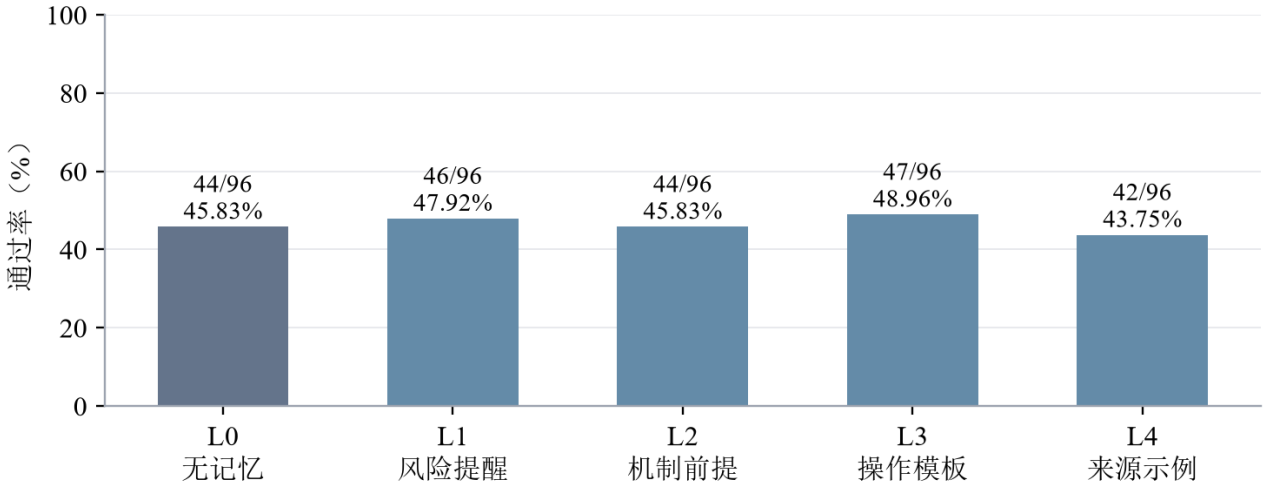


图 4 五档记忆的 Joint 通过率，分母各为 96 个代码单元

档位	F 通过数	S 通过数	Joint 通过数	完整测量
L0 无记忆	53/96	71/96	44/96	95/96
L1 风险提醒	53/96	74/96	46/96	96/96
L2 机制前提	53/96	74/96	44/96	96/96
L3 操作模板	54/96	75/96	47/96	96/96
L4 来源示例	49/96	71/96	42/96	96/96

L3 相对 L0 救回 6 次、损失 3 次，净增加 3 次；题族重采样 95%区间为−3.125 至+10.417 个百分点，配对检验 p=0.5625。48 个题族中 31 个在五档下成功的重复次数相同，其中 17 个全部失败、13 个全部成功，另 1 个各档均一次成功；只有 2 个题族存在某档两次成功、另一档两次失败的稳定强差别，均在训练部分。

这些结果说明什么

图 4 没有呈现记忆越详细、Joint 越高的趋势。L3 比无记忆高 3.125 个百分点，L4 低 2.083 个百分点；结合具体案例，一种可能解释是完整示例带入来源任务的假设，而操作模板与目标任务更容易衔接，但总分本身不能证明这一机制。不过区间跨过 0，当前不能确认 L3 总体更好，更不能仅凭 L4 总分较低就认定每个完整示例有害。

从分类器角度看，31/48 个题族没有可见的档位差别，意味着大量结果无法告诉模型“该选哪一档”。全部失败的题目也不能自动标成 L0 最优，因为它们没有证明无记忆更合适。逐题检查还发现 1005 在 L4 下成功却没有采用声明，1059 有来源四字段白名单与目标三字段要求的差别。这些现象要求后续标签同时考虑真实使用与可重复成绩，以免分类器学到生成波动或来源不匹配。

对应原实验：C02。数据来源：五档结果、案例复核。

返回要求四　返回本周实验主线

【A5】自动选择记忆档位胜过固定提醒了吗？

为什么做这项实验

分类器根据公开题目特征预测应该使用哪一档经验。本实验用【A4】的真实成绩训练，再与固定一档和公开规则比较；目标题的正确答案不能用于选择档位。只有最终代码成绩改善，才能说明选档对任务有帮助。返回要求四

选择方式	如何决定使用哪一档经验
分类器	根据公开题目特征预测
固定 L1	所有题都使用一句风险提醒
公开规则	根据预先写好的公开规则选择

怎样做

1）仅使用 36 个训练题族制作标签。某档两次 Joint 都通过时，按预定规则选平均输入 Token 最少的合格档；全失败或缺少有效记忆介入的情况标为未解决，不强行指定最佳档位。

2）最终得到 19 个有效题族标签：11 个 L0、7 个 L1、1 个 L3；另外 17 个保留未解决。提取公开题面长度、参数、绑定关系和副作用等特征，用逻辑回归训练，并仅在训练部分用三折划分选择设置。

3）在 12 个开发题族查看三种策略，各为两次重复；随后固定分类器及策略，在 24 个保留题族上比较，每种策略两重复，共 144 个逻辑单元。

4）对预测到同一档且协议完全一致的 12 个单元精确复用已有输出。按同题配对比较 Joint，保留实际采用数和缺测，不因某策略较差重新训练或换题。

看到了什么

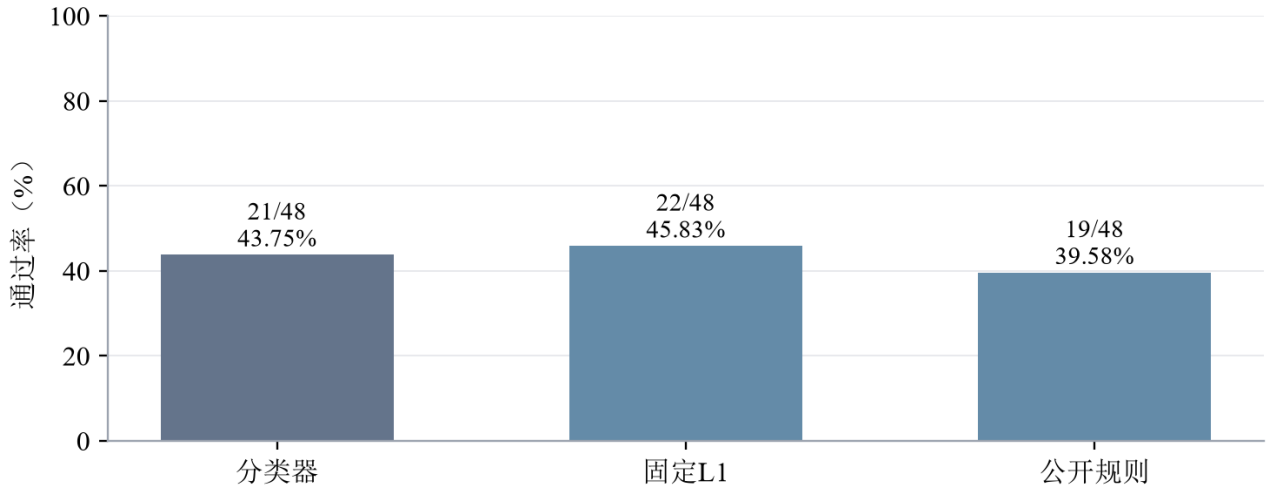


图 5 三种记忆选择策略在保留题上的 Joint 通过率

策略	F 通过数	S 通过数	Joint 通过数	完整测量

策略	F 通过数	S 通过数	Joint 通过数	完整测量
分类器	24/48	37/48	21/48	48/48
固定 L1	25/48	38/48	22/48	48/48
公开规则	25/48	34/48	19/48	47/48

开发部分三种策略均为 Joint 7/24。保留题中，分类器相对固定 L1 救回 1 次、损失 2 次；相对公开规则救回 3 次、损失 1 次，两项比较 Holm 校正后 p 均为 1。分类器条件有 12/48 次声明采用，固定 L1 有 45/48 次；不同策略可能主动选择 L0，因此采用率应结合预测档位解释。

这些结果说明什么

图 5 显示，分类器没有超过最简单的固定 L1 策略。它比公开规则高 2 次，却比固定 L1 少 1 次，不能据此证明学习型选择优于固定提醒。分类器大多学习到 L0 或 L1，而训练样本只有一个 L3、没有可靠的 L2 或 L4 标签，当前数据不足以训练出覆盖五档的清晰决策。

这项实验已经落实了“用真实结果训练分类器”的方法步骤，但尚未实现“分类器能帮助提高成绩”的研究目标。现有标签数量少且档位分布不均，是需要优先检查的可能原因；仅凭这次对照还不能排除分类特征或模型选择等其他原因。后续先执行 82 题标签批，按可训练门决定是否追加 82 题，保留未解决标签，并在独立题族上验证；不能把同题五档中的最高分直接当作推理时可获得的信息。

对应原实验：C03/C04a、C04b。数据来源：分类器结果汇总、完整分析来源。

返回要求四　返回本周实验主线

【A6】公开约束提醒能解决哪些实现问题？

为什么做这项实验

公开契约是题目已经说明的接口、对象和行为要求。本实验分别检查关系提醒、生成模板和公开检查能否帮助模型遵守要求。三项对照改变的内容和样本不同，结果需要分别解释。返回要求三

怎样做

1）关系提醒 B03R 固定 1 个题族、2 次重复，比较无卡/带卡与绑定提醒/关系提醒的四种组合，共 8 个单元。初析、候选和生成前计划共享，只在预定生成阶段改变提醒；本周精确复用已完成记录。

2）模板实验固定 12 个题族、2 次重复，比较登记的 P00、P13、P22 三种生成模板，共 72 个单元；共享首轮复析和规划，到生成阶段才分叉。

3）公开检查 D02 固定 48 个题族、2 次重复，比较原 P7 与 PUBLIC 流程，共 192 个单元。PUBLIC 按预定协议使用公开检查和反馈决定修复与交付，隐藏测试不回传给模型；这一对照改变的是完整代码使用流程，不只是一句提示。

4）分别统计各实验内部的成绩和配对变化，读取公开检查失败案例。已保存响应用于零 API 回放，回放发现的临时目录差异经修复后复核，不额外生成代码。

看到了什么

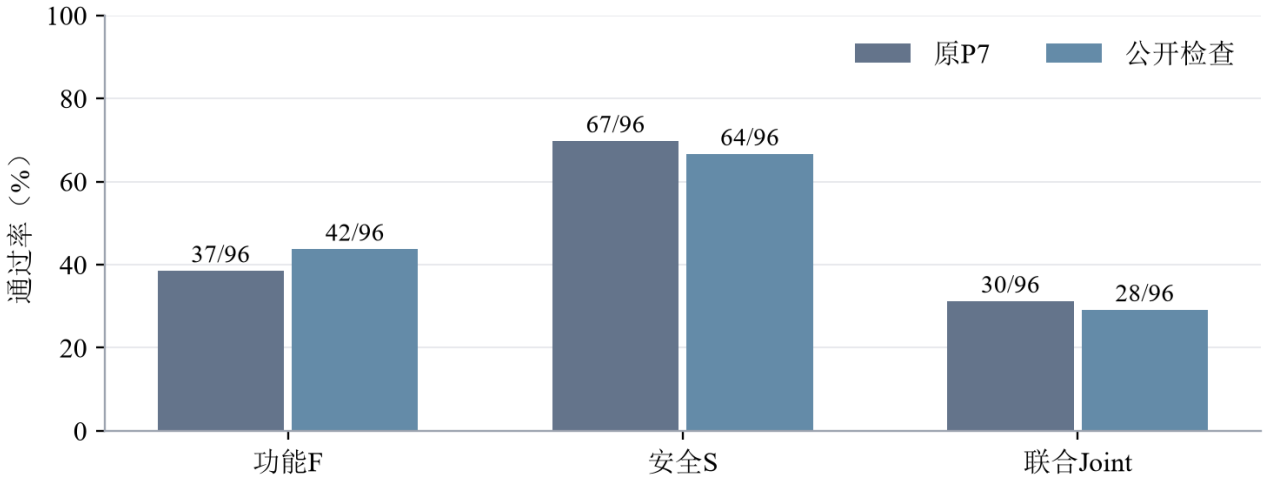


图 6 公开检查流程与原 P7 的功能、安全及联合通过率

实验与条件	Joint 通过数	补充结果
关系提醒四种组合	各 2/2	8/8 完整测量，无成绩区分空间
P00 / P13 / P22 模板	10/24、10/24、11/24	每组 24/24 完整测量
原 P7	30/96	F 37/96；S 67/96；完整测量 95/96
PUBLIC 公开检查	28/96	F 42/96；S 64/96；完整测量 96/96

PUBLIC 相对原 P7 救回 4 次、损失 6 次，Joint 净减少 2 次。D02 全部 192 个单元的零 API 回放最终与原成绩一致；为修复回放临时目录问题完成 21 项相关离线检查，旧差异现场保留。

这些结果说明什么

图 6 中，公开检查使 F 从 37 次增加到 42 次，但 S 从 67 次降至 64 次，Joint 也由 30 次降至 28 次。这说明“更多公开检查”未必等于更正确的交付，检查本身若理解错公开要求，也会把正确代码改坏。1001 的公开自检在内容已转义的情况下仍拒绝包含 onerror 的文本，继而促使代码破坏安全输出，是具体可核对的例子。

关系提醒的四种组合全部通过，只能说明接线按预定变量运行，无法证明提醒在总体上有效。模板 P22 仅多一次通过，也不足以承担整体提分结论。对主线而言，公开契约缺失、模型没有遵守契约、检查器错误扩大契约是三种不同问题；后续应把它们作为完整功能保持实验的解释层，避免把所有功能失败都归到经验卡或 Q 上。

对应原实验：B03R、S2_P13_P22、D02。数据来源：逐包统计、实际案例复核。

返回要求三　返回实验导航

【A7】来源经验的正向结果通过保留题确认了吗？

为什么做这项实验

本实验在同一 A7 代码生成与修复流程中，比较不提供经验和提供 M1 专门来源经验。M1_SOURCE36 与旧 1939 卡库不同；两组均最多一次公开证据修复。结果用于判断这套来源经验方案，不能单独归为 Q 或原 P7 的收益。返回要求三　返回要求七

怎样做

1）在 12 个开发题族上，分别使用无经验与 M1 来源经验，每题 2 次重复，共 48 个单元。来源经验排除同题族材料，固定公开题面、模型和 A7 修复预算。

2）按确认前登记的开发增量规则选出 M1，固定其配置，再在 24 个保留题族上运行两条件、两重复，共 96 个单元；不根据中途成绩调整方案。

3）记录每次实际注入的经验，验证同一交付代码的 F/S/Joint，并将两组按题目和重复配对，核对救回、损失以及建议是否落实。

4）同时报告按题族重采样区间和原协议精确检验，披露保留题此前在 D02 中的暴露；该组称方案保留确认，不称整个 CLE 从未见过的最终测试。

看到了什么

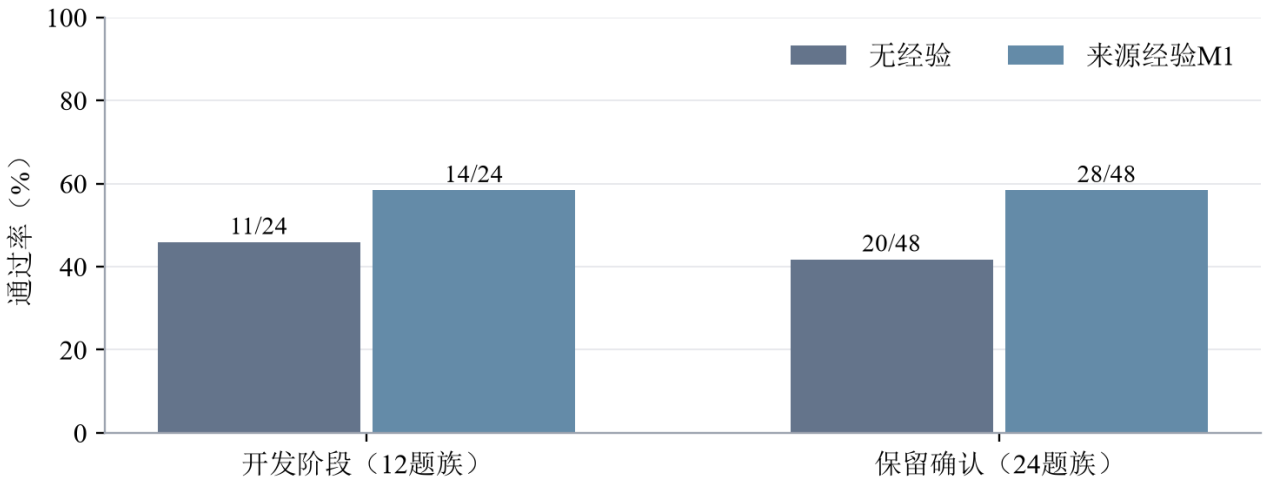


图 7 来源经验在开发和保留题上的 Joint 通过率，两部分样本分别统计

阶段与条件	F 通过数	S 通过数	Joint 通过数
开发：无经验	11/24	20/24	11/24
开发：M1	14/24	21/24	14/24
保留：无经验	27/48	37/48	20/48
保留：M1	33/48	39/48	28/48

两部分均完成完整测量。开发阶段 M1 实际注入 17/24 次，救回 5 次、损失 2 次；保留阶段实际注入 37/48 次，救回 9 次、损失 1 次，Joint 净增加 8 次，即 16.67 个百分点。保留阶段 95%题族重采样区间为+2.083 至+33.333 个百分点，题族区组精确双侧检验 p=0.078125；M1 两次重复间没有题族 Joint 分歧，无经验组有 4 个。

这些结果说明什么

图 7 显示，M1 在开发和保留题上均高于无经验，保留部分同时改善 F、S 和 Joint，是本轮最值得继续完整验证的正向结果。1001 中可以追踪到来源经验建议使用 html.escape，建议进入输入后在代码中落实，并对应最终救回；唯一损失案例 338 则涉及公开题面要求字符串、夹具使用字节串的冲突，不能不加区分地记为经验质量问题。

但两个统计方法给出的判断并不完全相同：重采样区间为正，原协议精确检验未达到 0.05。报告保留两者，不只挑有利的一项。因此当前结论是有方向性信号，尚未完成统计确认。后续比较须固定 A7 流程、来源资格与名单；当前先按 v09 做探针，排队全量暂缓；如果要解释成模型与卡库的交叉作用，还需单独固定使用模型、来源库及预算，完成真正的交叉矩阵。由于 v3.2 已经停用，新安排只执行 v4.1 三库比较，结论限于该模型。

对应原实验：S2_M1、S4。数据来源：开发及保留题统计、完整统计与案例分析。

返回要求三　返回要求七　返回本周实验主线

【A8】哪些结果已经完成，成本和检索测量还缺什么？

为什么做这项实验

本节核对基础清单完成了多少、费用记录覆盖什么，以及检索、Q 学习和建库还缺什么证据。它是零 API 资料复核，不产生新的代码成绩。完成数、检索质量和代码正确率需要分别判断。返回要求五

怎样做

1）按执行索引读取各包计划、完成数和原生结果，区分代码单元、仅选卡单元、共享前序输出及同档精确复用，不合并成独立题目总数。

2）检查 11 个代码包的既有零 API 回放结果，并读取 12 个代表案例的题面、卡片、计划、代码和验证记录。案例用于说明具体路径，不用于估计全体失败原因的比例。

3）汇总已报告 Token、物理 HTTP（实际发出的网络请求）、未知用量和在途请求。沿用原账本的来源范围，失败未知用量不记为免费，不假设缓存命中率。

4）查验 Q 更新、经验生成以及人工检索标签状态。没有执行或缺少必要标签的项目记为尚未验证，不能填入 0 分或从历史摘要反造记录。

看到了什么

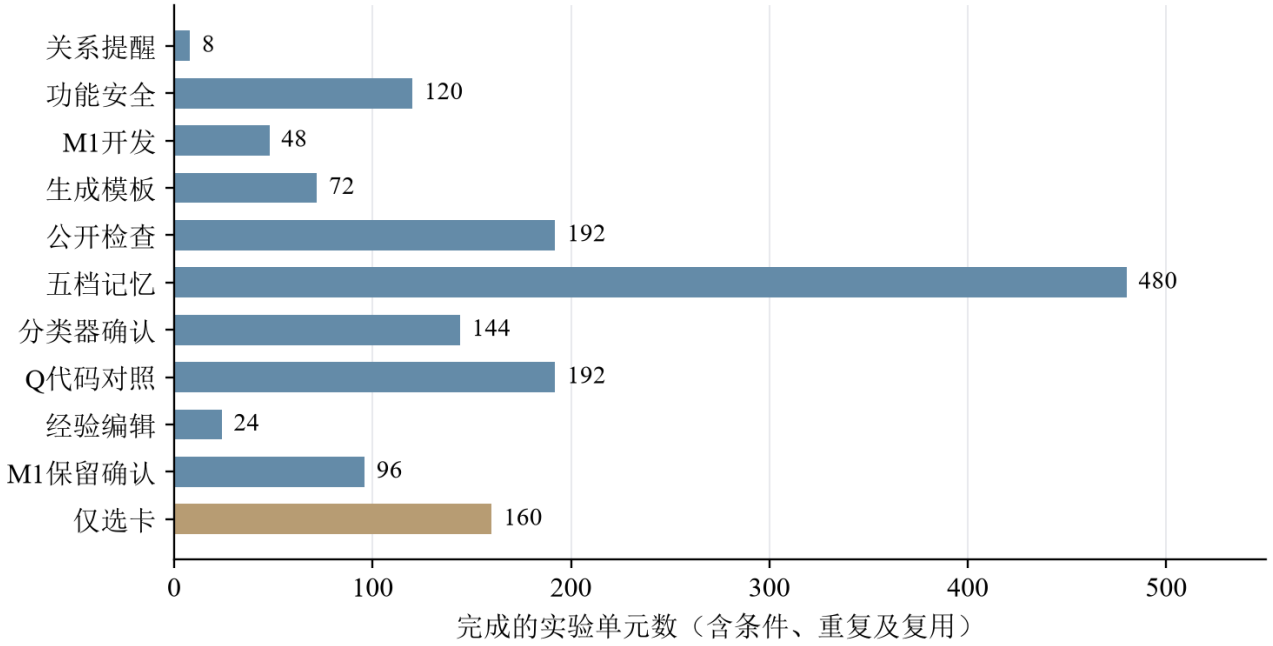


图 8 已完成基础清单的规模，代码单元与仅选卡单元分开显示

核对项	当前记录	能说明什么
代码实验单元	1376/1376	固定清单完成，含复用及重复
仅选卡单元	160/160	只检验选卡，不产生代码成绩
零 API 代码包回放	11 包一致	已存响应可重走对应流程
实际代码案例复核	12 例	提供具体原因证据，不代表总体比例
基础清单 Q 更新 / 新经验生成	0 / 0	10 月 26 日基础清单未进行新模型学习与建库
已报告 Token	65,186,659	累计账本用量，不是本周新增实付
物理 HTTP	10,338	包含记入来源的实际请求与重试
已结束未知用量 HTTP / 在途	302 / 0	未知部分不能记为零费用

这份累计记录包含本轮各包及列入恢复来源的请求，不能等同于整台电脑全部历史用量或本周新支出。当前没有足够账单依据给出人民币实付。关系提醒 8 格和分类器同档 12 格等复用均保留在各自逻辑分母中，不应为凑“新实验数”再次调用模型。

这些结果说明什么

图 8 和表格支持“基础清单完整完成”，并不支持“已做完全量新模型验证”。10 月 26 日基础清单没有完成 v4.1 的新 Q 学习、全 298 题 Q 四臂、从空库建立新经验、两个模型交叉使用两库，以及原验证

镜像下的 Base/Plus 评价。10 月 27 日新 Q 学习已开始，但尚未完成，最新前缀见【A9】。旧 P3、旧 Q 等结果只有在题面、模型、流程、反馈和预算匹配后才能作为新对照，否则只能保留为背景。

检索方面，准确率衡量题卡对的选入与未选入判断是否正确；精确率衡量选出的卡有多少适用；召回率衡量适用卡有多少被选出；F1 综合精确率和召回率。目前缺少人工确认的适用性标签，不能形成正式四指标。即使完成共同候选池标注，也只能先报告“候选池内召回率”；整库适用卡未被完整标注时，全库召回率仍未测量。这是测量缺口，不是已经证明检索差，也不能用 Q 覆盖率代替它。

数据来源：清单与成本汇总、零 API 回放、七项要求与全量任务。

返回要求二　返回要求五　返回要求六　返回要求七

【A9】反馈覆盖增加后，在线正确率怎样变化？

结果：前三个阶段完成，第三轮增长学习完成 243 题。反馈覆盖从 445 张升至 762 张，但在线 Joint 没有随覆盖单调上升。

为什么做这项实验？

旧 Q 在新模型上没有提分，需要让 v4.1 按自己的解题反馈重新学习。固定 1939 张卡正文，从 Q 和访问次数为零开始，保证观察到的是评分学习，不是换了一套卡。

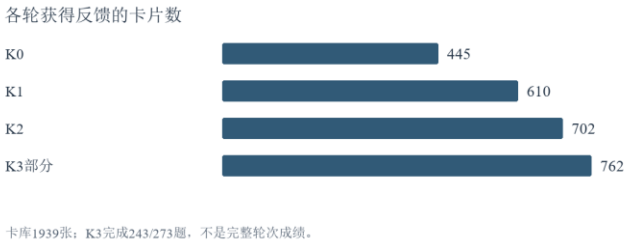
怎样做？

1）顺序完成 303 道初始化题，按实际采用且具备奖励资格的卡更新 Q，冻结为 K0。

2）在同 273 道增长题上继续三轮，分别冻结 K1、K2、K3；学习保持单 worker 逐题更新。

3）每轮完成后回放保存响应和原验证结果，分析反馈卡、题族和主要代码差异；冻结回测按【T4】另行执行。

学习阶段	已完成/计划	可测	首次 Joint	最终 Joint	已获反馈卡/1939
K0	303/303	301	143	148（49.17%）	445（22.95%）
K1	273/273	272	128	133（48.90%）	610（31.46%）
K2	273/273	273	123	124（45.42%）	702（36.20%）
K3	243/273	243	104	109（44.86%）	762（39.30%）



各阶段反馈覆盖

阶段	首次 F/S	最终 F/S	Q 记账次数	声明采用位置数
K0	159/244	163/247	837	878
K1	147/203	149/207	646	770
K2	145/204	146/206	611	748
K3 部分	124/179	125/182	662	835

这些结果说明什么？

K1 比 K0 新增 165 张反馈卡，K2 再新增 92 张，说明追加解题确实扩大了 Q 的反馈范围。K1 与 K2 使用同一增长题集，最终 Joint 分别为 133 和 124，在线读数下降；两轮生成不同、评分沿途变化，这个差值不能单独归因为 Q。54 题共同回测负责隔离轮次评分差异，全 273 题最终 Q 与相似度比较用于后续总体检验，目前暂缓。K3 只完成 243 题，不与完整 273 题均值拼成收益曲线。

当前学习仍使用冻结的原奖励资格：增长集 232 题允许 Q 反馈，41 题照常解题但不记奖励。新标签实验修订后的增长集契约没有追溯写入学习。声明采用只是模型输出记录，是否真正落实到代码还需阅读实现。

实际阅读的题目	代码与验证发现	对主线的判断
K2：1289、1298	类型或异常行为的公开要求与验收存在差异	负反馈含契约因素，不能全部解释为卡片不适用
K2：675、1301	生成代码覆盖外部配置；1301 另有 URL 夹具问题	需要区分实现错误与题目条件，选卡正确不保证实现正确
K2：108	IDNA 实现修订后通过，但该题不具备 Q 奖励资格	这次救回不是 Q 记账收益证据
K2：883、1139	采用记录缺失或自述采用与实现不一致	采用字段不足以证明代码落实

K0 已完成保存验证反馈的精确回放，303 行结果、Q 和卡库一致；另行重新执行代码时，1107 出现同代码结果变化，1111 出现提示分歧，不能把这部分写成动态重验全部一致。K1、K2 已完成各自原生回放和案例分析；K3 尚在运行。K0、K2 分别实际审查 12 题、9 题，以上为其中代表性证据，不作为全体原因比例。

返回追加学习要求　查看冻结回测安排

【A10】全量功能安全对照目前支持分栏表达吗？

阶段结果：已保存 2315/2980 次。原混合卡 198/462，分栏 194/464，当前没有显示分栏优于原卡。

为什么做这项实验？

小对照中分栏少通过 4 次。全量实验检验这一现象是否持续，并区分仅保留功能、仅保留安全以及两者分栏表达的作用。

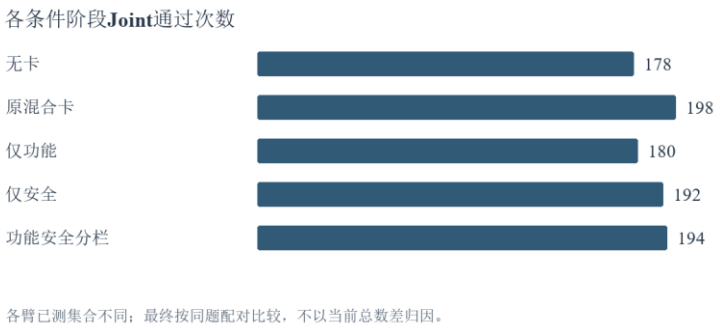
怎样做？

1）固定 298 道评价题，分别使用无卡、原混合卡、仅功能、仅安全、功能安全分栏五种条件，各独立运行两次。

2）四个带卡条件首次使用相同来源卡编号，再改变表达；各条件的修复过程独立，Q 和卡正文不更新。

3）完整后比较同题同重复的救回与损失、F/S 四象限、题族区间和代码落实，再执行【T5】的单处改动复验。

条件	已完成	可测	F 通过	S 通过	Joint
B0 无卡	462	461	208	349	178（38.61%）
BM 原混合卡	463	462	231	367	198（42.86%）
BF 仅功能	462	459	219	347	180（39.22%）
BS 仅安全	464	463	225	362	192（41.47%）
BFS 功能安全分栏	464	464	229	364	194（41.81%）



功能安全对照的阶段 Joint

这些结果说明什么？

原卡目前在五组中 Joint 最高，分栏未超过原卡。各条件的已完成题目集合不完全一致，表中相减不等于已完成的配对效应；正式主比较将在五组固定名单完成后计算。当前保留全部实验继续执行，

不按阶段排名挑选条件。功能、安全、Joint 分别报告，是为了判断分栏究竟恢复了功能、损失了安全，还是没有改变实现，而不是只看一个总分。

返回功能安全要求　查看差异原因复验

【A11】怎样用探针接力控制成本？

结论：已启动 Q 学习和功能安全全量继续；其他研究先做探针，排队全量先跳过。 v09 取代白天 v08 的自动接续方式，40 项调度离线验证通过。这是执行规则验证，不是科学收益结果。

为什么这样安排？

旧 Q、分栏和分类器小实验均未胜过对照。当前先用有限样本确认新机制和训练机会，把后续全量投入留给最有价值的问题；已经产生大量数据的两项全量保持规则完成。

怎样执行？

1）完成活动学习和功能安全，回放保存结果并阅读实际代码。

2）有真实前置且入口已验证的探针自动接续，普通负结果按既定固定样本收口；条件追加只执行登记的小批。

3）遇到排队全量先跳过，继续其他独立探针。跳过不解除真实完整卡库、分类器或原镜像依赖。

研究任务	本次自动范围	全量状态
Q 同题回测	54 题×5 条件×2＝540 次	其余 876 次暂缓
Q 审计	2 题×4 条件×2＝16 次技术探针	其余 2368 次暂缓
记忆标签	82 题×5 档×2＝820 次；条件满足才追加 82 题	不直接扩到 273 题
自动选档	真实新标签训练后 6 题×3 策略×2＝36 次	其余 1752 次暂缓
检索	57 题；条件满足才追加 57 题	不直接全 571 题
新库	2 道初始化题技术探针	完整建库暂缓
卡库交叉	真实完整新库到位后 12 题×3×2＝72 次	全 298 题暂缓
局部原因复验	最多 6 题、12 次本地验证	无实验模型请求

新增有界入口仍需离线验证后才能实际派发；队列名称不等于已做实验。截止时这些后续探针没有真实完成行。

已经投入多少？

本轮包或阶段	已报告 Token	物理 HTTP	未知用量或在途 HTTP
Q：K0	20,055,303	2,809	44

本轮包或阶段	已报告 Token	物理 HTTP	未知用量或在途 HTTP
Q：K1	18,378,470	2,530	28
Q：K2	18,639,471	2,616	79
Q：K3	16,325,744	2,373	81
功能安全	101,406,792	17,598	425
两包合计	174,805,780	27,926	657

本表为 23:01 累计物理账本，未知用量不计为零；基础实验 65,186,659 Token 在【A8】单列，Codex 分析用量另记。没有当前账单就不折算实付人民币。

对主线有什么影响？

覆盖增加证明反馈触达更多卡，不证明代码更正确。下一步 54 题配对回测先区分学习轮次的影响；功能安全完整对照回答经验拆分能否兼顾两个目标。82 题标签和 57 题检索负责判定是否存在可训练规律、遗漏发生在哪里，不替代完整迁移结论。

返回本周主线　返回待做安排　当前执行规则　本次保存快照