10 月 22 日-10 月 28 日实验探索报告

一、本周实验主线

本周研究经验如何帮助代码同时满足功能与安全要求：先确认旧经验和 Q 评分在新模型上是否有用，再检验追加反馈、经验表达和自动选档，最后比较新旧卡库。检索测量负责查明适用经验在哪里遗漏，代码复盘负责解释选到经验以后为何仍然出错。全量主比较保留，中间探索按信息价值减量。

本报告采用 10 月 28 日 18:10 保存的结果。**确定的进展是 Q 反馈覆盖持续提高；确定的旧实验结论是改选并未带来正确率提升，分栏表达和旧分类器也未胜过其对照。** 本轮学习完成 894/1122 次，功能安全对照完成 1952/2980 次；已完成结果、正在运行结果和待做方案分别列出。

Joint 指同一份代码同时通过功能和安全测试，F、S 分别表示功能、安全通过。初始化集 303 题建立学习起点，增长集 273 题用于追加反馈，审计集 298 题检验使用效果。CWE 是漏洞类型，family 是同来源或相近结构的题族。两次重复是独立运行，不是两道新题。P3 无经验流程与 P7 空卡对照分别统计。

（1）旧 Q 能否改善新模型的代码？

旧 Q 改变了实际卡号，但代码对照中学习 Q 与原 CLE 同为 11/48，相似度为 13/48。这次实验没有显示学习 Q 的正确率收益。 【A2】

证据对应：选卡变化及代码对照，见【A2】。

（2）追加学习是否形成了更多有效经验？

初始化和前两轮增长学习已经完成，获得反馈的卡依次为 445、610、702 张。第三轮已完成 45 题，覆盖达到 713/1939。覆盖提高已经发生；是否变成更多正确代码，由固定同题回测回答。 【A9】

证据对应：各轮覆盖、在线成绩及实际代码复盘，见【A9】。

（3）Q 收益能否迁移到同漏洞类型的不同题族？

旧结果不能代替本轮新 Q 迁移检验。本轮先完成学习与同题回测，再对 298 题做四组两重复，单独分析事先固定的同 CWE、不同反馈题族集合。 【A11】

证据对应：本轮比较范围和执行依赖，见【A11】。

（4）分开功能与安全经验是否更好？

小对照分栏 9/24，原卡 13/24，未改善。全量对照现完成 1952/2980 次；原卡阶段读数 173/390，分栏 169/390。当前读数不构成分栏收益，最终按全部同题配对结果判定。 【A3】

证据对应：已完成小对照；全量阶段读数另见【A10】，见【A3】。

（5）自动选择记忆程度值得继续吗？

既有分类器 21/48，固定提醒 22/48，分类器没有胜出。新安排先用 82 题判断能否学到稳定的档位选择，再决定追加一批或进入全量策略比较。 【A5】

证据对应：已完成分类器与固定策略比较，见【A5】。

（6）检索遗漏发生在找卡还是选卡？

历史 AI 标签不能替代本轮人工确认。新安排先做 57 题共同候选池，分开计算候选漏失和最终选卡漏失；只对本批候选池作出判断。 【A8】

证据对应：历史测量范围和四指标定义，见【A8】。

（7）新模型自己的卡库是否优于旧库？

旧卡迁移共同可测 23 次，两组各通过 7 次，没有表现出优势。接下来比较 v4.1 的无卡、旧库、新库；v3.2 已停用，其新交叉臂结束。单模型结果不用于声称两模型的交互作用。 【A1】

证据对应：已完成迁移对照及后续建库问题，见【A1】。

（8）如何用更少成本得到有用结论？

保留已启动全量和最终主要比较，缩小中间回测、标签和检索批次；技术检查计入正式名单，已返回结果按精确条件复用。新的安排已经进入工作台执行队列。 【A11】

证据对应：规模、扩大条件和实际接线，见【A11】。

（9）具体代码改动真的造成了退步吗？

现有代码复盘已区分题目要求缺项、来源假设带入和实现错误。下一步从功能安全差异题中选最多 6 题，预先写出单处修改的预测，再作最多 12 次本地验证，检验局部原因。 【A9】

证据对应：已完成案例证据；新局部复验见【T5】，见【A9】。

二、本周待做实验

下列安排承接本周已完成结果。正在运行的学习和功能安全全量保持原规则；尚未开始的批次采用新规模。所有技术检查都计入正式名单，重复运行相互独立。工作台按前置结果接续，不因普通负结果取消已保留的主比较。

【T1】共同协议和执行接续如何落实？

实验原因：让计划中的条件、名单和实际执行一致。

1. 保留活动学习、功能安全输入及已保存响应。
2. 后续评价统一使用修订后的 298 题公开契约；原验证器参考预检 298/298 通过，该数字不是模型成绩。
3. 每包完成后回放、统计、实际阅读差异代码，再更新叙事和图，满足交付条件后接续。

预测结果分析：41 个执行节点已经安装，61 项离线验证通过。成功标准是原生结果、回放和案例分析均有实际产物；入口准备完成不算实验完成。

返回本周主线

【T2】检索标签怎样经过人工确认？

实验原因：把模型估计变成可解释的适用性判断。

4. 用 2 题统一“直接适用、附加条件、冲突、不适用”的定义。
5. 人工裁决本批共同候选池中的标签，不只复核被选中的卡。
6. 汇总池内精确率、召回率等四指标，保留争议和裁决记录。

预测结果分析：人工确认后才给正式池内指标；只有 AI 初标时交付估计和复核材料。该结果不等于 1939 张全库召回率。

返回本周主线

【T3】外部数据集还需什么环境？

实验原因：使用独立外部任务检验卡库效果。

7. 补齐原 safecoder-python-validator:local 镜像及原正向校准。
8. 新库完成后，在 Base115 题和 Plus140 题分别做无卡、旧库、新库两重复，共 1530 次。
9. 每集前 2 题计入正式名单，常驻 Docker 和原 watchdog 执行，隐藏测试不回传。

预测结果分析：环境未就绪就保持未执行。两集分别判断新库相对旧库和无卡的收益。原 P3 外部 255 次暂缓，不随镜像到位自动恢复。

返回本周主线

【T4】怎样判断追加 Q 反馈和迁移是否有效？

实验原因：把“覆盖增多”与“正确代码增多”分开验证。

10. 完成 K3，冻结 Q，做原生回放与实际案例分析。
11. 同 54 题比较 K0、K1、K2、K3 及相似度，两重复；K3 和相似度另覆盖全部 273 题，合计 1416 次。
12. 完成分析后，298 题做原 CLE、相似度、学习 Q、同 CWE 打乱 Q 四组两重复，共 2384 次；先固定异反馈题族子集。

预测结果分析：同 54 题比较回答追加学习效果，全 273 题比较回答最终评分价值。新 Q 相对相似度和打乱 Q 的两项主要比较经 Holm 校正 $p \le 0.05$、题族 95%差值区间下界>0，且两重复净收益均非负，才称本轮稳定收益；未过门则写本轮未建立稳定收益。达到 2 个百分点优先继续投入，正收益不足 2 个百分点记小幅收益。

返回本周主线

【T5】分栏失败能否定位到具体改动？

实验原因：既检验分栏总体效果，也检验具体退步原因。

13. 完成 298 题五条件两重复的 2980 次对照，回放并比较分栏与原卡。

14. 阅读救回、损失题的题面、来源卡、计划、代码及原验证证据。

15. 选最多 6 道不同题，预先记录一处改动及预测，用独立副本完成最多 12 次本地原验证，不调用实验 API。

预测结果分析：Joint 增加且安全总通过数不降，支持本批兼顾；功能上升而安全下降说明取舍；Joint 无净增则本次未改善。原失败复现且单处修改恢复目标测试才支持该处局部原因，未恢复则单因预测未成立；不得把少数案例比例推广到所有失败。

返回本周主线

【T6】82 题能否训练出有价值的选档器？

实验原因：先验证训练机会，再支付全量策略比较费用。

16. 先 82 题五档两重复，共 820 次；L0 无卡，L1 一句提醒，L2 机制前提，L3 加目标模板，L4 加来源示例。

17. 按既定可训练门判断：至少 30 个训练题族、至少两档各有 5 个训练题族等条件；必要时只追加 82 题，最多 164 题。

18. 满足门槛后用既有 8 特征、逻辑回归和三种参数，按题族留出题的实际 Joint 选模，再进行 298 题三策略两重复，共 1788 个策略结果。

预测结果分析：最多 164 题仍不满足可训练门，结束分类器支线。稳定胜过固定档和规则才支持提分；Joint 差值 95%下界>−1 个百分点且完整流程已知 Token 减少≥20%、未知用量不足以推翻比较，才支持保质省 Token。两门均未过就结束本轮，不增加分类器复杂度。

返回本周主线

【T7】57 题能否找到检索的主要漏失？

实验原因：以较少标注定位检索瓶颈。

19. 固定增长集 27 题、审计集 30 题；各取 1 题检查后接续，共 57 题。

20. 三种查询使用共同池：每查询向量 Top24 与词面 Top8 联集，加固定随机 16；同题同卡去重，每对 AI 初标一次。

21. 主要 CWE 未覆盖、含正类的有效题不足 20，或召回区间半宽>0.10 时，追加固定 57 题，最多 114 题，再交付人工复核。

预测结果分析：查询差值在人工确认池内成立才支持本批查询改进；无差异保留低成本原查询。缺向量不记空返回，不为拼接采用链追加代码生成，不扩大为全库标注。

返回本周主线

【T8】新模型建立的新库比旧库好吗？

实验原因：把模型本身和经验来源的作用分开。

22. 从空库按原 CLE 初始化、三轮主动回放、改卡和全局门控建立新库；不是机械重跑三遍 273 题。

23. 在 298 题上比较 v4.1 无卡、旧库、新库，两重复共 1788 个结果；1192 个无卡和旧库结果逐格核准复用，新生成最多 596 次。

24. 新库生成、冻结回放和分析完成后才做三库对照，再按 T3 进入外部集。

预测结果分析：新库稳定胜过旧库与无卡才确认该集额外收益；审计集参与建库门控，跨集推广由 Base/Plus 回答。v3.2 后续臂因模型停用结束，不替换模型，也不把单模型三库称为两模型交互。

返回本周主线

三、实验内容与结果分析

【A1】无经验基线和旧卡迁移说明了什么？

为什么做这项实验

本实验回答两个问题：换成 v4.1 后，不看经验的模型能做对多少题；同一 P7 流程加入旧 1939 卡库后，成绩是否改变。P3 是无经验基线，P7 是另一套包含经验处理的生成流程，两者不能直接相减当作记忆收益。返回要求七

怎样做

25. 使用 deepseek-v4.1-flash-1017，保持原 P3 初析、规划、生成和最多一次修订，在 PLT 的 298 道 D_gate 题运行；不输入、不生成经验，不更新 Q。

26. 保留原 43 题结果，修复实际 TLS 传输问题后续跑 247 题，再按原实验规则补跑剩余 8 题；保留失败请求和未知用量，最终 298 题保存代码均零 API 回放。

27. 另外固定 12 题、每题两次重复，在 P7 中比较空卡与旧 1939 卡库；每个题次共享首次初析，最多三卡、最多一次修复，不学习 Q。

28. 对 48 个 P7 单元逐一回放；将技术缺测与模型答错分开，比较完整配对成绩，而不是把单次多通过一题直接归为经验作用。

看到了什么

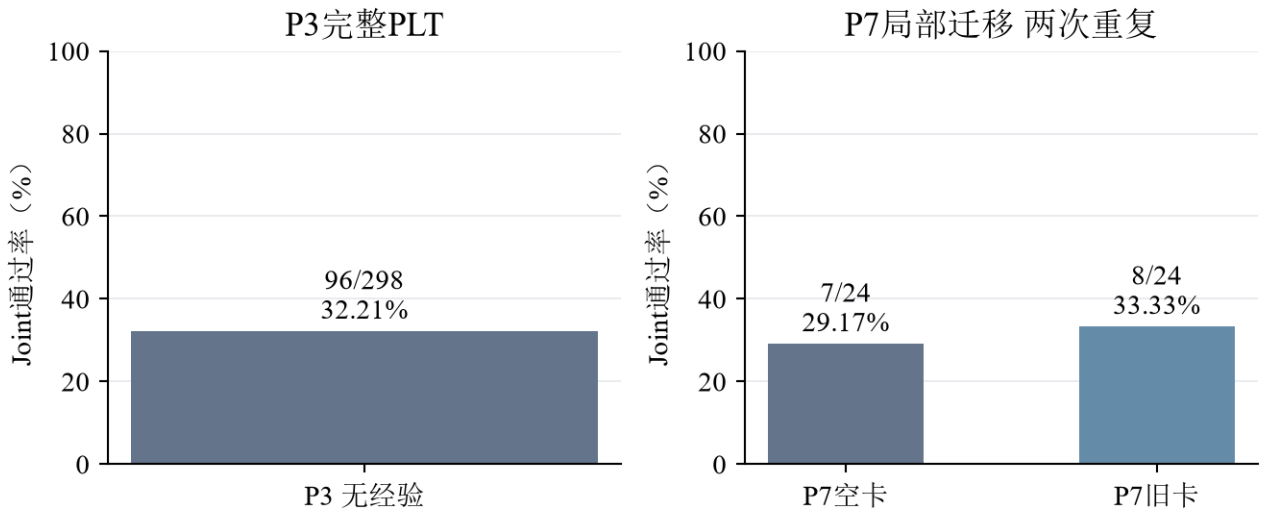


图 1 本周两个起步实验分别统计；P3 与 P7 不是同一流程

实验与条件	执行 / 计划	F 通过	S 通过	Joint 通过
P3 无经验	298 / 298	111 / 298	232 / 298	96 / 298
P7 空卡	24 / 24	7 / 24	18 / 24	7 / 24
P7 1939 卡	24 / 24	8 / 24	20 / 24	8 / 24

P3 完整测量 297 题，最终 Joint 为 32.21%；P7 空卡完整测量 23 个单元，带卡 24 个，双方均完整的 23 对中 Joint 均为 7 / 23。P3 已知 Token 为 3,841,636，30 次物理请求用量未知；P7 合计 2,063,129 Token（其中 Embedding 46,461），另 15 次请求尝试用量未知。两个来源的请求计数口径不同，费用均不写成实付账单，也不与【A8】累计数直接相加。

这些结果说明什么

图 1 左侧给出新模型在无经验完整任务集上的基线；右侧只说明这 12 题两重复的旧卡迁移表现。P7 原始总分带卡多 1 个通过，但唯一差异涉及空卡生成截断；排除不完整配对后双方相同。因此，这一轮建立了可复用的换模起点，尚未证明旧卡能够稳定提分。后续采用同 P7、同名单的 v4.1 三库对照；v3.2 停用后的新增交叉臂已经结束。后续【A2】至【A7】是在此后开展的机制比较，不把这些局部单元追加到 P3 的 298 题分母。

原始证据：10 月 25 日 P3 全量报告、10 月 25 日 P7 迁移报告。原始完成时间分别见各报告；本节属于 10 月 22 日至 28 日这一周。

返回要求七　返回本周实验主线　返回实验导航

【A2】Q 改变选卡后，代码是否更正确？

为什么做这项实验

本实验分两步：先通过重复选卡，判断 Q 有没有改变最终选中的卡，并与模型自身波动比较；再看改变选卡后，功能和安全是否一起通过。Q0 至 Q3 在下表中说明，最终仍由模型选择，不是直接取 Q 最高的三张。返回要求一

选卡方式	给模型的提示顺序是什么
Q0 原 CLE	按原有候选方式呈现，再由模型选择经验
Q1 相似度	优先呈现与当前题目语义相近的卡，再由模型选择
Q2 学习 Q	排序时加入经验卡的历史反馈分数，再由模型选择
Q3 打乱 Q	在同类漏洞中打乱卡与分数的对应关系，再由模型选择

Q0 的候选边界与其他组可能不同；与 Q0 比较时，不能把所有差异都归因于 Q 排序。

怎样做

29. 固定 1939 张经验正文和历史 Q 快照。972 张卡的 visits 大于 0，即曾获得反馈，覆盖率为 50.13%；Q 恰好为 0 但有反馈的卡也计入。这个快照包含 v3.2 的部分在线学习状态，不是 v4.1 重新学习的 Q。

30. 对 8 个题族的相同查询、候选和余弦相似度，分别运行四种排序，每种重复 5 次，共 160 次选卡。使用排序混合参数 $\lambda=0.5$、相似度阈值 $\delta=-1$ 和置换种子 20261015；这是本轮探索设置，不能写成所有历史 CLE 实验的默认参数。

31. 在 24 个预留题族上，每个条件重复 2 次，共 192 个代码单元。首次初析和候选共享，模型最多选三张；后续修复依各组代码独立进行，Q 和经验始终冻结。

32. 按相同题目及重复编号配对，比较卡号集合、新增卡采用、F/S/Joint 与救回损失。统计以题族为单位处理相关性，保留缺测及历史技术失败记录。

看到了什么

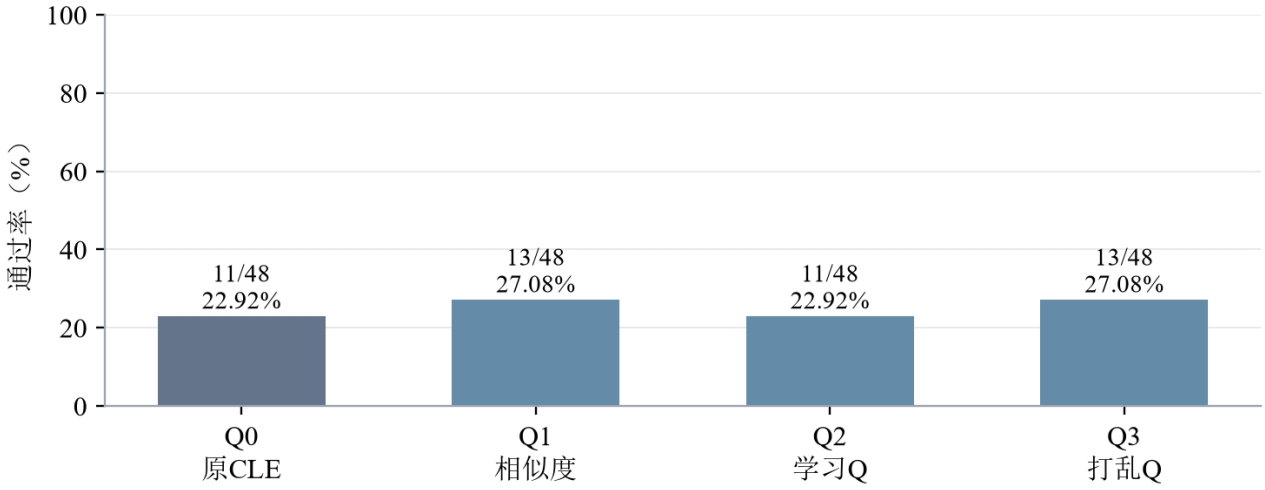


图 2 四种选卡条件的 Joint 通过率，分母各为 48 个代码单元

条件	F 通过数	S 通过数	Joint 通过数	完整测量
Q0 原 CLE	19/48	33/48	11/48	48/48
Q1 相似度	19/48	35/48	13/48	48/48
Q2 学习 Q	18/48	33/48	11/48	48/48
Q3 打乱 Q	20/48	32/48	13/48	47/48

重复选卡的 160 次有效记录显示，Q2 相对 Q0、Q1、Q3 的卡号集合差异超过组内波动，Holm 校正（同时比较多组时减少误判的方法）后的 p 值分别为 0.006、0.0072 和 0.00015。代码实验中，Q2 对 Q0 的首次选卡集合变化 46/48 次，新增卡声明采用 32/48 次。Q2 选中卡片的位置中 134/139 有过 Q 反馈，首次声明采用的位置中 97/97 有过反馈；这些是卡片位置数，不是独立题数。

这些结果说明什么

图 2 中，学习 Q 组与原 CLE 组同为 22.92%，比相似度和打乱 Q 各低 4.17 个百分点。逐题配对后，Q2 相对 Q1 没有救回、损失 2 次；相对 Q3 救回 1 次、损失 3 次；相对 Q0 救回和损失各 2 次。Q2 与 Q1、Q3 的两项成绩比较校正后 p 值均为 1，现有数据未支持学习 Q 提高 Joint。Q3 有一格缺测，不能将这一格解释成模型已被测出失败。

这个结果不能再主要解释为“没有接触到有 Q 的卡”，因为实际选中与声明采用的卡片大多已有反馈。具体失败仍发生在后面的落实环节：1209 采用了算术相关建议，但生成代码错误访问 AST 节点的 left/right 属性；1065 采用了跳过无效字段的建议，却仍然抛出异常；901 还存在公开题面未确定阈值的问题。因此，Q 的选卡作用已有直接证据，旧 Q 迁移适配、卡片适用性和代码实现能力则尚未被独立区分。下一步应完成新模型自己的分轮 Q 学习及冻结全量比较，不能凭本轮负结果宣布 Q 普遍无效。

对应原实验：D03a、D03b。数据来源：四臂统计和逐包汇总、选卡波动分析、代码与卡片复核。

返回要求一　返回要求二　返回本周实验主线

【A3】拆分或编辑经验能否兼顾功能与安全？

为什么做这项实验

功能经验帮助代码完成任务，安全经验帮助代码避免风险。本实验使用同一来源卡，比较混合与分栏展示；另从同一段已有代码出发比较有无经验的单次编辑，以减少起始代码不同的影响。分栏展示不等于建立了两套独立卡库。返回要求三

条件	实际给模型的经验内容
B0 无记忆	不提供经验卡
BM 原混合卡	采用原卡中混合的功能与安全建议
BF 功能视图	只呈现整理出的功能相关建议
BS 安全视图	只呈现整理出的安全相关建议
BFS 分区组合	分栏呈现功能和安全建议

怎样做

33. 固定 12 个题族、每题 2 次重复和五种条件，共 120 个代码单元：无记忆 B0、原混合卡 BM、仅功能视图 BF、仅安全视图 BS、功能与安全分区组合 BFS。

34. 共享首次初析及选卡。分区只读取来源卡正文，不查看目标题答案；分别记录 AI 分区和规则补全，生成模型接收相同公开任务，按原 P7 完成生成和最多一次修复。

35. 汇总各条件 F、S 与 Joint，将 BFS 和 BM 按同题配对，查明损失是否来自实际采用的建议或额外改写。

36. 补充编辑实验固定 6 个题族、2 次重复，以同一段 BM 首轮代码作为起点，只比较输入经验与不输入经验的单次编辑，共 24 个单元；它不是另一轮完整 P7 成绩。

看到了什么

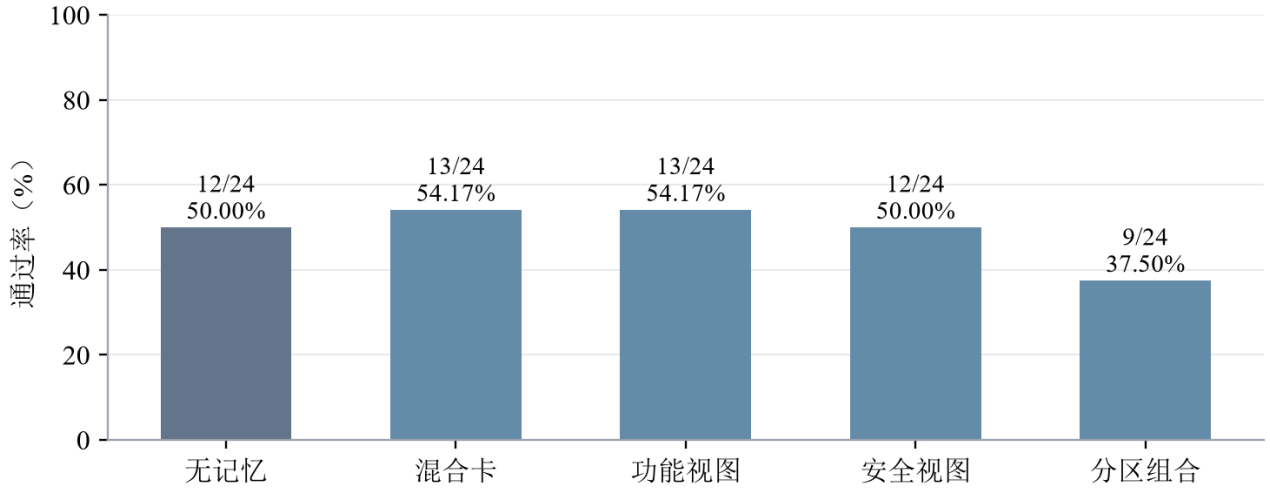


图 3 五种经验表达条件的 Joint 通过率，各为 12 题族两重复

条件	F 通过数	S 通过数	Joint 通过数
无记忆 B0	12/24	19/24	12/24
原混合卡 BM	14/24	19/24	13/24
功能视图 BF	15/24	19/24	13/24
安全视图 BS	13/24	18/24	12/24
分区组合 BFS	12/24	18/24	9/24

五组均完成完整测量。BFS 相对 BM 救回 0 次、损失 4 次。补充编辑中，无卡与带卡均为 F 7/12、S 9/12、Joint 6/12，救回和损失均为 0；带卡条件实际有 9/12 次输入经验，其余起点没有可用的采用卡列表。

这些结果说明什么

图 3 显示，分区组合的 Joint 为 37.50%，低于原混合卡的 54.17%。仅功能视图的功能通过数增加 1 次，但 Joint 没有增加，这说明改善功能的题目与安全通过的题目不一定重合。研究目标要求同一份代码同时满足两方面，因而不能用 F 单独增加替代 Joint 改善。

1326 的分区组合代码改写了白名单，破坏原有功能，但没有声明采用相关卡片。这说明“看到了不同的经验文本”和“明确使用某张卡导致错误”仍需区分。另一组编辑没有改变结果，也只说明这 6 个题族的单步编辑未产生收益；编辑输出格式不包含采用声明，不能把汇总中的采用数 0 解释为没有记忆输入。当前证据不支持直接推广这一拆分方式，后续全量实验应保留功能保持、来源假设迁移和实际代码改动三类分析，检验功能损失具体发生在哪里。

对应原实验：B02、B05。数据来源：逐包汇总、实际案例复核。

返回要求三　返回本周实验主线

【A4】经验越详细，代码就越好吗？

为什么做这项实验

要训练分类器，先要看同一道题在不同经验详细程度下是否真的有差别。如果大多数题各档表现相同，就缺少选择档位的学习信号。五档从不提供经验，到提供风险提醒、原理、任务模板或来源示例。返回要求四

档位	模型能看到什么
L0 无记忆	不提供经验
L1 风险提醒	一句话指出需要注意的风险
L2 机制前提	解释安全机制及适用条件
L3 操作模板	提供面向当前任务的操作模板
L4 来源示例	提供来源任务中的完整示例

怎样做

37. 固定 48 个 D_grow 题族，每题五档、每档两次重复，共 480 个单元；事先分为 36 个训练题族和 12 个开发题族。D_grow 是用于积累经验和反馈的任务池，不是最终独立测试集。

38. 从相同来源材料形成不同档位，排除同题族来源。15 张缺少来源代码的卡在所有档位共同排除，避免只有 L4 可用卡范围不同。

39. 各档按原 P7 预算生成和验证，记录真实采用、交付成绩和输入 Token。按题族查看两次重复是否支持同一档位，而不根据一次偶然成功指定标签。

40. 先报告五档完整结果，再将训练题族中具有可靠成功证据的记录交给【A5】；开发题族结果用于检验，不回填训练标签。

看到了什么

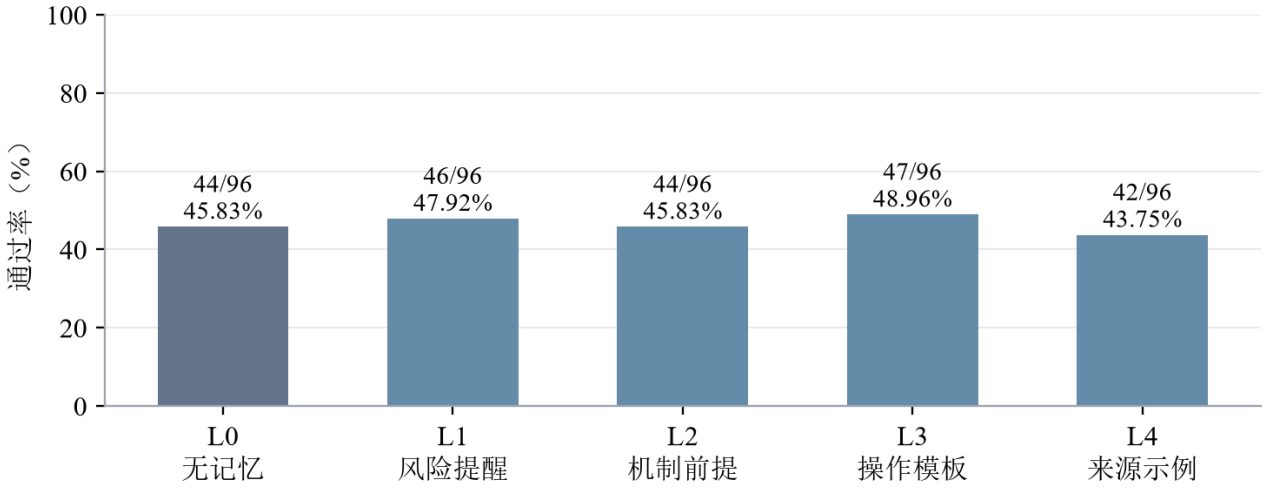


图 4 五档记忆的 Joint 通过率，分母各为 96 个代码单元

档位	F 通过数	S 通过数	Joint 通过数	完整测量
L0 无记忆	53/96	71/96	44/96	95/96
L1 风险提醒	53/96	74/96	46/96	96/96
L2 机制前提	53/96	74/96	44/96	96/96
L3 操作模板	54/96	75/96	47/96	96/96
L4 来源示例	49/96	71/96	42/96	96/96

L3 相对 L0 救回 6 次、损失 3 次，净增加 3 次；题族重采样 95%区间为−3.125 至+10.417 个百分点，配对检验 p=0.5625。48 个题族中 31 个在五档下成功的重复次数相同，其中 17 个全部失败、13 个全部成功，另 1 个各档均一次成功；只有 2 个题族存在某档两次成功、另一档两次失败的稳定强差别，均在训练部分。

这些结果说明什么

图 4 没有呈现记忆越详细、Joint 越高的趋势。L3 比无记忆高 3.125 个百分点，L4 低 2.083 个百分点；结合具体案例，一种可能解释是完整示例带入来源任务的假设，而操作模板与目标任务更容易衔接，但总分本身不能证明这一机制。不过区间跨过 0，当前不能确认 L3 总体更好，更不能仅凭 L4 总分较低就认定每个完整示例有害。

从分类器角度看，31/48 个题族没有可见的档位差别，意味着大量结果无法告诉模型“该选哪一档”。全部失败的题目也不能自动标成 L0 最优，因为它们没有证明无记忆更合适。逐题检查还发现 1005 在 L4 下成功却没有采用声明，1059 有来源四字段白名单与目标三字段要求的差别。这些现象要求后续标签同时考虑真实使用与可重复成绩，以免分类器学到生成波动或来源不匹配。

对应原实验：C02。数据来源：五档结果、案例复核。

返回要求四　返回本周实验主线

【A5】自动选择记忆档位胜过固定提醒了吗？

为什么做这项实验

分类器根据公开题目特征预测应该使用哪一档经验。本实验用【A4】的真实成绩训练，再与固定一档和公开规则比较；目标题的正确答案不能用于选择档位。只有最终代码成绩改善，才能说明选档对任务有帮助。返回要求四

选择方式	如何决定使用哪一档经验
分类器	根据公开题目特征预测
固定 L1	所有题都使用一句风险提醒
公开规则	根据预先写好的公开规则选择

怎样做

41. 仅使用 36 个训练题族制作标签。某档两次 Joint 都通过时，按预定规则选平均输入 Token 最少的合格档；全失败或缺少有效记忆介入的情况标为未解决，不强行指定最佳档位。

42. 最终得到 19 个有效题族标签：11 个 L0、7 个 L1、1 个 L3；另外 17 个保留未解决。提取公开题面长度、参数、绑定关系和副作用等特征，用逻辑回归训练，并仅在训练部分用三折划分选择设置。

43. 在 12 个开发题族查看三种策略，各为两次重复；随后固定分类器及策略，在 24 个保留题族上比较，每种策略两重复，共 144 个逻辑单元。

44. 对预测到同一档且协议完全一致的 12 个单元精确复用已有输出。按同题配对比较 Joint，保留实际采用数和缺测，不因某策略较差重新训练或换题。

看到了什么

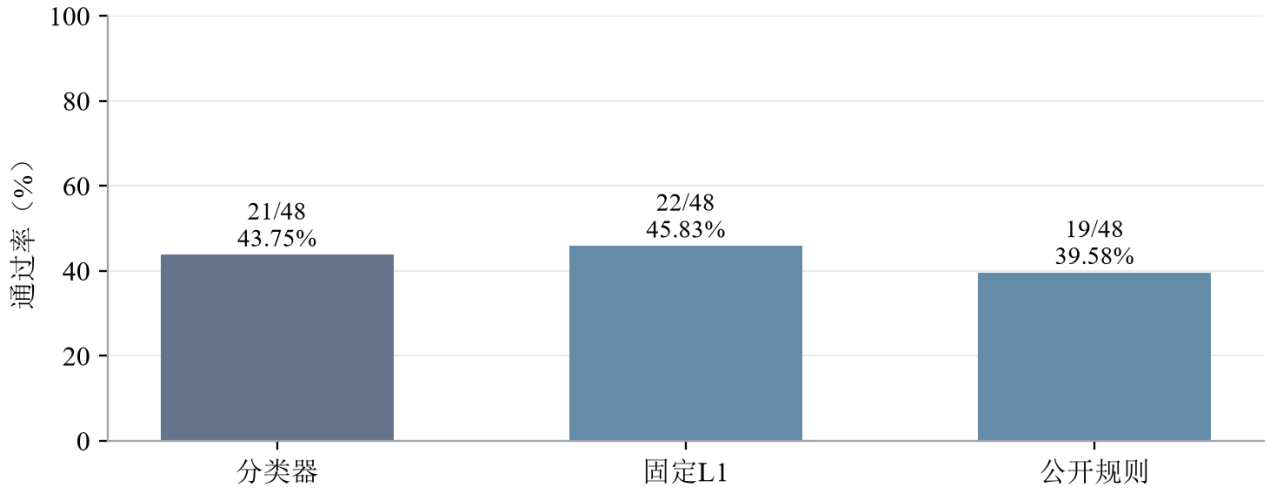


图 5 三种记忆选择策略在保留题上的 Joint 通过率

策略	F 通过数	S 通过数	Joint 通过数	完整测量
分类器	24/48	37/48	21/48	48/48
固定 L1	25/48	38/48	22/48	48/48
公开规则	25/48	34/48	19/48	47/48

开发部分三种策略均为 Joint 7/24。保留题中，分类器相对固定 L1 救回 1 次、损失 2 次；相对公开规则救回 3 次、损失 1 次，两项比较 Holm 校正后 p 均为 1。分类器条件有 12/48 次声明采用，固定 L1 有 45/48 次；不同策略可能主动选择 L0，因此采用率应结合预测档位解释。

这些结果说明什么

图 5 显示，分类器没有超过最简单的固定 L1 策略。它比公开规则高 2 次，却比固定 L1 少 1 次，不能据此证明学习型选择优于固定提醒。分类器大多学习到 L0 或 L1，而训练样本只有一个 L3、没有可靠的 L2 或 L4 标签，当前数据不足以训练出覆盖五档的清晰决策。

这项实验已经落实了“用真实结果训练分类器”的方法步骤，但尚未实现“分类器能帮助提高成绩”的研究目标。现有标签数量少且档位分布不均，是需要优先检查的可能原因；仅凭这次对照还不能排除分类特征或模型选择等其他原因。后续先执行 82 题标签批，按可训练门决定是否追加 82 题，保留未解决标签，并在独立题族上验证；不能把同题五档中的最高分直接当作推理时可获得的信息。

对应原实验：C03/C04a、C04b。数据来源：分类器结果汇总、完整分析来源。

返回要求四　返回本周实验主线

【A6】公开约束提醒能解决哪些实现问题？

为什么做这项实验

公开契约是题目已经说明的接口、对象和行为要求。本实验分别检查关系提醒、生成模板和公开检查能否帮助模型遵守要求。三项对照改变的内容和样本不同，结果需要分别解释。返回要求三

怎样做

45. 关系提醒 B03R 固定 1 个题族、2 次重复，比较无卡/带卡与绑定提醒/关系提醒的四种组合，共 8 个单元。初析、候选和生成前计划共享，只在预定生成阶段改变提醒；本周精确复用已完成记录。

46. 模板实验固定 12 个题族、2 次重复，比较登记的 P00、P13、P22 三种生成模板，共 72 个单元；共享首轮复析和规划，到生成阶段才分叉。

47. 公开检查 D02 固定 48 个题族、2 次重复，比较原 P7 与 PUBLIC 流程，共 192 个单元。PUBLIC 按预定协议使用公开检查和反馈决定修复与交付，隐藏测试不回传给模型；这一对照改变的是完整代码使用流程，不只是一句提示。

48. 分别统计各实验内部的成绩和配对变化，读取公开检查失败案例。已保存响应用于零 API 回放，回放发现的临时目录差异经修复后复核，不额外生成代码。

看到了什么

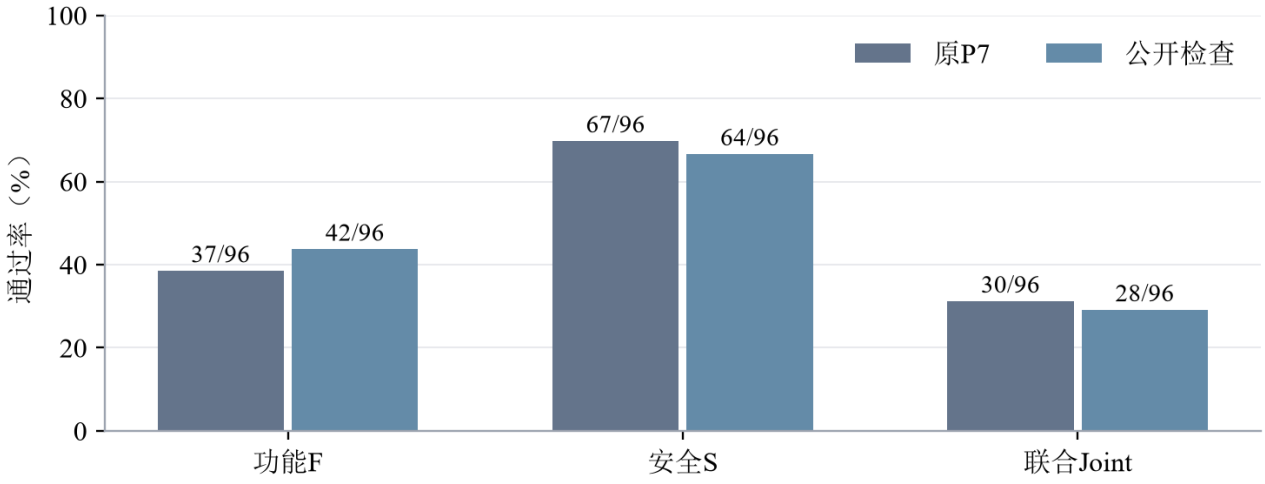


图 6 公开检查流程与原 P7 的功能、安全及联合通过率

实验与条件	Joint 通过数	补充结果
关系提醒四种组合	各 2/2	8/8 完整测量，无成绩区分空间
P00 / P13 / P22 模板	10/24、10/24、11/24	每组 24/24 完整测量
原 P7	30/96	F 37/96；S 67/96；完整测量 95/96
PUBLIC 公开检查	28/96	F 42/96；S 64/96；完整测量 96/96

PUBLIC 相对原 P7 救回 4 次、损失 6 次，Joint 净减少 2 次。D02 全部 192 个单元的零 API 回放最终与原成绩一致；为修复回放临时目录问题完成 21 项相关离线检查，旧差异现场保留。

这些结果说明什么

图 6 中，公开检查使 F 从 37 次增加到 42 次，但 S 从 67 次降至 64 次，Joint 也由 30 次降至 28 次。这说明“更多公开检查”未必等于更正确的交付，检查本身若理解错公开要求，也会把正确代码改坏。1001 的公开自检在内容已转义的情况下仍拒绝包含 onerror 的文本，继而促使代码破坏安全输出，是具体可核对的例子。

关系提醒的四种组合全部通过，只能说明接线按预定变量运行，无法证明提醒在总体上有效。模板 P22 仅多一次通过，也不足以承担整体提分结论。对主线而言，公开契约缺失、模型没有遵守契约、检查器错误扩大契约是三种不同问题；后续应把它们作为完整功能保持实验的解释层，避免把所有功能失败都归到经验卡或 Q 上。

对应原实验：B03R、S2_P13_P22、D02。数据来源：逐包统计、实际案例复核。

返回要求三　返回实验导航

【A7】来源经验的正向结果通过保留题确认了吗？

为什么做这项实验

本实验在同一 A7 代码生成与修复流程中，比较不提供经验和提供 M1 专门来源经验。M1_SOURCE36 与旧 1939 卡库不同；两组均最多一次公开证据修复。结果用于判断这套来源经验方案，不能单独归为 Q 或原 P7 的收益。返回要求三　返回要求七

怎样做

49. 在 12 个开发题族上，分别使用无经验与 M1 来源经验，每题 2 次重复，共 48 个单元。来源经验排除同题族材料，固定公开题面、模型和 A7 修复预算。

50. 按确认前登记的开发增量规则选出 M1，固定其配置，再在 24 个保留题族上运行两条件、两重复，共 96 个单元；不根据中途成绩调整方案。

51. 记录每次实际注入的经验，验证同一交付代码的 F/S/Joint，并将两组按题目和重复配对，核对救回、损失以及建议是否落实。

52. 同时报告按题族重采样区间和原协议精确检验，披露保留题此前在 D02 中的暴露；该组称方案保留确认，不称整个 CLE 从未见过的最终测试。

看到了什么

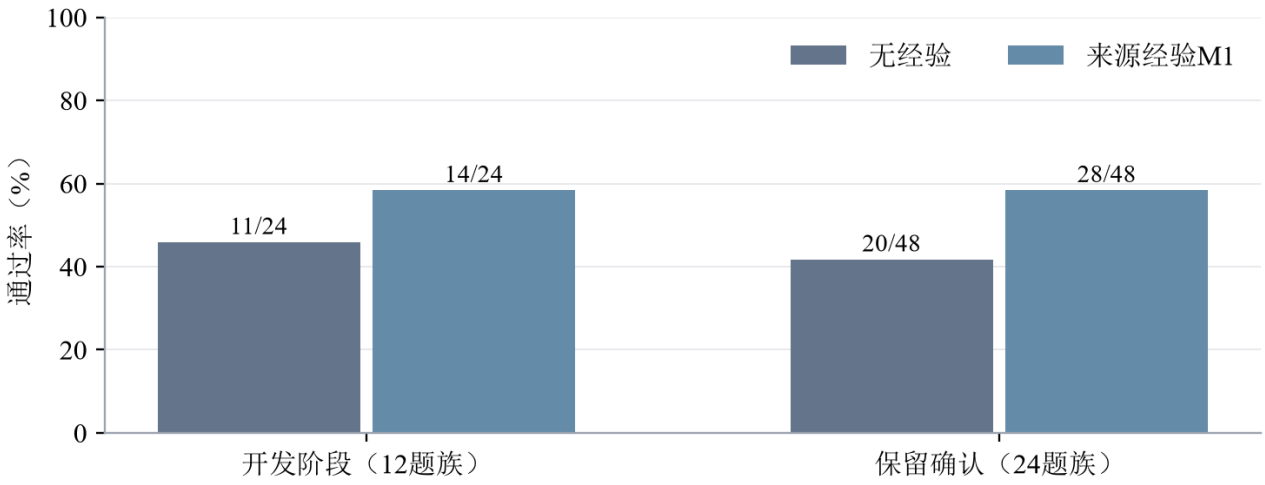


图 7 来源经验在开发和保留题上的 Joint 通过率，两部分样本分别统计

阶段与条件	F 通过数	S 通过数	Joint 通过数
开发：无经验	11/24	20/24	11/24
开发：M1	14/24	21/24	14/24
保留：无经验	27/48	37/48	20/48
保留：M1	33/48	39/48	28/48

两部分均完成完整测量。开发阶段 M1 实际注入 17/24 次，救回 5 次、损失 2 次；保留阶段实际注入 37/48 次，救回 9 次、损失 1 次，Joint 净增加 8 次，即 16.67 个百分点。保留阶段 95%题族重采样区间为+2.083 至+33.333 个百分点，题族区组精确双侧检验 p=0.078125；M1 两次重复间没有题族 Joint 分歧，无经验组有 4 个。

这些结果说明什么

图 7 显示，M1 在开发和保留题上均高于无经验，保留部分同时改善 F、S 和 Joint，是本轮最值得继续完整验证的正向结果。1001 中可以追踪到来源经验建议使用 html.escape，建议进入输入后在代码中落实，并对应最终救回；唯一损失案例 338 则涉及公开题面要求字符串、夹具使用字节串的冲突，不能不加区分地记为经验质量问题。

但两个统计方法给出的判断并不完全相同：重采样区间为正，原协议精确检验未达到 0.05。报告保留两者，不只挑有利的一项。因此当前结论是有方向性信号，尚未完成统计确认。下一步应在同一 A7 流程、相同来源资格和固定全量名单上继续比较；如果要解释成模型与卡库的交叉作用，还需单独固定使用模型、来源库及预算，完成真正的交叉矩阵。由于 v3.2 已经停用，新安排只执行 v4.1 三库比较，结论限于该模型。

对应原实验：S2_M1、S4。数据来源：开发及保留题统计、完整统计与案例分析。

返回要求三　返回要求七　返回本周实验主线

【A8】哪些结果已经完成，成本和检索测量还缺什么？

为什么做这项实验

本节核对基础清单完成了多少、费用记录覆盖什么，以及检索、Q 学习和建库还缺什么证据。它是零 API 资料复核，不产生新的代码成绩。完成数、检索质量和代码正确率需要分别判断。返回要求五

怎样做

53. 按执行索引读取各包计划、完成数和原生结果，区分代码单元、仅选卡单元、共享前序输出及同档精确复用，不合并成独立题目总数。

54. 检查 11 个代码包的既有零 API 回放结果，并读取 12 个代表案例的题面、卡片、计划、代码和验证记录。案例用于说明具体路径，不用于估计全体失败原因的比例。

55. 汇总已报告 Token、物理 HTTP（实际发出的网络请求）、未知用量和在途请求。沿用原账本的来源范围，失败未知用量不记为免费，不假设缓存命中率。

56. 查验 Q 更新、经验生成以及人工检索标签状态。没有执行或缺少必要标签的项目记为尚未验证，不能填入 0 分或从历史摘要反造记录。

看到了什么

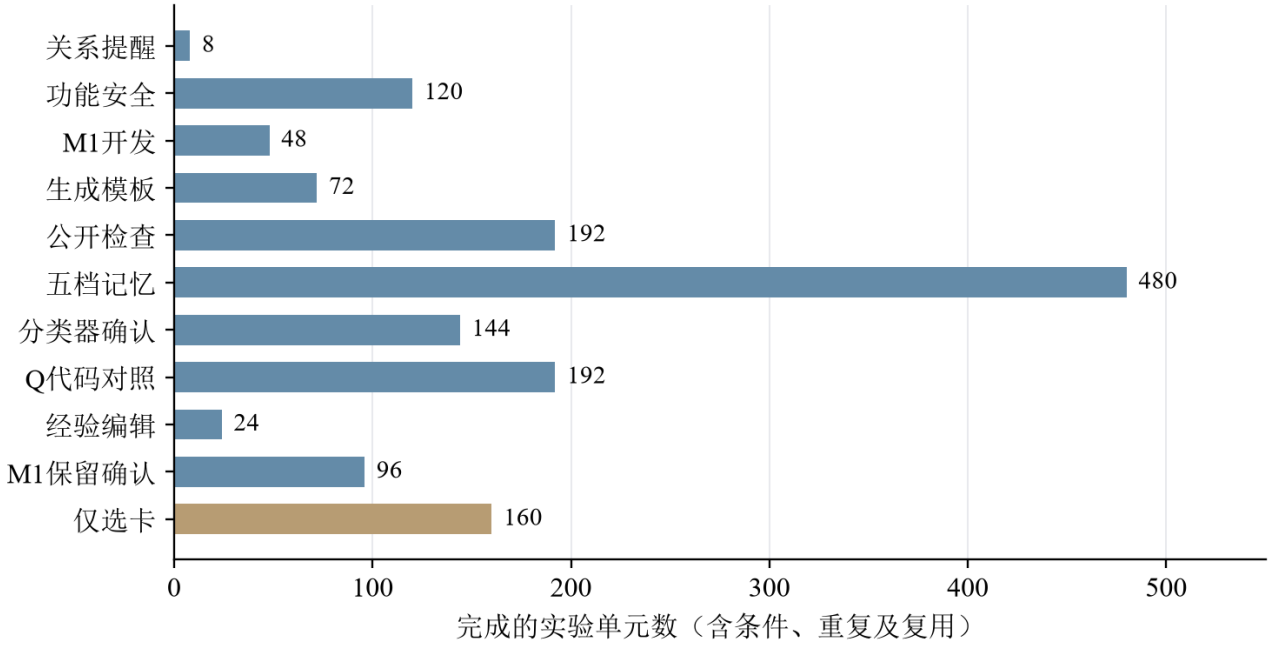


图 8 已完成基础清单的规模，代码单元与仅选卡单元分开显示

核对项	当前记录	能说明什么
代码实验单元	1376/1376	固定清单完成，含复用及重复
仅选卡单元	160/160	只检验选卡，不产生代码成绩
零 API 代码包回放	11 包一致	已存响应可重走对应流程
实际代码案例复核	12 例	提供具体原因证据，不代表总体比例
基础清单 Q 更新 / 新经验生成	0 / 0	10 月 26 日基础清单未进行新模型学习与建库
已报告 Token	65,186,659	累计账本用量，不是本周新增实付
物理 HTTP	10,338	包含记入来源的实际请求与重试
已结束未知用量 HTTP / 在途	302 / 0	未知部分不能记为零费用

这份累计记录包含本轮各包及列入恢复来源的请求，不能等同于整台电脑全部历史用量或本周新支出。当前没有足够账单依据给出人民币实付。关系提醒 8 格和分类器同档 12 格等复用均保留在各自逻辑分母中，不应为凑“新实验数”再次调用模型。

这些结果说明什么

图 8 和表格支持“基础清单完整完成”，并不支持“已做完全量新模型验证”。10 月 26 日基础清单没有完成 v4.1 的新 Q 学习、全 298 题 Q 四臂、从空库建立新经验、两个模型交叉使用两库，以及原验证

镜像下的 Base/Plus 评价。10 月 27 日新 Q 学习已开始，但尚未完成，最新前缀见【A9】。旧 P3、旧 Q 等结果只有在题面、模型、流程、反馈和预算匹配后才能作为新对照，否则只能保留为背景。

检索方面，准确率衡量题卡对的选入与未选入判断是否正确；精确率衡量选出的卡有多少适用；召回率衡量适用卡有多少被选出；F1 综合精确率和召回率。目前缺少人工确认的适用性标签，不能形成正式四指标。即使完成共同候选池标注，也只能先报告“候选池内召回率”；整库适用卡未被完整标注时，全库召回率仍未测量。这是测量缺口，不是已经证明检索差，也不能用 Q 覆盖率代替它。

数据来源：清单与成本汇总、零 API 回放、七项要求与全量任务。

返回要求二　返回要求五　返回要求六　返回要求七

【A9】反馈覆盖增加后，在线正确率怎样变化？

结果：前三个阶段完成，第三轮增长学习完成 45 题。反馈覆盖从 445 张升至 713 张，但在线 Joint 没有随覆盖单调上升。

为什么做这项实验？

旧 Q 在新模型上没有提分，需要让 v4.1 按自己的解题反馈重新学习。固定 1939 张卡正文，从 Q 和访问次数为零开始，保证观察到的是评分学习，不是换了一套卡。

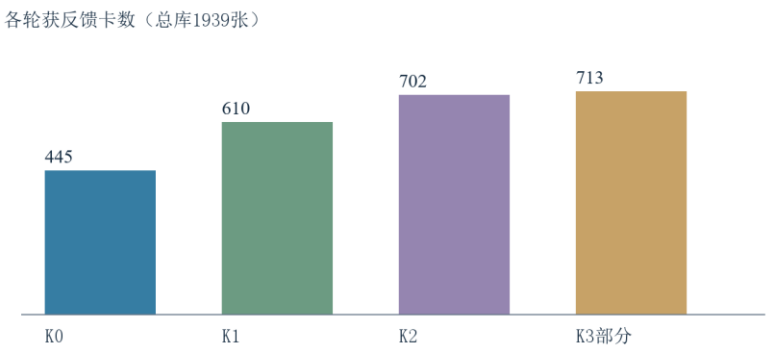
怎样做？

57. 顺序完成 303 道初始化题，按实际采用且具备奖励资格的卡更新 Q，冻结为 K0。

58. 在同 273 道增长题上继续三轮，分别冻结 K1、K2、K3；学习保持单 worker 逐题更新。

59. 每轮完成后回放保存响应和原验证结果，分析反馈卡、题族和主要代码差异；冻结回测按【T4】另行执行。

学习阶段	已完成/计划	可测	首次 Joint	最终 Joint	已获反馈卡/1939
K0 初始化	303/303	301	143	148（49.17%）	445（22.95%）
K1 增长第一轮	273/273	272	128	133（48.90%）	610（31.46%）
K2 增长第二轮	273/273	273	123	124（45.42%）	702（36.20%）
K3 增长第三轮	45/273	45	20	20（44.44%）	713（36.77%）



各阶段反馈覆盖

阶段	首次 F/S	最终 F/S	Q 记账次数	声明采用位置数
K0	159/244	163/247	837	878
K1	147/203	149/207	646	770
K2	145/204	146/206	611	748
K3 部分	23/33	22/33	110	129

这些结果说明什么？

K1 比 K0 新增 165 张反馈卡，K2 再新增 92 张，说明追加解题确实扩大了 Q 的反馈范围。K1 与 K2 使用同一增长题集，最终 Joint 分别为 133 和 124，在线读数下降；两轮生成不同、评分沿途变化，这个差值不能单独归因为 Q。54 题共同回测负责隔离轮次评分差异，全 273 题最终 Q 与相似度比较负责检验最终价值。K3 只完成 45 题，不与完整 273 题均值拼成收益曲线。

当前学习仍使用冻结的原奖励资格：增长集 232 题允许 Q 反馈，41 题照常解题但不记奖励。新标签实验修订后的增长集契约没有追溯写入学习。声明采用只是模型输出记录，是否真正落实到代码还需阅读实现。

实际阅读的题目	代码与验证发现	对主线的判断
K2：1289、1298	类型或异常行为的公开要求与验收存在差异	负反馈含契约因素，不能全部解释为卡片不适用
K2：675、1301	生成代码覆盖外部配置；1301 另有 URL 夹具问题	需要区分实现错误与题目条件，选卡正确不保证实现正确
K2：108	IDNA 实现修订后通过，但该题不具备 Q 奖励资格	这次救回不是 Q 记账收益证据
K2：883、1139	采用记录缺失或自述采用与实现不一致	采用字段不足以证明代码落实

K0 已完成保存验证反馈的精确回放，303 行结果、Q 和卡库一致；另行重新执行代码时，1107 出现同代码结果变化，1111 出现提示分歧，不能把这部分写成动态重验全部一致。K1、K2 已完成各自原

生回放和案例分析；K3 尚在运行。K0、K2 分别实际审查 12 题、9 题，以上为其中代表性证据，不作为全体原因比例。

返回追加学习要求　查看冻结回测安排

【A10】全量功能安全对照目前支持分栏表达吗？

阶段结果：已保存 1952/2980 次。原混合卡 173/390，分栏 169/390，当前没有显示分栏优于原卡。

为什么做这项实验？

小对照中分栏少通过 4 次。全量实验检验这一现象是否持续，并区分仅保留功能、仅保留安全以及两者分栏表达的作用。

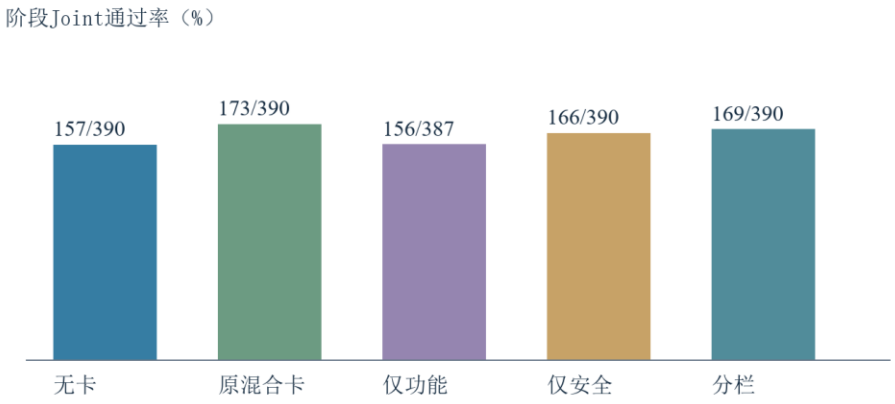
怎样做？

60. 固定 298 道评价题，分别使用无卡、原混合卡、仅功能、仅安全、功能安全分栏五种条件，各独立运行两次。

61. 四个带卡条件首次使用相同来源卡编号，再改变表达；各条件的修复过程独立，Q 和卡正文不更新。

62. 完整后比较同题同重复的救回与损失、F/S 四象限、题族区间和代码落实，再执行【T5】的单处改动复验。

条件	已完成	可测	F 通过	S 通过	Joint
B0 无卡	391	390	182	296	157（40.26%）
BM 原混合卡	390	390	201	311	173（44.36%）
BF 仅功能	390	387	190	293	156（40.31%）
BS 仅安全	391	390	194	305	166（42.56%）
BFS 功能安全分栏	390	390	199	306	169（43.33%）



功能安全对照的阶段 Joint

这些结果说明什么？

原卡目前在五组中 Joint 最高，分栏未超过原卡。各条件的已完成题目集合不完全一致，表中相减不等于已完成的配对效应；正式主比较将在五组固定名单完成后计算。当前保留全部实验继续执行，不按阶段排名挑选条件。功能、安全、Joint 分别报告，是为了判断分栏究竟恢复了功能、损失了安全，还是没有改变实现，而不是只看一个总分。

返回功能安全要求　查看差异原因复验

【A11】新安排如何减少成本并落到执行层？

结果：新计划已安装到工作台的 41 个节点，16 个未来节点的入口或交付条件完成更新，61 项离线验证通过。已启动的学习与功能安全实验保持原规则。 这是执行准备结果，不是模型正确率结果。

为什么这样安排？

中间轮次、标签和检索负责找到值得验证的机制，不需要一开始承担所有全量费用；最终 Q、功能安全及合格策略的主要比较保留全量，保证结论仍来自完整对照。

怎样执行？

63. 活动学习完成 K3，回放和分析后接 1416 次回测，再接 2384 次 Q 审计比较。

64. 功能安全完成 2980 次后分析并做 R01 本地复验；记忆标签、检索按各自前置和扩大条件执行。

65. 每包分析须包含真实统计、实际代码阅读和结论，回写对应叙事与图后才完成交付；普通负结果按预定主比较继续。

待做实验	新安排	与全量相比	扩大或完成条件
中间 Q 回测	同 54 题，最终两组全 273 题，共 1416 次	中间题量 19.8%	最终比较仍全量
记忆标签	82 题×5 档×2 次＝820 次	首批 30.0%	必要时追加 82 题，最多 60.1%
检索标注	57 题共同候选池	首批为 571 题的 10.0%	覆盖或精度不足再 57 题，最多 20.0%
Q 审计	298 题×4 组×2 次＝2384 次	100%	固定两项主要比较
功能安全	298 题×5 组×2 次＝2980 次	100%	完整配对分析及局部复验
自动选档	条件满足后 1788 策略结果	100%	先过可训练门，不强行造标签
新旧库	v4.1 三库 1788 结果	100%	1192 次精确复用，新生成最多 596 次
外部三库	Base/Plus 共 1530 次	100%	原环境就绪；两集分别分析

投入已经发生了多少？

本轮包或阶段	已报告 Token	物理 HTTP	未知用量或在途 HTTP
Q：K0	20,055,303	2,809	44
Q：K1	18,378,470	2,530	28
Q：K2	18,639,471	2,616	79
Q：K3 部分	3,028,002	485	65
Q 合计	60,101,246	8,440	216
功能安全	85,061,020	14,814	361
两包合计	145,162,266	23,254	577

本表取 18:10 物理账本；未知用量不计为零，也不按假定缓存命中率换算实付。此前基础实验的 65,186,659 Token 在【A8】单列，不把不同范围账本直接拼成项目总费。Codex 分析消耗与实验模型用量分别记录。

这些安排能得到什么结论？

缩小中间批次保留了三个关键回答：追加评分是否有效、最终评分能否迁移、经验表达是否改善 Joint。标签和检索按预先确定的条件扩大，避免为了结果好看追加样本。提分结论依据配对收益、题

族区间、重复一致性和校正后的主要检验；省 Token 结论依据质量不明显降低且完整流程成本下降。没有达到对应条件就结束该项收益主张，不换指标宣布成功。

具体执行依据见当前实验计划；本报告数据见保存快照。

返回本周主线　返回待做安排