10 月 22 日-10 月 28 日实验探索报告

一、本周实验主线

本周研究经验如何帮助代码同时满足功能与安全要求：先确认旧经验和 Q 评分在新模型上是否有用，再检验追加反馈、经验表达和自动选档，最后比较新旧卡库。检索测量负责查明适用经验在哪里遗漏，代码复盘负责解释选到经验以后为何仍然出错。截至本次补充，四轮 Q 学习已完成，Q 后续对照与记忆标签暂停；功能安全剩余全量暂缓，检索测量可以继续。

本报告按特殊安排并入 10 月 29 日已完成的实验和分析，内容核对截至 10 月 29 日 15:45。按本次特殊要求，10 月 29 日补充归入这一份报告；保留原标题，不另设本周周报。各实验仍注明实际发生时间。核心进展是：Q 反馈覆盖达到 769/1939；功能安全拆分在 486 组有效配对中净少 5 次 Joint 通过；单处代码修改让 3 题中的 2 题恢复 Joint；新增边界提醒的 24 对结果完全不变。下文保留历史实验，更新相关结论与待做清单；累计运行数不作为今日新增数量。

Joint 指同一份代码同时通过功能和安全测试，F、S 分别表示功能、安全通过。初始化集 303 题建立学习起点，增长集 273 题用于追加反馈，审计集 298 题检验使用效果。CWE 是漏洞类型，family 是同来源或相近结构的题族。两次重复是独立运行，不是两道新题。P3 无经验流程与 P7 空卡对照分别统计。A1—A7 的旧图表保留原计划分母，缺测及已测分母在相邻文字或表格注明；A9—A10 通过数使用明确列出的完成测量数，不能跨表直接比较百分比。

经验卡是可复用的解题建议；Q 是根据解题反馈更新的卡片评分。这里的“学习”只更新卡片评分，不训练生成模型的参数。“反馈覆盖”是获得过反馈的卡数除以总卡数，不代表这些卡已经被证明有效。旧卡与旧 Q 来自 v3.2；旧 Q 快照 972/1939 张卡已有反馈（50.13%），本轮 v4.1 评分从 0 重新学到 769/1939（39.7%），这是两个独立评分起点，不能相减解释成覆盖下降。本周生成模型为 deepseek-v4.1-flash-1017。

一次代码运行＝一道题在一个条件下的一次生成与验证。同一道题重复两次，仍只算一道独立题。配对比较固定题目及重复编号，再比较两个条件：“救回”指原来 Joint 不通过、换条件后通过；“损失”指相反变化。“保存完成”表示记录已经落盘，“已测”表示功能和安全结果均可获得，缺测不当作已测失败。

CLE 是本项目使用经验辅助生成代码的 Agent 系统。PLT 是本项目使用的代码安全题集，D_init、D_grow、D_gate 分别对应初始化集、增长集和审计集。P3 和 P7 是两套不同的解题流程：P3 不使用经验；P7 保留经验处理流程，空卡条件只是不输入卡片。两流程的分数不能直接相减当作经验收益。公开契约指题面已经说明的接口、输入输出和行为要求；测试夹具指执行验证所用的环境、辅助对象和测试代码。

各实验中的“12 题”或“24 题”只表示该实验名单规模，不表示名单彼此独立；来源经验确认题此前还用于 D02。A2 的 24 题称为 Q 对照名单，A5 的 24 题称为分类器确认名单，A7 的 24 题称为来源经验确认名单；本报告不把三份名单宣称为彼此独立。不同实验不能按题数直接累加或当作多次独立确认，本文只在同一实验内部按题号与重复配对。

下文按“问题→待做实验→已完成实验”阅读，点击【A】可跳到证据，点击【T】可跳到后续安排。统计中的置信区间表示差值的估计范围；跨过 0 时，数据仍容许正、负两种方向。p 值用于按预定规则判断差异，不是“结论正确的概率”。Holm 校正用于同时做多项比较时控制误判。

（1）旧 Q 能否改善新模型的代码？

旧 Q 改变了实际卡号，但代码对照中学习 Q 与原 CLE 同为 11/48，相似度为 13/48。与候选范围一致的相似度组相比，学习 Q 少通过 2/48 次，没有提高正确率；原 CLE 候选范围不同，与它的同分不能单独解释为纯 Q 效应。 【A2】

证据对应：选卡变化及代码对照，见【A2】。

（2）追加学习是否让更多经验卡获得反馈？

四轮学习已完成 1122 次，累计去重反馈卡数依次为 445、610、702、769 张，最终覆盖 39.7%。反馈范围扩大已经确认；冻结 Q 收益对照只保存 16/540 次，按要求暂停。【A9】

（3）Q 收益能否迁移到同漏洞类型的不同题族？

本轮新 Q 迁移对照尚未执行，当前暂停。旧 Q 的小对照已经完成，但不能代替新 Q 在不同题族上的迁移检验。【A2】 待做安排

（4）分开功能与安全经验是否更好？

小批探索见【A3】，扩大后的另一批运行见【A10】，两批分开统计。当前扩大批的分开写法没有改善配对结果。486 组有效比较救回 27 组、损失 32 组，净少 5 组；五条件共同 479 组中，原卡 Joint 为 203/479，分开写为 198/479。剩余 547 次全量暂缓，转向具体代码原因分析。【A10】 【A12】

（5）自动选择记忆程度值得继续吗？

既有分类器 21/48，固定提醒 22/48，分类器没有胜出。新 82 题标签批只保存 5/820 次，标签和分类器当前均暂停；不能据这 5 次判断新分类器效果。【A5】 待做安排

（6）检索遗漏发生在找卡还是选卡？

57 题的题意初析和候选池已完成，2 题先行标注共 144 个题卡组合，当前处理 34 条，其中 33 条有效、1 条失败。人工确认 0 条，正式检索指标尚未形成；检索测量按原范围继续。【A15】

（7）新模型自己的卡库是否优于旧库？

从空库建经验的 2 题技术探针通过，产出 5 张临时卡；完整新库尚未建成，不能比较新库与旧库孰优。旧卡迁移共同可测 23 次，两组均通过 7 次；v3.2 停用后的新跨模型臂不再执行。【A1】 【A14】

（8）如何用更少成本得到有用结论？

已完成结果和成功响应复用。当前边界提醒在 24 对比较中救回 0、损失 0，没有达到扩大门槛，因此不执行后续 96 次确认和 1192 次全量。检索继续，Q 与记忆实验维持暂停。【A13】【A16】

（9）具体代码改动真的造成了退步吗？

本地撤销 3 题中的配置覆盖后，3 题都恢复功能，其中 2 题同时保留安全通过。这 3 个案例中的具体错误改动已得到验证；但随后新增边界提醒未改变 24 对中的任何测试结果。原因成立不等于一句提醒就能解决问题。【A12】【A13】

二、补充更新后的待做实验

【T1】先完成检索标签，再判断漏卡发生在哪里

原因：候选池已建立，但还不能据此判断卡片是否适用于题目。

1. 处理固定 2 题的 144 个题卡组合（第 1184 题 69 张卡，第 500 题 75 张卡），逐条保留模型给出的适用性理由。

2. 对照公开题面与卡片，检查标签与公开题面及卡片是否一致：直接适用＝无需额外假设；需要附加条件＝满足注明前提才可用；冲突＝按卡做会违反本题要求；不适用＝与本题所需操作无关；证据不足时保留信息不足，不强行归类；网络失败记录为未标注，不算不适用。

3. 这 2 题的先行检查完成后，按原 57 题范围接续其余标注；输出人工复核清单，人工确认后再计算候选池内的检索指标。

当前状态：这 2 题的先行标签检查未完成，存在网络中断；不补发已执行过一次的题卡标注请求。检索是否有用要区分两步：先看系统找回的卡中有多少适用，再看最终选中的卡是否保留这些适用经验。标签必须经人工确认；若相关经验在前一步就遗漏，则先改检索，若进入候选池却被排除，则先改选卡。这里的指标只覆盖本批候选池，不代表整个卡库。

【T2】Q 与经验详细程度实验保留结果，等待明确恢复

原因：需要分别验证评分收益和经验详细程度的作用。详细程度有五档：不用经验、一句风险提醒、机制与适用前提、机制加目标题操作模板、机制加来源题示例；分类器就是为题目自动选择档位的程序，当前按要求暂停。

1. 保留 54 题 Q 回测已保存 16/540 次运行，以及 82 题×5 档×2 次重复的经验详细程度标注已保存 5/820 次运行。

2. 暂停期间只整理已有证据，不调用模型补齐，也不训练分类器。

3. 后续恢复仍沿用已登记名单、重复次数和实验规则；先完成各自小批比较，再按已登记的探针计划逐项检查扩大条件；本报告不另设新门槛。

当前状态：Q 回测、Q 迁移、记忆标签、分类器及标签追加均暂停。当前结果不足以计算预定小批对照的正确率差异，不能判成成功或失败。

【T3】只保留能解释问题的后续实验

原因：边界提醒在 24 组成对比较中没有改善测试结果；完整建库和大规模卡库比较暂缓，跨模型与外部评测另有下述依赖。

1. 当前边界提醒版本停止扩大，保留 48 次完整结果与回放。

2. 功能安全对照剩余 547 次暂缓；完整新库、交叉比较及外部评测继续跳过。

3. 后续若改变干预方式，先写清要改变哪一种代码行为、怎样在成对结果中验证；没有新干预不重复跑同一负结果。

当前状态：旧模型 DeepSeek v3.2 不可用，不能开展新的跨模型对照；Base 和 Plus 是两套外部评测集，目前缺少原 Docker 验证环境，因此外部评测不能执行。本文的新模型均为 deepseek-v4.1-flash-1017。这些未执行项不记作失败；当前 v4.1 结果也不代替跨模型比较。

返回本周主线

三、实验内容与结果分析

本次补充导航：【A9】Q 学习及回放　【A10】功能安全配对　【A12】单处修改　【A13】边界提醒　【A14】建库探针　【A15】检索检查　【A16】最新用量

【A1】无经验基线和旧卡迁移说明了什么？

为什么做这项实验

本实验回答两个问题：换成 v4.1 后，不看经验的模型能做对多少题；同一 P7 流程加入旧 1939 卡库后，成绩是否改变。P3 是无经验基线，P7 是另一套包含经验处理的生成流程，两者不能直接相减当作记忆收益。返回要求七

怎样做

1. 使用 deepseek-v4.1-flash-1017，保持原 P3 初析、规划、生成和最多一次修订，在 PLT 的 298 道 D_gate 题运行；不输入、不生成经验，不更新 Q。

2. 保留原 43 题结果，修复实际 TLS 传输问题后续跑 247 题，再按原实验规则补跑剩余 8 题；保留失败请求和未知用量，最终 298 题保存代码均零 API 回放。

3. 另外固定 12 题、每题两次重复，在 P7 中比较空卡与旧 1939 卡库；每个题次共享首次初析，最多三卡、最多一次修复，不学习 Q。

4. 对 48 个 P7 单元逐一回放；将技术缺测与模型答错分开，比较完整配对成绩，而不是把单次多通过一题直接归为经验作用。

看到了什么

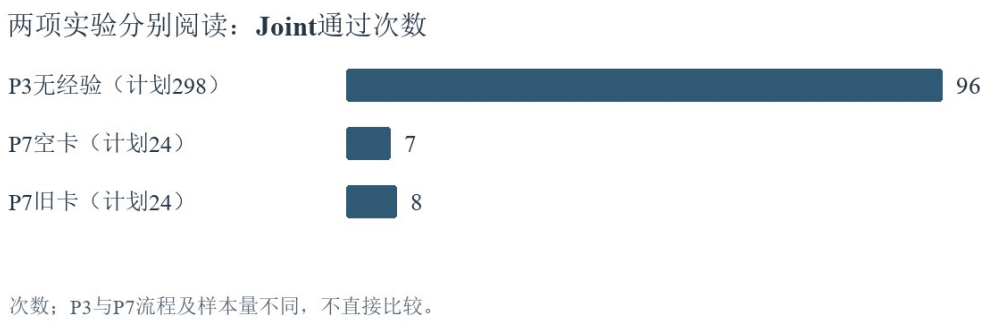


图 1 两项起步实验的 Joint 通过次数；P3 计划 298 次，P7 每条件计划 24 次，不比较柱高推断经验收益

实验与条件	保存 / 计划	F 通过 / 计划	S 通过 / 计划	Joint 通过 / 计划
P3 无经验	298 / 298	111 / 298	232 / 298	96 / 298
P7 空卡	24 / 24	7 / 24	18 / 24	7 / 24
P7 1939 卡	24 / 24	8 / 24	20 / 24	8 / 24

上表以计划次数为分母，表示交付通过占比；未测记录不计通过，也不称为测试失败。完整测量口径另列：P3 为 297/298，F 为 111/297、S 为 232/297、Joint 为 96/297；P7 空卡为 23/24，F 为 7/23、S 为 18/23、Joint 为 7/23；P7 带卡为 24/24。P3 完整测量 297 题，按 298 题计划计算 Joint 为 32.21%（96/298），按已测计算为 32.32%（96/297）；P7 空卡完整测量 23 个单元，带卡 24 个，双方均完整的 23 对中 Joint 均为 7 / 23。P3 已知 Token 为 3,841,636，30 次物理请求用量未知；P7 合计 2,063,129 Token（其中 Embedding 46,461），另 15 次请求尝试用量未知。两个来源的请求计数口径不同，费用均不写成实付账单，也不与【A8】累计数直接相加。

这些结果说明什么

图 1 第一项给出新模型在无经验完整任务集上的基线；后两项只说明这 12 题两重复的旧卡迁移表现。P7 原始总分带卡多 1 个通过，但唯一差异涉及空卡生成截断；排除不完整配对后双方相同。因此，这一轮建立了可复用的换模起点，尚未证明旧卡能够稳定提分。后续采用同 P7、同名单的 v4.1 三库对照；v3.2 停用后的新增交叉臂已经结束。后续【A2】至【A7】是在此后开展的机制比较，不把这些局部单元追加到 P3 的 298 题分母。

原始证据：10 月 25 日 P3 全量报告、10 月 25 日 P7 迁移报告。原始完成时间分别见各报告；本节属于 10 月 22 日至 28 日这一周。

返回要求七　返回本周实验主线　返回实验导航

【A2】Q 改变选卡后，代码是否更正确？

为什么做这项实验

本实验分两步：先通过重复选卡，判断 Q 有没有改变最终选中的卡，并与模型在相同条件下多次选卡的波动比较；再看改变选卡后，功能和安全是否一起通过。Q0 至 Q3 在下表中说明，最终仍由模型选择，不是直接取 Q 最高的三张。返回要求一

选卡方式	给模型的提示顺序是什么
Q0 原 CLE	按原有候选方式呈现，再由模型选择经验
Q1 相似度	优先呈现与当前题目语义相近的卡，再由模型选择
Q2 学习 Q	排序时加入经验卡的历史反馈分数，再由模型选择
Q3 打乱 Q	在同类漏洞中打乱卡与分数的对应关系，再由模型选择

Q0 的候选边界与其他组可能不同；与 Q0 比较时，不能把所有差异都归因于 Q 排序。

怎样做

1. 固定 1939 张经验正文和历史 Q 快照。972 张卡的反馈次数（visits）大于 0，即曾获得反馈，覆盖率为 50.13%；Q 恰好为 0 但有反馈的卡也计入。这个快照包含 v3.2 的部分在线学习状态，不是 v4.1 重新学习的 Q。

2. 对 8 个题族的相同查询、候选和余弦相似度，分别运行四种排序，每种重复 5 次，共 160 次选卡。使用排序混合参数 λ=0.5（混合排序分数，不是模型一半时间看 Q）、相似度阈值 δ=−1（本设置不以相似度分数排除候选）和置换种子 20261015（固定打乱结果，便于重复核对）；这是本轮探索设置，不能写成所有历史 CLE 实验的默认参数。

3. 在 24 个事先留出的题族上，每个条件重复 2 次，共 192 个代码运行。首次题意分析和候选卡列表共享，模型最多选三张；后续修复依各组代码独立进行，Q 和经验始终冻结。

4. 按相同题目及重复编号配对，比较卡号集合、新增卡采用、F/S/Joint 与救回损失。统计以题族为单位处理相关性，保留缺测及历史技术失败记录。

看到了什么

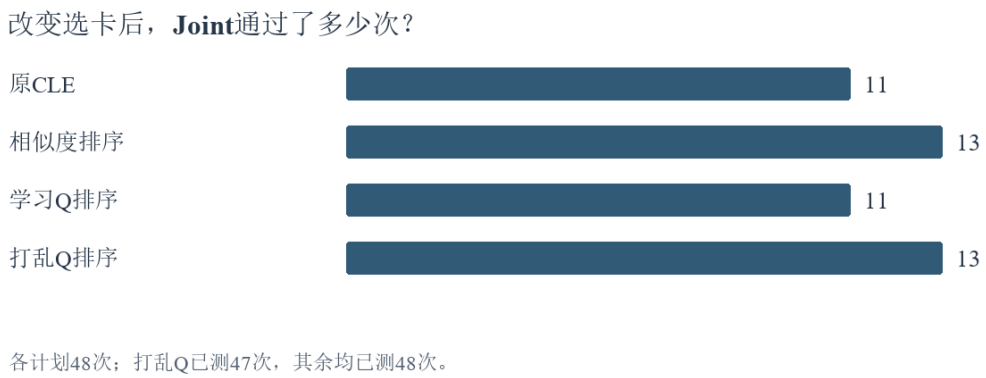


图 2 四种选卡条件的 Joint 通过次数；各计划 48 次，Q3 有 1 次缺测

条件	F 通过数	S 通过数	Joint 通过数	已测/计划
Q0 原 CLE	19/48	33/48	11/48	48/48
Q1 相似度	19/48	35/48	13/48	48/48
Q2 学习 Q	18/48	33/48	11/48	48/48
Q3 打乱 Q	20/48	32/48	13/48	47/48

上表各组以 48 次计划为分母；Q3 只完成 47 次测量，13/48 不是已测成功率，其已测成功率为 13/47。

重复选卡的 160 次有效记录显示，Q2 相对 Q0、Q1、Q3 的卡号集合差异超过组内波动，Holm 校正（同时比较多组时减少误判的方法）后的 p 值分别为 0.006、0.0072 和 0.00015。代码实验中，Q2 对 Q0 的首次选卡集合变化 46/48 次，新增卡声明采用 32/48 次。“卡位”指一次运行中一张卡的出现，同一张卡在不同运行重复出现会重复计数；运行数与卡位数分别统计。Q2 选中卡片的位置中 134/139 有过 Q 反馈，首次声明采用的位置中 97/97 有过反馈。32/48 统计“采用了相对 Q0 新增卡的运行”，97 统计 Q2 全部 48 次首次生成中声明采用的卡，包括新选入和两组共有的卡，因此不能用 32×3 检验 97；这些是累计卡片出现次数：同一张卡在不同运行中出现会重复计数，不是去重卡数或独立题数。

这些结果说明什么

图 2 中，学习 Q 组与原 CLE 组同为 22.92%，按 48 次计划分母计算，比相似度和打乱 Q 各低 4.17 个百分点；若仅描述已测成功率，Q3 为 13/47，与 Q2 的 11/48 相差 4.74 个百分点。逐题配对后，Q2 相对 Q1 没有救回、损失 2 次；相对 Q3 救回 1 次、损失 3 次；相对 Q0 救回和损失各 2 次。Q2 与 Q1、Q3 的两项成绩比较校正后 p 值均为 1，现有数据未支持学习 Q 提高 Joint。Q3 有一格缺测，不能将这一格解释成模型已被测出失败。

这个结果不能再主要解释为“没有接触到有 Q 的卡”，因为实际选中与声明采用的卡片大多已有反馈。具体失败仍发生在后面的落实环节：1209 采用了算术相关建议，但生成代码错误访问 AST 节点的 left/right 属性；1065 采用了跳过无效字段的建议，却仍然抛出异常；901 还存在公开题面未确定阈值的问题。因此，同候选边界下 Q2 与 Q1、Q3 的重复选卡差异支持 Q 改变了选择；Q2 对 Q0 的 46/48 变化还包含候选路径差异，旧 Q 迁移适配、卡片适用性和代码实现能力则尚未被独立区分。后续已完成新模型自己的四轮 Q 学习，见【A9】；54 题冻结探针已启动后暂停，见【T2】；排队全量暂缓，不能凭本轮负结果宣布 Q 普遍无效。

本节对应的原实验编号：D03a、D03b。数据来源：四臂统计和逐包汇总、选卡波动分析、代码与卡片复核。

返回要求一　返回要求二　返回本周实验主线

【A3】小批对照中，拆分或编辑经验能否兼顾功能与安全？

为什么做这项实验

功能经验帮助代码完成任务，安全经验帮助代码避免风险。本实验使用同一来源卡，比较混合与按功能与安全分段展示；另从同一段已有代码出发比较有无经验的单次编辑，以减少起始代码不同的影响。按功能与安全分段展示不等于建立了两套独立卡库。返回功能安全问题

条件	实际给模型的经验内容
B0 无记忆	不提供经验卡
BM 原混合卡	采用原卡中混合的功能与安全建议

条件	实际给模型的经验内容
BF 功能视图	呈现整理出的功能建议及适用上下文
BS 安全视图	呈现整理出的安全建议及适用上下文
BFS 功能安全分段组合	分别以功能、安全和适用上下文段落呈现同一来源卡

怎样做

1. 固定 12 个题族、每题 2 次重复和五种条件，共 120 个代码运行：无记忆 B0、原混合卡 BM、仅功能视图 BF、仅安全视图 BS、功能安全分段组合 BFS。

2. 各条件共享首次题意分析；只有四个带卡条件共享来源卡编号，B0 始终没有卡输入。整理时把同一张卡的文字分成功能建议、安全建议和适用上下文；不是另建功能卡库和安全卡库。分区只读取来源卡正文，不查看目标题答案；分别记录模型整理和按既定规则补全文段的处理方式，生成模型接收相同公开任务，按原 P7 完成生成和最多一次修复。

3. 汇总各条件 F、S 与 Joint，将 BFS 和 BM 按同题配对，查明损失是否来自实际采用的建议或额外改写。

4. 补充编辑实验固定 6 个题族、2 次重复，以同一段 BM 首轮代码作为起点，只比较输入经验与不输入经验的单次编辑，共 24 个单元；它不是另一轮完整 P7 成绩。

看到了什么

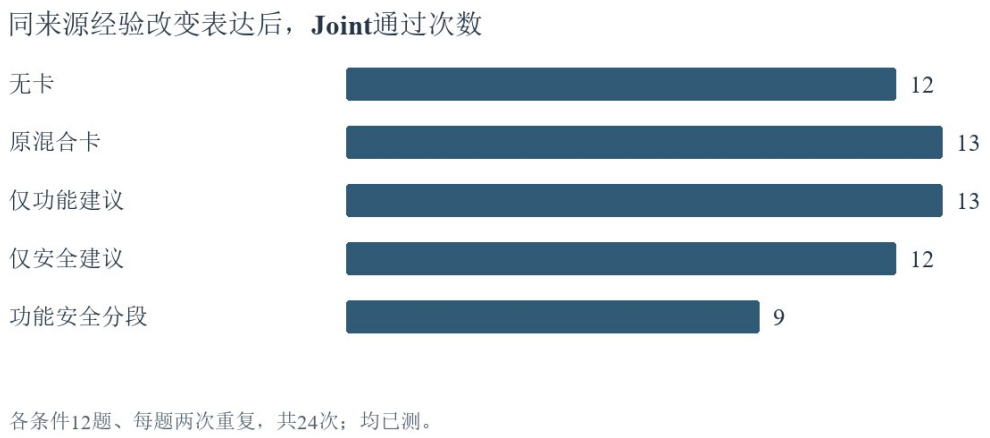


图 3 五种经验表达条件的 Joint 通过次数；每条件 24 次，均已测

条件	F 通过数	S 通过数	Joint 通过数
无记忆 B0	12/24	19/24	12/24
原混合卡 BM	14/24	19/24	13/24
功能视图 BF	15/24	19/24	13/24
安全视图 BS	13/24	18/24	12/24
功能安全分段组合 BFS	12/24	18/24	9/24

五组均完成完整测量。BFS 相对 BM 救回 0 次、损失 4 次。补充编辑中，无卡与带卡均为 F 7/12、S 9/12、Joint 6/12，救回和损失均为 0；带卡条件实际有 9/12 次输入经验，其余起点没有可用的采用卡列表。

这些结果说明什么

图 3 显示，功能安全分段组合的 Joint 为 37.50%，低于原混合卡的 54.17%。仅功能视图的功能通过数增加 1 次，但 Joint 没有增加，这说明改善功能的题目与安全通过的题目不一定重合。研究目标要求同一份代码同时满足两方面，因而不能用 F 单独增加替代 Joint 改善。

1326 的功能安全分段组合代码改写了白名单，破坏原有功能，但没有声明采用相关卡片。这说明“看到了不同的经验文本”和“明确使用某张卡导致错误”仍需区分。另一组编辑没有改变结果，也只说明这 6 个题族的单步编辑未产生收益；编辑输出格式不包含采用声明，不能把汇总中的采用数 0 解释为没有记忆输入。当前证据不支持直接推广这一拆分方式，后续全量实验应保留功能保持、来源假设迁移和实际代码改动三类分析，检验功能损失具体发生在哪里。

本节对应的原实验编号：B02、B05。数据来源：逐包汇总、实际案例复核。

返回功能安全问题　返回本周实验主线

【A4】提醒、原理、目标模板和来源示例，哪种经验表达更有用？

为什么做这项实验

要训练分类器，先要看同一道题在不同经验详细程度下是否真的有差别。如果大多数题各档表现相同，就缺少选择档位的学习信号。五档分别是不提供经验、风险提醒、原理、目标模板和来源示例。L3 与 L4 改变的不只是长度，也改变了内容类型：目标模板面向当前题，来源示例来自另一道题。返回记忆选择问题

档位	模型能看到什么
L0 无记忆	不提供经验
L1 风险提醒	一句话指出需要注意的风险
L2 机制前提	解释安全机制及适用条件
L3 操作模板	提供面向当前任务的操作模板
L4 来源示例	提供来源任务中的完整示例

怎样做

1. 固定 48 个 D_grow 题族，每题五档、每档两次重复，共 480 个单元；事先分为 36 个训练题族和 12 个开发题族。D_grow 是用于积累经验和反馈的任务池，不是最终独立测试集。

2. 从相同来源材料形成不同档位，排除同题族来源。15 张缺少来源代码的卡在所有档位共同排除，避免只有 L4 可用卡范围不同。

3. 各档按原 P7 预算生成和验证，记录真实采用、交付成绩和输入 Token。按题族查看两次重复是否支持同一档位，而不根据一次偶然成功指定标签。

4. 先报告五档完整结果，再将训练题族中具有可靠成功证据的记录交给【A5】；开发题族结果用于检验，不回填训练标签。

看到了什么

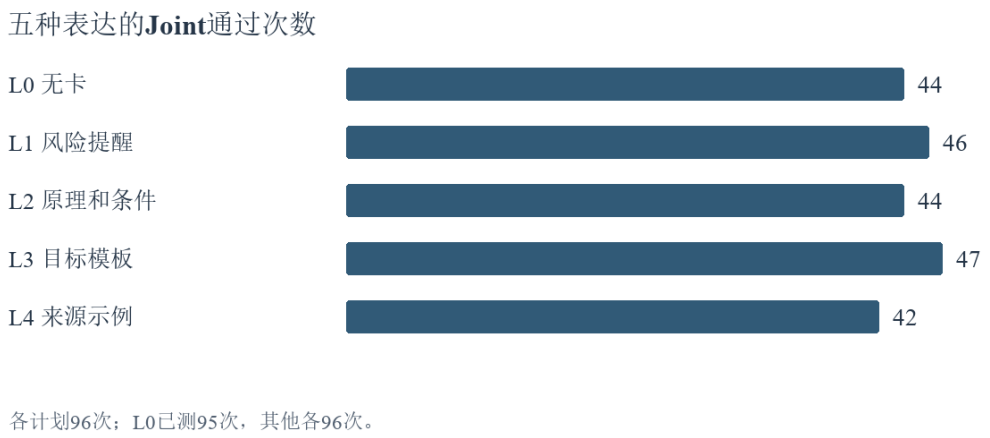


图 4 五档表达的 Joint 通过次数；各计划 96 次，L0 有 1 次缺测

档位	F 通过数	S 通过数	Joint 通过数	已测/计划
L0 无记忆	53/96	71/96	44/96	95/96
L1 风险提醒	53/96	74/96	46/96	96/96
L2 机制前提	53/96	74/96	44/96	96/96
L3 操作模板	54/96	75/96	47/96	96/96
L4 来源示例	49/96	71/96	42/96	96/96

上表按 96 次计划计算比例，L0 有 1 次缺测；其已测 Joint 为 44/95。以下差值和检验沿用原报告口径，缺测本身不证明模型失败。

L3 与 L0 双方均完成测量的 95 对中，共同通过 41 对、共同不通过 45 对，L3 救回 6 对、损失 3 对；L3 为 47/95，L0 为 44/95，净提高 3/95＝3.158 个百分点。原统计仍保留如下：以 96 个计划位置计算净增 3 次，包含 1 个未测位置；题族重采样 95%区间为−3.125 至+10.417 个百分点，按题族整体交换比较条件的双侧置换检验 p=0.5625（原统计以 48 个题族、96 个计划位置计算，包含 1 个缺测位置；这是历史计划口径，不作为 95 对完整测量的检验结果）。48 个题族中 31 个在五档下成功的重复次数相同，其中 17 个全部失败、13 个全部成功，另 1 个各档均一次成功；另有 2 个题族出现某档两次成功、另一档两次失败，均在训练部分；剩余 15 个题族存在档位差别，但没有达到这种两次全成功对两次全失败的对比。17 个全失败题族只能说明本次没有成功档，不能说明各档作用相同。

这些结果说明什么

图 4 没有呈现记忆越详细、Joint 越高的趋势。按图 4 的 96 次计划口径，L3 比无记忆高 3.125 个百分点，L4 低 2.083 个百分点；这些不是剔除缺测后的配对差值。结合具体案例，一种可能解释是

完整示例带入来源任务的假设，而操作模板与目标任务更容易衔接，但总分本身不能证明这一机制。不过区间跨过 0，当前不能确认 L3 总体更好，更不能仅凭 L4 总分较低就认定每个完整示例有害。

从分类器角度看，31/48 个题族没有可见的档位差别，意味着大量结果无法告诉模型“该选哪一档”。全部失败的题目也不能自动标成 L0 最优，因为它们没有证明无记忆更合适。逐题检查还发现 1005 在 L4 下成功却没有采用声明，1059 有来源四字段白名单与目标三字段要求的差别。这些现象要求后续标签同时考虑真实使用与可重复成绩，以免分类器学到生成波动或来源不匹配。

本节对应的原实验编号：C02。数据来源：五档结果、案例复核。

返回记忆选择问题　返回本周实验主线

【A5】自动选择记忆档位胜过固定提醒了吗？

为什么做这项实验

分类器根据公开题目特征预测应该使用哪一档经验。本实验用【A4】的真实成绩训练，再与固定一档和公开规则比较；目标题的正确答案不能用于选择档位。只有最终代码成绩改善，才能说明选档对任务有帮助。返回记忆选择问题

选择方式	如何决定使用哪一档经验
分类器	根据公开题目特征预测
固定 L1	所有题固定使用 L1 档；提醒内容随题目及检索到的经验变化，不是所有题复制同一句话
公开规则	无候选卡选 L0；题面出现外部绑定标记或写入等操作词选 L3，否则选 L2

怎样做

1. 仅使用 36 个训练题族制作标签。某档两次 Joint 都通过时，按预定规则选平均输入 Token 最少的合格档；全失败或缺少有效记忆介入的情况标为未解决，不强行指定最佳档位。

公开规则只检查题面：外部绑定标记是至少 3 字符的大写名称；操作词为 write、delete、modify、update、execute、open、send、save。它们是程序用于选档的文字特征，不代表已经证明存在副作用。分类器的 8 项输入是公开文本长度、参数词数、上下文长度、大写绑定名称数、是否说明返回值、是否说明异常、上述操作词数、安全要求长度。

2. 最终得到 19 个有效题族标签：11 个 L0、7 个 L1、1 个 L3；另外 17 个保留未解决。提取公开题面长度、参数、绑定关系和副作用等特征，用逻辑回归训练，并仅在训练部分用三折划分选择设置。

3. 在 12 个开发题族查看三种策略，各为两次重复；随后固定分类器及策略，在 24 个保留题族上比较，每种策略两重复，共 144 个逻辑运行。这 24 个确认题族由独立的确认名单提供，不是把 36 个训练题族和 12 个开发题族再拆成 24 个；完整题号名单见原实验记录。

4. 对预测到同一档且协议完全一致的 12 个单元精确复用已有输出。按同题配对比较 Joint，保留实际采用数和缺测，不因某策略较差重新训练或换题。

看到了什么

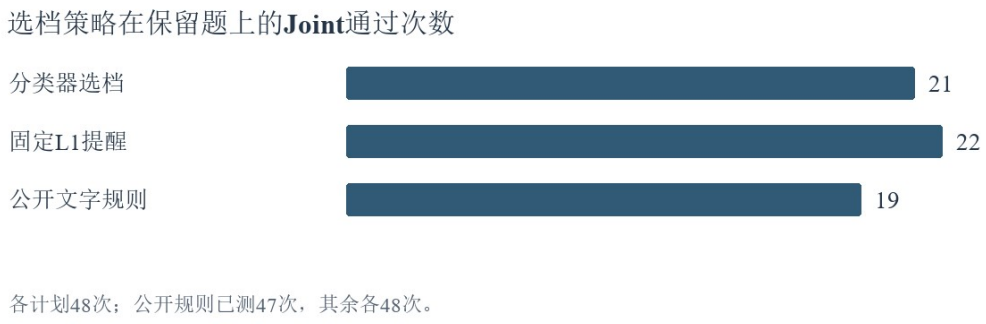


图 5 三种策略的 Joint 通过次数；各计划 48 次，公开规则有 1 次缺测

策略	F 通过数	S 通过数	Joint 通过数	已测/计划
分类器	24/48	37/48	21/48	48/48
固定 L1	25/48	38/48	22/48	48/48
公开规则	25/48	34/48	19/48	47/48

上表以 48 次计划为分母，公开规则有 1 次缺测，已测 Joint 为 19/47。

开发部分三种策略均为 Joint 7/24，分母来自 12 个开发题族各两次重复；这一步复用 C02 已有五档结果评估策略，不是另做 72 次独立生成。保留题中，分类器相对固定 L1 救回 1 次、损失 2 次；相对公开规则救回 3 次、损失 1 次，两项比较 Holm 校正后 p 均为 1。分类器条件有 12/48 次声明采用，固定 L1 有 45/48 次；不同策略可能主动选择 L0，因此采用率应结合预测档位解释。

这些结果说明什么

图 5 显示，分类器没有超过最简单的固定 L1 策略。它比公开规则高 2 次，却比固定 L1 少 1 次，不能据此证明学习型选择优于固定提醒。分类器大多学习到 L0 或 L1，而训练样本只有一个 L3、没有可靠的 L2 或 L4 标签，当前数据不足以训练出覆盖五档的清晰决策。

这项实验已经落实了“用真实结果训练分类器”的方法步骤，但尚未实现“分类器能帮助提高成绩”的研究目标。现有标签数量少且档位分布不均，是需要优先检查的可能原因；仅凭这次对照还不能排除分类特征或模型选择等其他原因。原计划先执行 82 题标签批，按训练数据门槛决定是否追加 82 题；该批当前已暂停，保留未解决标签，并在独立题族上验证；不能把同题五档中的最高分直接当作推理时可获得的信息。

本节对应的原实验编号：C03/C04a、C04b。数据来源：分类器结果汇总、完整分析来源。

返回记忆选择问题　返回本周实验主线

【A6】公开约束提醒能解决哪些实现问题？

为什么做这项实验

公开契约是题目已经说明的接口、对象和行为要求。本实验分别检查关系提醒、生成模板和公开检查能否帮助模型遵守要求。三项对照改变的内容和样本不同，结果需要分别解释。返回功能安全问题

怎样做

1. 关系提醒 B03R 固定 1 个题族、2 次重复，比较无卡/带卡与绑定提醒/关系提醒的四种组合，共 8 个单元。初析、候选和生成前计划共享，只在预定生成阶段改变提醒；本周精确复用已完成记录。

2. 模板实验固定 12 个题族、2 次重复，比较三种生成模板：P00 保留原提示；P13 增加保持正常行为和检查安全风险的要求；P22 再加入三个通用示例及最小必要改动要求，共 72 个单元；共享首轮分析和规划，到生成阶段才分叉。

3. 公开检查 D02 固定 48 个题族、2 次重复，比较原 P7 与 PUBLIC 流程，共 192 个单元。PUBLIC 按预定协议使用公开检查和反馈决定修复与交付，隐藏测试不回传给模型；这一对照改变的是完整代码使用流程，不只是一句提示。

4. 分别统计各实验内部的成绩和配对变化，读取公开检查失败案例。已保存响应用于零 API 回放，回放发现的临时目录差异经修复后复核，不额外生成代码。

看到了什么

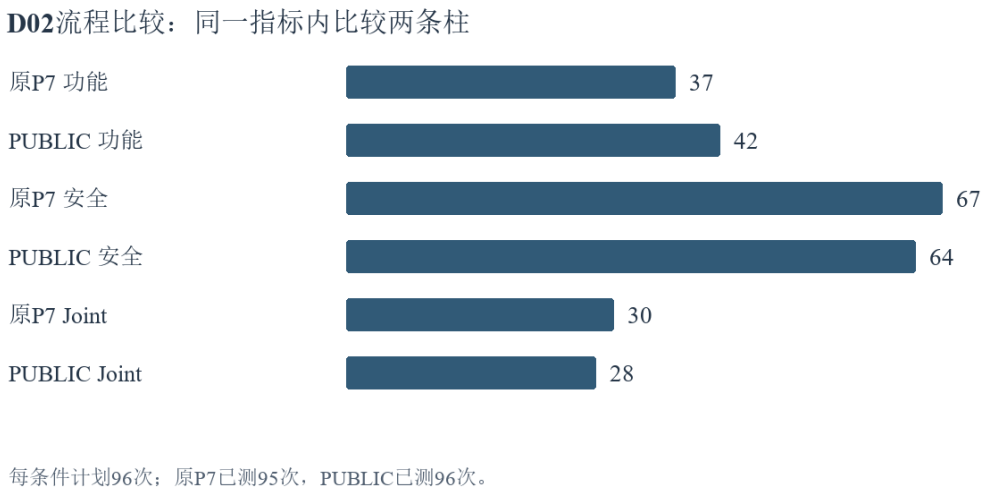


图 6 仅展示 D02 流程比较：每条件计划 96 次，原 P7 有 1 次缺测，关系提醒与模板见下表

实验与条件	Joint 通过数	补充结果
关系提醒四种组合	各 2/2	8/8 完整测量，无成绩区分空间
P00 / P13 / P22 模板	10/24、10/24、11/24	每组 24/24 已测/计划
原 P7	30/96	F 37/96；S 67/96；完整测量 95/96
PUBLIC 公开检查	28/96	F 42/96；S 64/96；完整测量 96/96

原 P7 有 1 次缺测：30/96 是计划分母口径，已测 Joint 为 30/95。

PUBLIC 相对原 P7 救回 4 次、损失 6 次，Joint 净减少 2 次。D02 全部 192 个单元的保存响应回放与原终态一致（含 1 次缺测状态；回放一致不把缺测变成测量成功）；为修复回放临时目录问题完成 21 项相关离线检查，旧差异现场保留。

这些结果说明什么

图 6 中，PUBLIC 整套流程下，F 从 37 次增加到 42 次，但 S 从 67 次降至 64 次，Joint 也由 30 次降至 28 次。这说明“更多公开检查”未必等于更正确的交付，检查本身若理解错公开要求，也会把正确代码改坏。1001 的公开自检在内容已转义的情况下仍拒绝包含 onerror 的文本，继而促使代码破坏安全输出，是具体可核对的例子。

关系提醒的四种组合全部通过，只能说明接线按预定变量运行，无法证明提醒在总体上有效。模板 P22 仅多一次通过，也不足以承担整体提分结论。该比较同时改变检查、反馈、修复和交付，不能把净变化单独归到某一句检查提示。对主线而言，公开契约缺失、模型没有遵守契约、检查器错误扩大契约是三种不同问题；后续应把它们作为完整功能保持实验的解释层，避免把所有功能失败都归到经验卡或 Q 上。

本节对应的原实验编号：B03R、S2_P13_P22、D02。数据来源：逐包统计、实际案例复核。

返回功能安全问题　返回实验导航

【A7】来源经验在另一批事先留出的题目上仍然有效吗？

为什么做这项实验

本实验在同一 A7 代码生成与修复流程中，比较不提供经验和提供 M1 专门来源经验。M1_SOURCE36 是这项实验专用的来源经验集合，与旧 1939 卡库不同；两组均最多一次公开证据修复。结果用于判断这套来源经验方案，不能单独归为 Q 或原 P7 的收益。返回功能安全问题　返回要求七

怎样做

这里的“保留题”是没有用于挑选 M1 方案的另一批题，不是把通过 Joint 的代码拿走经验后再测试。开发题用于选择方案，保留题用于固定方案后的比较；每个条件都独立生成代码。

1. 在 12 个开发题族上，分别使用无经验与 M1 来源经验，每题 2 次重复，共 48 个单元。来源经验排除同题族材料，固定公开题面、模型和 A7 修复预算。

2. 按确认前登记的开发增量规则选出 M1，固定其配置，再在 24 个保留题族上运行两条件、两重复，共 96 个单元；不根据中途成绩调整方案。

3. 记录每次实际注入的经验，验证同一交付代码的 F/S/Joint，并将两组按题目和重复配对，核对救回、损失以及建议是否落实。

4. 同时报告按题族重采样区间和原协议精确检验，说明这批保留题此前已用于 D02 实验；该组称方案保留确认，不称整个 CLE 从未见过的最终测试。

看到了什么

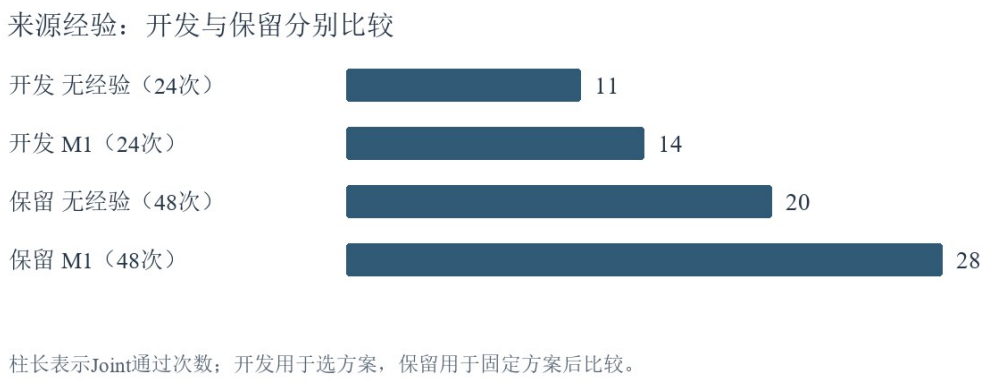


图 7 来源经验的 Joint 通过次数；开发每条件 24 次，保留每条件 48 次，两阶段分别比较

阶段与条件	F 通过数	S 通过数	Joint 通过数
开发：无经验	11/24	20/24	11/24
开发：M1	14/24	21/24	14/24
保留：无经验	27/48	37/48	20/48
保留：M1	33/48	39/48	28/48

两部分均完成完整测量。表内主成绩包含所有分配到该条件的运行，包括未注入经验的运行；没有把分母缩小为 17 或 37 来提高通过率。是否注入取决于来源资格和当次检索，不代表每次都能找到可用来源卡。开发阶段 M1 实际注入 17/24 次，救回 5 次、损失 2 次；保留阶段实际注入 37/48 次，救回 9 次、损失 1 次，Joint 净增加 8 次，即 16.67 个百分点。保留阶段 95%题族重采样区间为 +2.083 至+33.333 个百分点，题族区组精确双侧检验 p=0.078125；M1 中每个题族的两次重复 Joint 结果一致，无经验组 24 个保留题族中有 4 个的两次重复结果不一致。

这些结果说明什么

图 7 中，开发部分用于挑选 M1 方案，不能再当作一次独立确认；固定方案后，保留题部分的 M1 高于无经验，保留部分的 F、S 和 Joint 通过数均增加，但尚未达到预设统计门槛；这一结果支持继续验证该方案，尚不支持稳定提分结论。1001 中可以追踪到来源经验建议使用 html.escape，建议进入输入后在代码中落实，并对应最终救回；唯一损失案例 338 则涉及公开题面要求字符串、夹具使用字节串的冲突，不能不加区分地记为经验质量问题。

但两个统计方法给出的判断并不完全相同：重采样区间为正，原协议精确检验 p=0.078125，大于预定 0.05 门槛。报告保留两者，不只挑有利的一项。因此当前结论是在已测保留题上净增加 8 次 Joint 通过；原协议精确检验未通过 0.05 门槛，因此尚不能宣布稳定提分。后续比较须固定 A7 流程、来源资格与名单；当前先按 v09 做探针，排队全量暂缓；如果要解释成模型与卡库的交叉作用，还需单独固定使用模型、来源库及预算，完成真正的交叉矩阵。由于 v3.2 已经停用，新安排只执行 v4.1 三库比较，结论限于该模型。

本节对应的原实验编号：S2_M1、S4。数据来源：开发及保留题统计、完整统计与案例分析。

返回功能安全问题　返回要求七　返回本周实验主线

【A8】哪些结果已经完成，成本和检索测量还缺什么？

为什么做这项实验

本节核对 10 月 26 日基础清单完成了多少、费用记录覆盖什么，以及检索、Q 学习和建库还缺什么证据。它是零 API 资料复核，不产生新的代码成绩。完成数、检索质量和代码正确率需要分别判断。返回检索问题

怎样做

1. 按执行索引读取各包计划、完成数和原生结果，区分代码运行、仅选卡单元、共享前序输出及同档精确复用，不合并成独立题目总数。

2. 检查 10 个代码实验包和 1 个仅选卡包的既有零 API 回放结果，并读取 12 个代表案例的题面、卡片、计划、代码和验证记录。案例用于说明具体路径，不用于估计全体失败原因的比例。

3. 汇总已报告 Token、物理 HTTP（实际发出的网络请求）、未知用量和在途请求。沿用原账本的来源范围，失败未知用量不记为免费，不假设缓存命中率。

4. 查验 Q 更新、经验生成以及人工检索标签状态。没有执行或缺少必要标签的项目记为尚未验证，不能填入 0 分或从历史摘要反造记录。

看到了什么

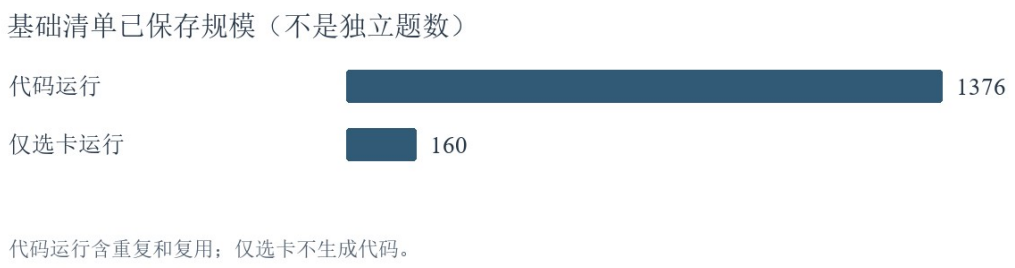


图 8 已完成基础清单的规模，代码运行与仅选卡单元分开显示

核对项	当前记录	能说明什么
代码实验运行	1376/1376	固定清单完成，含复用及重复
仅选卡单元	160/160	只检验选卡，不产生代码成绩
零 API 代码包回放	10 个代码包及 D03a 仅选卡包一致	已存响应可重走对应流程
实际代码案例复核	12 例	提供具体原因证据，不代表总体比例
10 月 26 日基础清单的学习范围（不含 A9）	仅 10 月 26 日基础清单：Q 更新 0 次、新经验生成 0 张	10 月 26 日基础清单未进行新模型学习与建库；后续 Q 学习见 A9
已报告 Token	65,186,659	累计账本用量，不是本周新增实付
物理 HTTP	10,338	包含记入来源的实际请求与重试
已结束未知用量 HTTP / 在途	302 / 0	未知部分不能记为零费用

这份账本仅对应 10 月 26 日基础清单及其列入恢复来源的请求；【A11】另报 10 月 27 日起的新 Q 学习和功能安全运行。两表按各自来源保留，不拼成全项目总费用。这份累计记录包含本轮各包及列入恢复来源的请求，不能等同于整台电脑全部历史用量或本周新支出。本表记录用量，不换算实付人民币。关系提醒 8 格和分类器同档 12 格等复用均保留在各自逻辑分母中，不应为凑“新实验数”再次调用模型。

1376 次代码运行的组成如下；P3 的 298 次和 P7 旧卡迁移的 48 次属于更早的换模起步实验，不在这 1376 次内。160 次选卡只比较卡号，不生成代码，也不加进 1376。

基础清单原编号	本文位置	计划及保存次数
B03R 关系提醒	A6	8
B02 功能安全表达	A3	120
S2_M1 来源经验开发	A7	48
S2_P13_P22 生成模板	A6	72
D02 公开检查流程	A6	192
C02 五档表达	A4	480
C04b 分类器确认	A5	144
D03b 四组 Q 代码对照	A2	192
B05 单次编辑	A3	24
S4 来源经验确认	A7	96
合计	保存运行，不是去重题数	1376

分类器拟合及开发读数复用 C02 结果，不再加一批生成次数。关系提醒 8 次和同档策略 12 次复用已经返回的结果：它们算设计中的逻辑运行，但不算新的模型请求。已保存 1376 次也不等于全部可测，缺测在各实验表中另列。

这些结果说明什么

图 8 和表格支持“基础清单完整完成”，并不支持“已做完全量新模型验证”。10 月 26 日基础清单没有完成 v4.1 的新 Q 学习、全 298 题 Q 四臂、从空库建立新经验、两个模型交叉使用两库，以及原验证镜像下的 Base/Plus 评价。10 月 27 日启动的新 Q 学习现已全部完成，最终统计见【A9】。旧 P3、旧 Q 等结果只有在题面、模型、流程、反馈和预算匹配后才能作为新对照，否则只能保留为背景。

检索方面，准确率衡量题卡对的选入与未选入判断是否正确；精确率衡量选出的卡有多少适用；召回率衡量适用卡有多少被选出；F1 综合精确率和召回率。目前缺少人工确认的适用性标签，不能形成正式四指标。即使完成共同候选池标注，也只能先报告“候选池内召回率”；整库适用卡未被完整标注时，全库召回率仍未测量。这是测量缺口，不是已经证明检索差，也不能用 Q 覆盖率代替它。

数据来源：清单与成本汇总、零 API 回放、七项要求与全量任务。

返回要求二　返回检索问题　返回成本安排问题　返回要求七

【A9】Q 学习完成后，目前能确认什么？

结论：反馈覆盖扩大到 39.7%；评分是否提高正确率仍由暂停的对照实验回答。 四轮学习于 10 月 28 日 23:33 完成，是 10 月 28 日期末成果，本次并入本报告，不把 1122 次累计运行算作 10 月 29 日新增。

1. 固定 1939 张经验卡，所有卡 Q 初值为 0。让模型在初始化集 303 题中选卡、生成代码、接受功能与安全验证，再据反馈更新评分。

2. 在另一批增长集 273 题上顺序学习三轮，K1、K2、K3 重复同一题集；每轮后保存评分。

3. 初始化集 303 题可授予反馈；增长集 232 题具备反馈资格，其余 41 题因奖励条件未合格仍执行但不更新 Q。只有模型声明实际采用的卡按协议记账，这不等于已证明卡内容在代码中正确实现；卡正文不变。

4. 冻结评分（评价时不再更新 Q）后，用 54 题比较五种排序：相似度排序，以及 K0、K1、K2、K3 四个学习阶段的 Q 排序。每种两次重复，共 540 次；依次已保存 3、4、3、4、2 次，合计 16/540 后暂停。这里的五条件与【A10】的五种经验表达不同。

学习阶段	保存运行数	完成测量数	功能通过	安全通过	Joint 通过	累计有反馈卡数
初始化 K0	303	301	163	247	148	445
增长第一轮 K1	273	272	149	207	133	610
增长第二轮 K2	273	273	146	206	124	702
增长第三轮 K3	273	273	144	204	126	769

阶段	首次功能通过	首次安全通过	首次 Joint	评分更新次数	声明采用卡次
K0	159	244	143	837	878
K1	147	203	128	646	770
K2	145	204	123	611	748
K3 完整	142	201	120	743	928

采用卡次按每次生成尝试累计，包括首次生成和修复；同一卡在两次尝试中出现会计两次。K3 的 928 卡次来自 426 次生成尝试，并非只来自 273 次首次生成；每次尝试最多三张，928 未超过 426×3。卡次不等于去重卡数，声明采用也不等于代码正确实现。

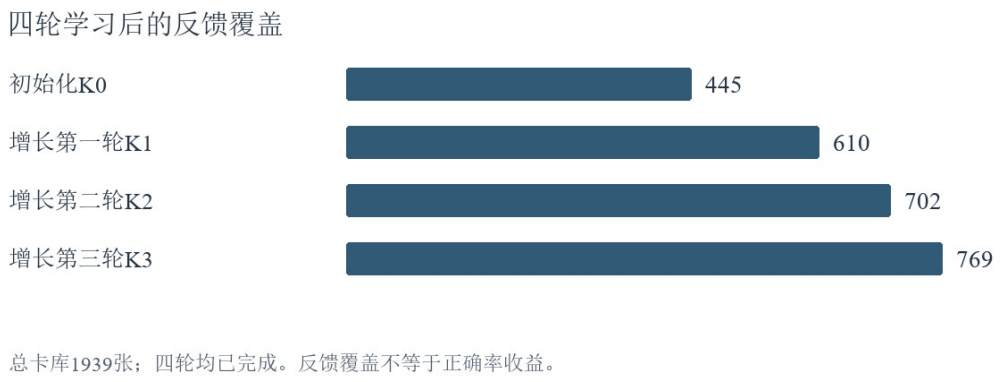


图 9 四轮学习后累计获得反馈的卡数；总卡库 1939 张

“最终”指该次解题按协议结束时交付的代码，并非以后轮次重新测得的分数。通过数以本行完成测量数为分母。累计卡数去重，以 1939 张卡为分母，四阶段覆盖率依次为 23.0%、31.5%、36.2%、39.7%。K0 与增长轮不是同一题集，同一题再次调用模型也可能给出不同代码；这些在线学习读数不是固定评分对照。因此，更多卡获得反馈是已发生的变化，“评分使代码更正确”仍未建立。表中保存运行数包括未完成测量的记录；K0 缺测 2 次、K1 缺测 1 次，均不算已测失败。

原始证据：四轮学习运行区　本报告状态快照

返回追加学习问题　返回实验导航

K3 的完整回放和分析也已完成：273 题、426 次生成尝试的代码、功能、安全、Joint 和逐题评分事件与保存记录一致；1939 张卡的评分与访问次数逐题重建一致，未新增模型请求。实际阅读 12 个代表队列项、涉及 10 道题。首次代码 Joint 为 120/273，允许一次修复后为 126/273，救回 6 题、损失 0；按题族计算的 95%差值区间为 0.71 至 4.04 个百分点，双侧置换 p=0.03125。这检验的是修复前后变化，不是有 Q 相对无 Q 的收益。

本轮 355 张卡获得 743 次有效反馈，涉及 180 个题族，其中 67 张此前没有反馈。声明采用 928 卡次并不保证建议正确落实：第 1298 题仍覆盖已有签名字典，第 1002 题覆盖题目提供的 HTML 模板；第 1289 题同时存在题面字符串与测试字节类型冲突。第 1019 题通过删除对已有用户表的清空操作恢复 Joint。上述证据说明，反馈里混有题目约定差异、实现错误和真实修复效果，不能把它们全部解释成卡片质量。

查看 K3 完整回放及逐题分析

K3 完成前的历史复盘

以下保留 K0—K2 的案例和回放发现。它们不是 K3 的新数据；K3 完整结果见上表及上一段。

实际阅读的题目	代码与验证发现	对主线的判断
K2：1289、1298	类型或异常行为的公开要求与验收存在差异	负反馈含契约因素，不能全部解释为卡片不适用
K2：675、1301	生成代码覆盖外部配置；1301 另有 URL 夹具问题	需要区分实现错误与题目条件，选卡正确不保证实现正确
K2：108	IDNA 实现修订后通过，但该题不具备 Q 奖励资格	这次救回不是 Q 记账收益证据

实际阅读的题目	代码与验证发现	对主线的判断
K2：883、1139	采用记录缺失或自述采用与实现不一致	采用字段不足以证明代码落实

保存响应回放是读取过去的模型响应和验证反馈来重走流程，不发新模型请求，也不重新执行代码；代码重验则是在本地再次运行同一代码和验证器。两者检查的对象不同。K0 已完成保存验证反馈的精确回放，303 行结果、Q 和卡库一致；另行重新执行代码时，1107 出现同代码结果变化，1111 出现提示分歧，所以代码重验并非全部一致；本表仍保留原始测量值，不用复验结果静默替换成绩。K1、K2 已完成各自原生回放和案例分析；这段复盘形成时 K3 尚在运行，K3 完成后的成绩已更新在上表。K0、K2 分别实际审查 12 题、9 题，以上为其中代表性证据，不作为全体原因比例。

返回追加学习要求　查看冻结回测安排

10 月 28 日 23:01 的旧快照中，K3 仅完成 243 次，首次功能/安全/Joint 为 124/179/104，交付为 125/182/109，反馈卡 762 张，评分更新 662 次，声明采用 835 卡次。23:33 完成后，首次为 142/201/120，交付为 144/204/126，反馈卡 769 张，评分更新 743 次，声明采用 928 卡次。旧快照保留于历史版，不与最终完整 273 题混算。

【A10】扩大到 298 题计划后，功能与安全经验分开写会改善结果吗？

结论：当前拆分方式没有提高已保存配对结果的 Joint。 共保存 2433 次运行，原计划 298 题×5 条件×2 次重复＝2980 次，剩余 547 次暂缓。10 月 29 日分别整理全部保存记录和可配对的结果。这 298 道独立题并非每道都完成全部条件与重复。

实验思路：每张来源卡的原文片段按“功能保持”“安全动作”“适用上下文”分类。仅功能保留功能片段和上下文，仅安全保留安全片段和上下文；分开写则在同一张卡中分别列出功能、安全和上下文三个字段。来源卡编号不变，不变成两张卡，也不新写事实。另设原卡和无卡对照。

1. 固定 298 道题、模型、验证器和两次独立重复。

2. 第一次生成代码前，四个带卡条件使用同一批选中来源卡，再按上述方法改变提供给模型的文字结构；这样首先比较的是经验表达，而不是卡号差异；无卡条件始终不提供经验。

3. 各条件独立生成、独立修复，Q 和卡正文不更新。

4. 先统计每组结果，再只用同题同重复的完整测量配对比较。

经验条件	保存次数	实际测量	功能通过	安全通过	Joint 通过
无卡	486	485	219	368	188
原卡	487	486	241	385	206
仅功能	485	482	229	365	188
仅安全	487	486	233	381	200
功能和安全分开写	488	488	240	383	203

保存运行数指已落盘的结果记录；完成测量指功能和安全均取得通过或失败结果，不等于通过。表内通过数均以本行实际测量数为分母。无卡、原卡、仅功能、仅安全、分开写分别有 1、1、3、1、0 次缺测，不计作已测失败。各行的已测集合不同，上表用于交代保存情况。下图统一使用五种条件都完成测量的 479 组（同题、同次重复），用于直观比较。

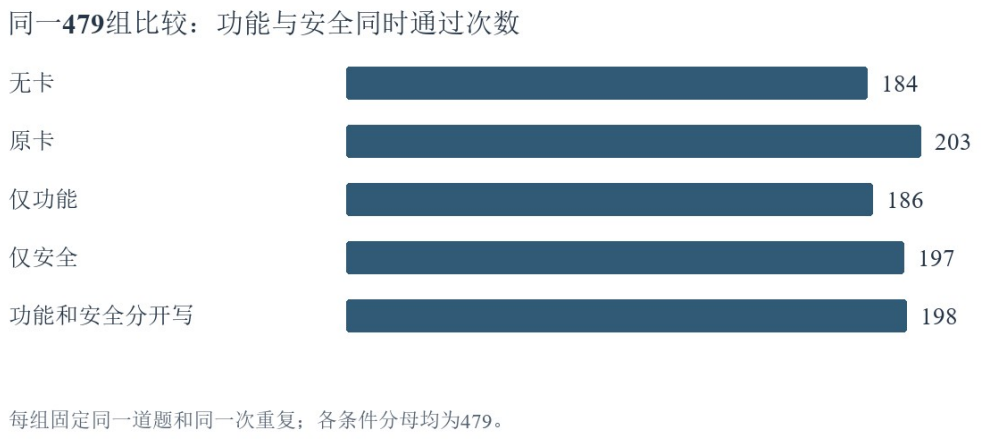


图 10 五种经验条件的 Joint 通过次数（每种 479 次：无卡 184、原卡 203、仅功能 186、仅安全 197、分开写 198）

共同 479 组中的条件	无卡	原卡	仅功能	仅安全	分开写
Joint 通过次数	184	203	186	197	198

原卡与分开写还可以组成 486 组有效配对，比五组共同集合多 7 组。其中 27 组从不通过变为通过，32 组从通过变为不通过，净少 5 组。两种统计范围都指向同一判断：当前分开写法没有带来更多同时通过功能与安全测试的代码。共同 479 组中，原卡也高于无卡和仅保留单类信息的条件；这是这批保存结果的描述，不作为全部 298 题两次重复的最终排名。2433 次保存中，2395 次进入五条件共同集合（479×5）；其余 38 次仍留在单条件统计或其他可测配对中。下一步把建议绑定到具体参数、密钥或接口，是结合【A12】案例提出的实验方向，不是单凭本表得出的原因结论。

本报告中的 E 盘证据链接用于本机查阅；运行根为 20261027_full_requirements，各链接的实验目录和文件名用于定位，报告正文与图表保留主要数字，外部读者无需打开原始文件即可理解结论。

原始证据：部分结果统计

返回功能安全问题　返回实验导航

在原卡与分开写双方均完成测量的 486 对中，配对结果如下。原卡通过 206 次，分开写通过 201 次；分开写单组总表中的 203 次还包括 2 次没有对应原卡完整测量的通过，不能用 203−206 代替配对净差。

原卡结果	分开写通过	分开写不通过	合计
通过	174	32	206
不通过	27	253	280
合计	201	285	486

【A11】历史记录：10 月 28 日怎样安排探针接力与成本？

本节保留 10 月 28 日 23:01 的调度与用量记录。10 月 29 日的暂停、停止扩大和最新用量以待做实验及【A16】为准。

以下仅记录 10 月 28 日当时的决定，已由当前待做清单取代，不是恢复运行指令。 当时安排 Q 学习和功能安全全量继续，其他研究先做探针，排队全量先跳过。 v09 取代白天 v08 的自动接续方式，40 项调度离线验证通过。这是执行规则验证，不是科学收益结果。

为什么这样安排？

旧 Q、功能安全分段表达和分类器小实验均未胜过对照。当前先用有限样本确认新机制和训练机会，把后续全量投入留给最有价值的问题；已经产生大量数据的两项全量保持规则完成。

怎样执行？

1. 完成活动学习和功能安全，回放保存结果并阅读实际代码。

2. 有已经完成的必要前置任务且入口已验证的探针自动接续，普通负结果按既定固定样本收口；条件追加只执行登记的小批。

3. 遇到排队全量先跳过，继续其他独立探针。跳过不解除真实完整卡库、分类器或原镜像依赖。

研究任务	本次自动范围	全量状态
Q 同题回测	54 题×5 条件×2＝540 次	原 1416 次方案中其余 876 次暂缓
Q 审计	2 题×4 条件×2＝16 次技术探针	其余 2368 次暂缓
记忆标签	82 题×5 档×2＝820 次；条件满足才追加 82 题	不直接扩到 273 题
自动选档	真实新标签训练后 6 题×3 策略×2＝36 次	其余 1752 次暂缓
检索	57 题；条件满足才追加 57 题	不直接扩到增长集 273 题＋审计集 298 题＝571 题
新库	2 道初始化题技术探针	完整建库暂缓
卡库交叉	真实完整新库到位后 12 题×3×2＝72 次	全 298 题暂缓
局部原因复验	最多 6 题、12 次本地验证	无实验模型请求

当时 1416 次同题方案＝最终 K3 与相似度各 273 题×2 次，加中间 K0/K1/K2 各 54 题×2 次；先行 540 次＝五条件各 54 题×2 次。因此 876 是 1416 减 540，不是 540 内的剩余次数。先行批当前完成 16 次，批内还剩 524 次且已暂停。

10 月 28 日当时新增限定题数的执行入口仍需离线验证后才能实际派发；队列名称不等于已做实验。截止时这些后续探针没有真实完成行。

已经投入多少？

本轮包或阶段	已报告 Token	物理 HTTP	未知用量或在途 HTTP
Q：K0	20,055,303	2,809	44
Q：K1	18,378,470	2,530	28
Q：K2	18,639,471	2,616	79
Q：K3	16,325,744	2,373	81
功能安全	101,406,792	17,598	425
两包合计	174,805,780	27,926	657

本表为 23:01 累计物理账本，未知用量不计为零；基础实验 65,186,659 Token 在【A8】单列，Codex 分析用量另记。没有当前账单就不折算实付人民币。

对主线有什么影响？

覆盖增加证明反馈触达更多卡，不证明代码更正确。当时计划用 54 题回测区分学习轮次、用功能安全对照检验经验表达、用 82 题标签和 57 题检索检查选档与遗漏。当前 Q 和标签均暂停，功能安全剩余 547 次暂缓；只有检索按原范围继续。以上是历史研究目的，当前行动以待做清单为准。

返回本周主线　返回待做安排　当前执行规则　本次保存快照

【A12】撤销一处错误改动，能否恢复功能？

结论：3 道题都恢复功能，其中 2 道保留安全通过，因而达到 Joint 通过。 这属于对保存代码的本地原因验证，不修改原模型成绩。

实验思路：从功能安全对照的 12 例代码复盘中，按“能单独撤销一处配置覆盖”选出 3 题。配置覆盖是指模型重新赋值，把运行环境已有的正则对象或密钥换成另一个值。这是为验证原因而选的案例，不是随机抽样。保持其余代码和测试不变，比较修改前后，判断这处改动是否影响失败。

1. 阅读公开题面、已有代码及验证结果。三题的预先预测均为：撤销该处覆盖后功能恢复，同时安全仍通过；然后分别验证。

2. 本地复验原代码，再仅撤销对应的配置覆盖。

3. 使用原验证器复验修改代码，共 3 题、6 次验证，不调用生成模型。

修改对象	原结果	单处修改后的结果	对预测的判断
第 128 题：恢复使用已有正则对象	功能失败，安全通过	功能通过，安全失败	预测功能恢复成立；预测安全仍通过不成立
第 353 题：去掉把已有密钥置为空字节的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint
第 359 题：去掉把已有密钥置为 None 的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint

这些结果把“可能改坏了配置”变成了具体代码证据：撤销对应改动确实改变测试结果。第 128 题说明，仅恢复功能还不够，安全也必须通过。3 题是有目的选取的案例，不能用 2/3 估算整个题库中这类原因的占比。

原始证据：单处修改和 6 次验证

返回代码改动问题　返回实验导航

【A13】增加修改边界提醒，能否减少错误改动？

结论：功能、安全和 Joint 测试结果逐对不变，但 7/24 对代码不同；停止扩大这个提醒版本。生成编辑实验完成 48/48 次（12 题×2 条件×2 重复）；保存响应的回放核对也完成 48/48 次，没有新增生成请求。

实验思路：把对具体错误的观察转成生成提醒，检验模型是否因此减少不必要的改动。“影响半径”指一次经验应用改变了哪些代码对象，是否扩展到本不需要改动的参数、配置或接口。

1. 固定 12 道题，每题使用保存的起始代码和同一批经验卡。模型只编辑一次，不接收测试反馈；原提示和新增提醒各独立重复两次，共 48 次编辑。

2. 两种提示都要求根据公开题目和经验编辑所给代码。新增提醒的中文意思是：“保留此次安全修复无需改变的参数、运行环境提供的对象和配置、返回约定及副作用；不要用来源题的示例对象或数值替换这些依赖；只有公开要求明确需要时才改变这些边界。”

3. 对比同题同重复的功能、安全、Joint 结果，并检查生成代码是否改变。

4. 回放保存响应，核对 48 次结果一致，不新增生成请求。

条件	运行次数	功能通过	安全通过	Joint 通过
原提示	24	11	16	8
边界提醒	24	11	16	8

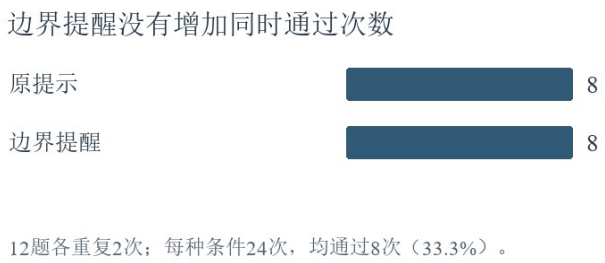


图 11 原提示与边界提醒均通过 8/24（12 题各重复 2 次，24 对中救回 0、损失 0）

以原提示为对照，24 组成对比较中救回 0、损失 0；每次重复各含 12 对，两次重复都没有任何 Joint 结果变化。同题同重复下比较两种提示的代码，7 对代码不同、17 对完全相同，测试结果逐对一致。代码复盘依据公开要求检查参数、环境对象、返回方式等是否被不必要地改写，核验到提醒减少此类改写的题数为 0；这项核验不把所有代码差异都算成错误。预定扩大条件是：净救回至少 2 次，两次重复各自净变化均不为负，没有新增安全失败，且至少 4 道题经代码核对减少了不必要改写。本次净救回为 0，核验减少不必要改写的题数也为 0，所以没有通过扩大条件，后续 24 题×2 条

件×2 重复＝96 次确认，以及 298 题×2 条件×2 重复＝1192 次全量均不执行（与【A10】暂缓的 547 次属于不同实验）。该结果否定的是当前提醒方式，不能据此把【A12】已验证的具体错误原因抹去。

原始证据：结果统计　停止决定

返回代码改动问题　返回实验导航

【A14】新模型能否从空库产生经验？

结论：2 题技术探针通过，得到 5 张临时经验卡；这不是完整新卡库。

1. 使用 deepseek-v4.1-flash-1017，从空经验库开始，按原 CLE 系统（本项目的经验学习代码 Agent）流程运行原生顺序的前 2 题，题号 45 和 46。

2. 检查首次生成代码及验证，保存经验提取结果。

3. 对已保存事件回放，核对代码和卡片内容，不重复调用模型。

指标	结果
不同题号数	2（同一题族，即同来源或相近结构的一类题）
首次 Joint	2/2
临时卡片	共 5 张，程序类型分别记为 1 张种子、2 张正向经验、2 张提示；这里只核对提取产物数量，不据类型名认定卡片有效
完整三轮建库	未执行
实际 HTTP 请求	17 次，其中 1 次用量未知
已报告 Token	29,944

两题来自同一题族，只说明这段技术流程能执行，不能证明新卡库能帮助不同题族。卡片中涉及“线性时间”（输入变长时耗时按相同比例增长）的说法尚无对应复杂度验证，不能直接作为已证明知识使用。完整建库暂缓，现有 5 张卡不用于宣称完整新库优于旧库；后续新旧卡库比较仍暂缓。

原始证据：建库技术探针

返回新卡库问题　返回实验导航

【A15】检索标签已经测到哪一步？

结论：57 题的候选池已完成，适用性标注和人工确认尚未完成。 候选池只是把待判断的卡收集起来，不能记作 57 题检索质量已测完。

1. 复用与本轮公开题面精确匹配的 52 题历史初步分析，补齐其余 5 题。标注模型同为 deepseek-v4.1-flash-1017，只读取公开题面和卡片，不读取测试答案。

2. 为 57 题分别建立待判断的卡片集合（每题一个候选池），并保存检索用向量（把查询文字编码成数字以比较语义相近程度）；这一步不生成解题代码。

3. 先检查第 1184 题的 69 张卡和第 500 题的 75 张卡，共 144 个题卡组合，保存模型标签及理由；这两题是完整 57 题检查的先行部分。

4. 人工确认后，在人工判断的候选池内比较实际检索返回和最终选卡：分别计算两阶段指标：检索精确率＝检索返回卡中的适用数÷返回卡数；选卡精确率＝最终选中卡中的适用数÷选中卡数。检索召回率与选卡召回率，分别用各阶段保留的适用卡数除以池内人工确认的适用卡总数。候选池汇集多路找卡结果，所以还可以检查某一路实际检索漏掉了哪些卡。

工作	截止时结果	是否能算正式检索结论
初步题意分析	57/57	否，是准备工作
候选池	57/57	否，还需判断适用性
两题先行标注	已发出 35/144；已保存处理结果 34/144＝33 条有效标签＋1 条失败；另 1 条已发出但未保存结果	否，尚未完成
人工确认	0 条	否

已落盘处理记录为 34 条（33 条有效、1 条失败）；此外还有 1 个已发出但未写入处理记录的网络中断请求，两者分别统计。该未决请求仍未形成可用标签，不算“卡片不适用”。已保存成功标签保留，不重复付费；同一题卡组合最多一次实际 API 标注调用。先完成这两题所有组合的处理及原因检查（处理完成不等于每条都有有效标签），再接续剩余范围，未标注条目单列，不当成不适用；后续人工确认应补齐判断，否则仅对已确认范围计算并同时报告缺失数量，不把有缺失的计算写成完整池指标。

原始证据：两题前缀记录

返回检索问题　返回待做检索

【A16】10 月 27 日起的七项实验累计用了多少资源？

本表只列下方七项实验，不含 A8 的 10 月 26 日基础清单，也不含 A1 的 P3/P7 起步实验，不是全项目总账。下表按 10 月 29 日核对的最新已保存账本，包含【A11】10 月 28 日 23:01 之后的增量，不能再与 A11 相加。Q 学习比 A11 新增 1,944,684 Token、266 次 HTTP，功能安全新增 5,142,594 Token、866 次 HTTP；HTTP 均包含其原账本记录的成功、失败和重试，未知用量列仍保留。以下为跨周累计已报告用量，不是 10 月 29 日单日新增费用。Token 是模型处理的文本单位；HTTP 是实际网络请求次数，包含成功、失败及向量请求。未知用量不能按零费用计算。没有可靠实际单价与完整账单，本稿不换算人民币。

实验	已报告 Token	实际 HTTP 请求数	Token 用量未知或请求尚未结束的 HTTP 数
Q 学习	75,343,672	10,594	234
冻结 Q 同题回测 · 54 题小批	1,296,336	171	17
功能与安全经验拆分	106,549,386	18,464	434

实验	已报告 Token	实际 HTTP 请求数	Token 用量未知或请求尚未结束的 HTTP 数
五档记忆标签 · 82 题小批	358,600	60	5
经验检索准备与标注 · 57 题	116,329	46	3
新模型建库 · 2 题技术探针	29,944	17	1
影响半径 · 边界提醒对照	712,383	48	0

表中最后一列沿用原运行记录的合并计数：既包含没有收到 Token 用量的请求，也可能包含截止时尚未结束的请求，不据此推算费用上限。本表只统计实验，不含报告写作和独立文字审阅。

返回本周主线