10 月 29 日-11 月 4 日实验探索报告

一、本周实验主线

本周围绕两个总问题展开，下分四项具体问题：模型应用经验后为什么反而改坏代码，以及怎样确认找出的经验真正适用。先复查已保存代码，再用小批对照验证原因，最后整理检索标签。经验评分的学习已经完成；根据 10 月 29 日的暂停决定，后续评分对照、经验详细程度标注和自动选档实验暂停；待排队的大规模实验不启动。暂停只改变后续安排，不删除已完成结果。

本稿统计到 2026-10-29 12:29:49（北京时间）。这是截至 10 月 29 日中午的周中稿。跨周数字从各实验启动时累计到本稿截止时点，分别列出运行次数、测量次数和通过次数，下面明确区分既有学习结果与本周新增分析，不把累计完成数算成本周新增。

经验卡是可复用的做题建议；Q 是项目中经验卡效用评分的符号，根据做题后的功能与安全验证反馈更新；“Q 学习”在本文指更新卡片评分，不是训练模型参数。Joint 表示同一份代码同时通过功能测试和安全测试。一次“运行”指一道题在一种条件下执行一次；同题重复两次仍然是一道题。“一组”固定同一道题和同一次重复：比较两种条件时含 2 次运行，比较五种条件时含 5 次运行。本文按实验分别给分母，不把不同任务量相加成总正确率。

（1）分开写功能与安全经验，是否让更多代码同时通过测试？

没有改善当前配对结果。 同题、同次重复的 486 组有效比较中，相对原卡，分开写使 27 组由 Joint 失败变为通过（救回），32 组由通过变为失败（损失），净少 5 组（27−32）。五种条件都完成测量的 479 组中，原卡 Joint 通过 203/479，分开写通过 198/479。【A1】

证据支持“当前拆分方式没有提高这批结果”，因此暂不扩大剩余全量。下一步先定位具体代码改动，而非继续增加同类运行次数。【A2】

（2）找到错误改动后，提醒模型少改无关内容就够了吗？

定位具体改动有效，当前提醒方案无效。 3 道题的本地单处修改使 2 道恢复 Joint 通过；另 1 道功能恢复但安全失败。随后 12 道题的两次重复对照中，原提示与新增边界提醒均通过 8/24，逐对结果完全相同。【A2】【A3】

这支持继续研究“哪些改动不该做”，但不支持扩大当前这一句提醒。直接修改已有代码与让模型重新生成代码是两种干预，不能当成同一个实验。

（3）更多卡获得 Q 评分，是否已经证明评分有用？

证明了反馈范围扩大，尚未完成正确率对照。 既有四轮学习完成 1122 次，最终 769/1939 张卡获得反馈（39.7%）。冻结评分后的 54 题回测已保存 16/540 次，现已暂停，不用学习过程自身的正确率代替评分收益。【A4】

（4）新卡库和检索质量，目前能得出什么判断？

从空库提取经验的技术流程已经跑通，完整新库尚未建成。 2 题技术探针产出 5 张临时卡。检索 57 题的题意初步分析和待判断的候选卡集合已备齐，当前只开展 2 题的标签检查，人工确认仍为 0；现阶段不发布检索精确率或召回率。【A5】【A6】

二、本周待做实验

【T1】先完成检索标签，再判断漏卡发生在哪里

原因：候选池已建立，但还不能据此判断卡片是否适用于题目。

1. 处理固定 2 题的 144 个题卡组合（第 1184 题 69 张卡，第 500 题 75 张卡），逐条保留模型给出的适用性理由。

2. 对照公开题面与卡片，检查标签与公开题面及卡片是否一致：直接适用＝无需额外假设；需要附加条件＝满足注明前提才可用；冲突＝按卡做会违反本题要求；不适用＝与本题所需操作无关；证据不足时保留信息不足，不强行归类；网络失败记录为未标注，不算不适用。

3. 这 2 题的先行检查完成后，按原 57 题范围接续其余标注；输出人工复核清单，人工确认后再计算候选池内的检索指标。

当前状态：这 2 题的先行标签检查未完成，存在网络中断；不补发已执行过一次的题卡标注请求。检索是否有用要区分两步：先看系统找回的卡中有多少适用，再看最终选中的卡是否保留这些适用经验。标签必须经人工确认；若相关经验在前一步就遗漏，则先改检索，若进入候选池却被排除，则先改选卡。这里的指标只覆盖本批候选池，不代表整个卡库。

【T2】Q 与经验详细程度实验保留结果，等待明确恢复

原因：需要分别验证评分收益和经验详细程度的作用。详细程度有五档：不用经验、一句风险提醒、机制与适用前提、机制加目标题操作模板、机制加来源题示例；分类器就是为题目自动选择档位的程序，当前按要求暂停。

1. 保留 54 题 Q 回测已保存 16/540 次运行，以及 82 题×5 档×2 次重复的经验详细程度标注已保存 5/820 次运行。

2. 暂停期间只整理已有证据，不调用模型补齐，也不训练分类器。

3. 后续恢复仍沿用已登记名单、重复次数和实验规则；先完成各自小批比较，再按已登记的探针计划逐项检查扩大条件；本报告不另设新门槛。

当前状态：Q 回测、Q 迁移、记忆标签、分类器及标签追加均暂停。当前结果不足以计算预定小批对照的正确率差异，不能判成成功或失败。

【T3】只保留能解释问题的后续实验

原因：边界提醒在 24 组成对比较中没有改善测试结果；完整建库和大规模卡库比较暂缓，跨模型与外部评测另有下述依赖。

1. 当前边界提醒版本停止扩大，保留 48 次完整结果与回放。

2. 功能安全对照剩余 547 次暂缓；完整新库、交叉比较及外部评测继续跳过。

3. 后续若改变干预方式，先写清要改变哪一种代码行为、怎样在成对结果中验证；没有新干预不重复跑同一负结果。

当前状态：旧模型 DeepSeek v3.2 不可用，不能开展新的跨模型对照；Base 和 Plus 是两套外部评测集，目前缺少原 Docker 验证环境，因此外部评测不能执行。本文的新模型均为 deepseek-v4.1-flash-1017。这些未执行项不记作失败；当前 v4.1 结果也不代替跨模型比较。

返回本周主线

三、实验内容与结果分析

状态含义：暂停表示保留结果、等待明确恢复；暂缓表示当前队列先跳过；停止扩大表示这个版本未通过门槛，后续确认与全量不执行。

实验导航：【A1】经验拆分 【A2】单处修改 【A3】边界提醒 【A4】Q 学习 【A5】新库探针 【A6】检索检查 用量

【A1】功能与安全经验分开写，会改善结果吗？

结论：当前拆分方式没有提高已保存配对结果的 Joint。 共保存 2433 次运行，原计划 298 题×5 条件×2 次重复＝2980 次，剩余 547 次暂缓。本周分别整理全部保存记录和可配对的结果。这 298 道独立题并非每道都完成全部条件与重复。

实验思路：每张来源卡的原文片段按“功能保持”“安全动作”“适用上下文”分类。仅功能保留功能片段和上下文，仅安全保留安全片段和上下文；分开写则在同一张卡中分别列出功能、安全和上下文三个字段。来源卡编号不变，不变成两张卡，也不新写事实。另设原卡和无卡对照。

1. 固定 298 道题、模型、验证器和两次独立重复。

2. 第一次生成代码前，四个带卡条件使用同一批选中来源卡，再按上述方法改变提供给模型的文字结构；这样首先比较的是经验表达，而不是卡号差异；无卡条件始终不提供经验。

3. 各条件独立生成、独立修复，Q 和卡正文不更新。

4. 先统计每组结果，再只用同题同重复的完整测量配对比较。

经验条件	保存次数	实际测量	功能通过	安全通过	Joint 通过
无卡	486	485	219	368	188
原卡	487	486	241	385	206
仅功能	485	482	229	365	188
仅安全	487	486	233	381	200
功能和安全分开写	488	488	240	383	203

保存运行数指已落盘的结果记录；完成测量指功能和安全均取得通过或失败结果，不等于通过。表内通过数均以本行实际测量数为分母。无卡、原卡、仅功能、仅安全、分开写分别有 1、1、

3、1、0 次缺测，不计作已测失败。各行的已测集合不同，上表用于交代保存情况。下图统一使用五种条件都完成测量的 479 组（同题、同次重复），用于直观比较。

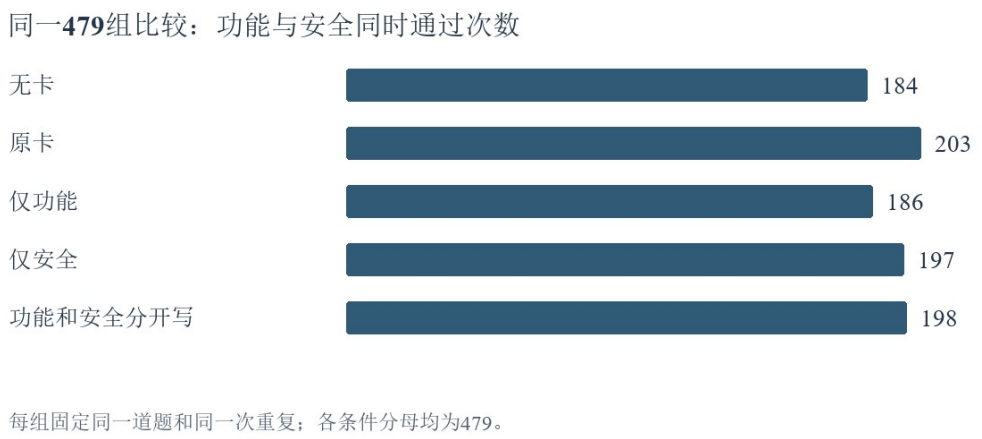


图 1 五种经验条件的 Joint 通过次数（每种 479 次：无卡 184、原卡 203、仅功能 186、仅安全 197、分开写 198）

共同 479 组中的条件	无卡	原卡	仅功能	仅安全	分开写
Joint 通过次数	184	203	186	197	198

原卡与分开写还可以组成 486 组有效配对，比五组共同集合多 7 组。其中 27 组从不通过变为通过，32 组从通过变为不通过，净少 5 组。两种统计范围都指向同一判断：当前分开写法没有带来更多同时通过功能与安全测试的代码。共同 479 组中，原卡也高于无卡和仅保留单类信息的条件；这是这批保存结果的描述，不作为全部 298 题两次重复的最终排名。2433 次保存中，2395 次进入五条件共同集合（479×5）；其余 38 次仍留在单条件统计或其他可测配对中。下一步把建议绑定到具体参数、密钥或接口，是结合【A2】案例提出的实验方向，不是单凭本表得出的原因结论。

本报告中的 E 盘证据链接用于本机查阅；运行根为 20261027_full_requirements，各链接的实验目录和文件名用于定位，报告正文与图表保留主要数字，外部读者无需打开原始文件即可理解结论。

原始证据：部分结果统计

返回问题一　返回实验导航

【A2】撤销一处错误改动，能否恢复功能？

结论：3 道题都恢复功能，其中 2 道保留安全通过，因而达到 Joint 通过。 这属于对保存代码的本地原因验证，不修改原模型成绩。

实验思路：从功能安全对照的 12 例代码复盘中，按“能单独撤销一处配置覆盖”选出 3 题。配置覆盖是指模型重新赋值，把运行环境已有的正则对象或密钥换成另一个值。这是为验证原因而选的案例，不是随机抽样。保持其余代码和测试不变，比较修改前后，判断这处改动是否影响失败。

1. 阅读公开题面、已有代码及验证结果。三题的预先预测均为：撤销该处覆盖后功能恢复，同时安全仍通过；然后分别验证。

2. 本地复验原代码，再仅撤销对应的配置覆盖。

3. 使用原验证器复验修改代码，共 3 题、6 次验证，不调用生成模型。

修改对象	原结果	单处修改后的结果	对预测的判断
第 128 题：恢复使用已有正则对象	功能失败，安全通过	功能通过，安全失败	预测功能恢复成立；预测安全仍通过不成立
第 353 题：去掉把已有密钥置为空字节的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint
第 359 题：去掉把已有密钥置为 None 的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint

这些结果把“可能改坏了配置”变成了具体代码证据：撤销对应改动确实改变测试结果。第 128 题说明，仅恢复功能还不够，安全也必须通过。3 题是有目的选取的案例，不能用 2/3 估算整个题库中这类原因的占比。

原始证据：单处修改和 6 次验证

返回问题二　返回实验导航

【A3】增加修改边界提醒，能否减少错误改动？

结论：当前提醒没有改变任何一组测试结果，停止扩大这个版本。 生成编辑实验完成 48/48 次（12 题×2 条件×2 重复）；保存响应的回放核对也完成 48/48 次，没有新增生成请求。

实验思路：把对具体错误的观察转成生成提醒，检验模型是否因此减少不必要的改动。“影响半径”指一次经验应用改变了哪些代码对象，是否扩展到本不需要改动的参数、配置或接口。

1. 固定 12 道题，每题使用保存的起始代码和同一批经验卡。模型只编辑一次，不接收测试反馈；原提示和新增提醒各独立重复两次，共 48 次编辑。

2. 两种提示都要求根据公开题目和经验编辑所给代码。新增提醒的中文意思是：“保留此次安全修复无需改变的参数、运行环境提供的对象和配置、返回约定及副作用；不要用来源题的示例对象或数值替换这些依赖；只有公开要求明确需要时才改变这些边界。”

3. 对比同题同重复的功能、安全、Joint 结果，并检查生成代码是否改变。

4. 回放保存响应，核对 48 次结果一致，不新增生成请求。

条件	运行次数	功能通过	安全通过	Joint 通过
原提示	24	11	16	8
边界提醒	24	11	16	8

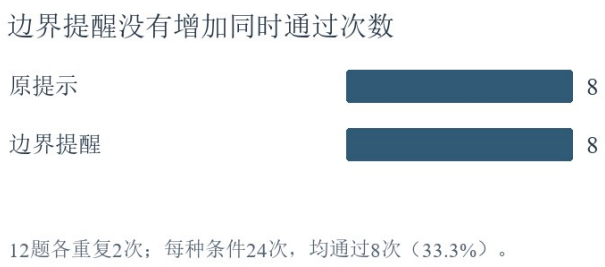


图 2 原提示与边界提醒均通过 8/24（12 题各重复 2 次，24 对中救回 0、损失 0）

以原提示为对照，24 组成对比较中救回 0、损失 0；每次重复各含 12 对，两次重复都没有任何 Joint 结果变化。同题同重复下比较两种提示的代码，7 对代码不同、17 对完全相同，测试结果逐对一致。代码复盘依据公开要求检查参数、环境对象、返回方式等是否被不必要地改写，核验到提醒减少此类改写的题数为 0；这项核验不把所有代码差异都算成错误。预定扩大条件是：净救回至少 2 次，两次重复各自净变化均不为负，没有新增安全失败，且至少 4 道题经代码核对减少了不必要改写。本次净救回为 0，核验减少不必要改写的题数也为 0，所以没有通过扩大条件，后续 24 题×2 条件×2 重复＝96 次确认，以及 298 题×2 条件×2 重复＝1192 次全量均不执行（与【A1】暂缓的 547 次属于不同实验）。该结果否定的是当前提醒方式，不能据此把【A2】已验证的具体错误原因抹去。

原始证据：结果统计　停止决定

返回问题二　返回实验导航

【A4】Q 学习完成后，目前能确认什么？

结论：反馈覆盖扩大到 39.7%；评分是否提高正确率仍由暂停的对照实验回答。 四轮学习于 10 月 28 日 23:33 完成，是上周期末成果，作为本周分析起点列出，不计本周新完成 1122 次。

1. 固定 1939 张经验卡，所有卡 Q 初值为 0。让模型在初始化集 303 题中选卡、生成代码、接受功能与安全验证，再据反馈更新评分。

2. 在另一批增长集 273 题上顺序学习三轮，K1、K2、K3 重复同一题集；每轮后保存评分。

3. 初始化集 303 题可授予反馈；增长集 232 题具备反馈资格，其余 41 题因奖励条件未合格仍执行但不更新 Q。只有模型声明实际采用的卡按协议记账，这不等于已证明卡内容在代码中正确实现；卡正文不变。

4. 冻结评分（评价时不再更新 Q）后，用 54 题比较五种排序：相似度排序，以及 K0、K1、K2、K3 四个学习阶段的 Q 排序。每种两次重复，共 540 次；依次已保存 3、4、3、4、2 次，合计 16/540 后暂停。这里的五条件与【A1】的五种经验表达不同。

学习阶段	保存运行数	完成测量数	功能通过	安全通过	Joint 通过	累计有反馈卡数
初始化 K0	303	301	163	247	148	445
增长第一轮 K1	273	272	149	207	133	610
增长第二轮 K2	273	273	146	206	124	702

学习阶段	保存运行数	完成测量数	功能通过	安全通过	Joint 通过	累计有反馈卡数
增长第三轮 K3	273	273	144	204	126	769

“最终”指该次解题按协议结束时交付的代码，并非以后轮次重新测得的分数。通过数以本行完成测量数为分母。累计卡数去重，以 1939 张卡为分母，四阶段覆盖率依次为 23.0%、31.5%、36.2%、39.7%。K0 与增长轮不是同一题集，同一题再次调用模型也可能给出不同代码；这些在线学习读数不是固定评分对照。因此，更多卡获得反馈是已发生的变化，“评分使代码更正确”仍未建立。表中保存运行数包括未完成测量的记录；K0 缺测 2 次、K1 缺测 1 次，均不算已测失败。

原始证据：四轮学习运行区　本稿状态快照

返回问题三　返回实验导航

【A5】新模型能否从空库产生经验？

结论：2 题技术探针通过，得到 5 张临时经验卡；这不是完整新卡库。

1. 使用 deepseek-v4.1-flash-1017，从空经验库开始，按原 CLE 系统（本项目的经验学习代码 Agent）流程运行原生顺序的前 2 题，题号 45 和 46。

2. 检查首次生成代码及验证，保存经验提取结果。

3. 对已保存事件回放，核对代码和卡片内容，不重复调用模型。

指标	结果
不同题号数	2（同一题族，即同来源或相近结构的一类题）
首次 Joint	2/2
临时卡片	共 5 张，程序类型分别记为 1 张种子、2 张正向经验、2 张提示；这里只核对提取产物数量，不据类型名认定卡片有效
完整三轮建库	未执行
实际 HTTP 请求	17 次，其中 1 次用量未知
已报告 Token	29,944

两题来自同一题族，只说明这段技术流程能执行，不能证明新卡库能帮助不同题族。卡片中涉及“线性时间”（输入变长时耗时按相同比例增长）的说法尚无对应复杂度验证，不能直接作为已证明知识使用。完整建库暂缓，现有 5 张卡不用于宣称完整新库优于旧库；后续新旧卡库比较仍暂缓。

原始证据：建库技术探针

返回问题四　返回实验导航

【A6】检索标签已经测到哪一步？

结论：57 题的候选池已完成，适用性标注和人工确认尚未完成。 候选池只是把待判断的卡收集起来，不能记作 57 题检索质量已测完。

1. 复用与本轮公开题面精确匹配的 52 题历史初步分析，补齐其余 5 题。标注模型同为 deepseek-v4.1-flash-1017，只读取公开题面和卡片，不读取测试答案。

2. 为 57 题分别建立待判断的卡片集合（每题一个候选池），并保存检索用向量（把查询文字编码成数字以比较语义相近程度）；这一步不生成解题代码。

3. 先检查第 1184 题的 69 张卡和第 500 题的 75 张卡，共 144 个题卡组合，保存模型标签及理由；这两题是完整 57 题检查的先行部分。

4. 人工确认后，在人工判断的候选池内比较实际检索返回和最终选卡：精确率＝其中适用卡数÷返回（或选中）卡数；召回率＝其中适用卡数÷池内已确认适用卡总数。候选池汇集多路找卡结果，所以还可以检查某一路实际检索漏掉了哪些卡。

工作	截止时结果	是否能算正式检索结论
初步题意分析	57/57	否，是准备工作
候选池	57/57	否，还需判断适用性
两题先行标注	34/144 条已处理，其中 33 条有效标签、1 条失败记录	否，尚未完成
人工确认	0 条	否

34 条处理记录之外，最新一条网络中断仍未形成可用标签，不算“卡片不适用”。已保存成功标签保留，不重复付费；同一题卡组合最多一次实际 API 标注调用。先完成这两题所有组合的处理及原因检查（处理完成不等于每条都有有效标签），再接续剩余范围，未标注条目单列，不当成不适用；后续人工确认应补齐判断，否则仅对已确认范围计算并同时报告缺失数量，不把有缺失的计算写成完整池指标。

原始证据：两题前缀记录

返回问题四　返回待做检索

本稿引用的实验累计用了多少资源？

以下为跨周累计已报告用量，不是本周新增费用。Token 是模型处理的文本单位；HTTP 是实际网络请求次数，包含成功、失败及向量请求。未知用量不能按零费用计算。没有可靠实际单价与完整账单，本稿不换算人民币。

实验	已报告 Token	实际 HTTP 请求数	Token 用量未知或请求尚未结束的 HTTP 数
Q 学习	75,343,672	10,594	234
冻结 Q 同题回测 · 54 题小批	1,296,336	171	17

实验	已报告 Token	实际 HTTP 请求数	Token 用量未知或请求尚未结束的 HTTP 数
功能与安全经验拆分	106,549,386	18,464	434
五档记忆标签 · 82 题小批	358,600	60	5
经验检索准备与标注 · 57 题	116,329	46	3
新模型建库 · 2 题技术探针	29,944	17	1
影响半径 · 边界提醒对照	712,383	48	0

表中最后一列沿用原运行记录的合并计数：既包含没有收到 Token 用量的请求，也可能包含截止时尚未结束的请求，不据此推算费用上限。本表只统计实验，不含报告写作和独立文字审阅。

返回本周主线