10 月 29 日-11 月 4 日实验探索报告

一、本周实验主线

本周继续回答两个问题：经验为什么会让代码出错，以及怎样确认检索出来的经验真正适用。先复查已保存代码，再用小批对照验证原因，最后整理检索标签。Q 相关实验、记忆标签及分类器按要求暂停；排队全量不启动。暂停只改变后续安排，不删除已完成结果。

本稿统计到 2026-10-29 12:29:49（北京时间）。这是周中稿，11 月 4 日之后的结果尚未发生。跨周运行采用累计读数，下面明确区分既有学习结果与本周新增分析，不把累计完成数算成本周新增。

经验卡是可复用的做题建议；Q 是卡片根据解题反馈得到的评分。Joint 表示同一份代码同时通过功能测试和安全测试。一次“运行”指一道题在一种条件下执行一次；同题重复两次仍然是一道题。本文按实验分别给分母，不把不同任务量相加成总正确率。

（1）分开写功能与安全经验，是否让更多代码同时通过测试？

没有改善当前配对结果。 同题、同次重复的 486 组有效比较中，分开写经验救回 27 次、损失 32 次，净少 5 次 Joint 通过。五种条件都完成测量的 479 组中，原卡通过 203 次，分开写通过 198 次。【A1】

证据支持“当前拆分方式没有提高这批结果”，因此暂不扩大剩余全量。下一步先定位具体代码改动，而非继续增加同类运行次数。【A2】

（2）找到错误改动后，提醒模型少改无关内容就够了吗？

定位具体改动有效，当前提醒方案无效。 3 道题的本地单处修改使 2 道恢复 Joint 通过；另 1 道功能恢复但安全失败。随后 12 道题的两次重复对照中，原提示与新增边界提醒均通过 8/24，逐对结果完全相同。【A2】【A3】

这支持继续研究“哪些改动不该做”，但不支持扩大当前这一句提醒。直接修改已有代码与让模型重新生成代码是两种干预，不能当成同一个实验。

（3）更多卡获得 Q 评分，是否已经证明评分有用？

证明了反馈范围扩大，尚未完成正确率对照。 既有四轮学习完成 1122 次，最终 769/1939 张卡获得反馈（39.7%）。冻结评分后的 54 题回测已保存 16/540 次，现已暂停，不用学习过程自身的正确率代替评分收益。【A4】

（4）新卡库和检索质量，目前能得出什么判断？

从空库提取经验的技术流程已经跑通，完整新库尚未建成。 2 题技术探针产出 5 张临时卡。检索 57 题的初析和候选池已备齐，当前只开展 2 题的标签检查，人工确认仍为 0；现阶段不发布检索准确率。【A5】【A6】

二、本周待做实验

【T1】先完成检索标签，再判断漏卡发生在哪里

原因：候选池已建立，但还不能据此判断卡片是否适用于题目。

1. 完成固定 2 题的 144 个题卡配对检查，逐条保留模型给出的适用性理由。

2. 对照公开题面与卡片，检查“直接适用、需要附加条件、冲突、不适用”的解释是否一致；网络失败记录为未标注，不算不适用。

3. 前缀检查完成后，按原 57 题范围接续其余标注；输出人工复核清单，人工确认后再计算候选池内的检索指标。

当前状态：2 题标签检查未完成，存在网络中断；不补发已执行过一次的题卡标注请求。正向判断需要相关经验已进入候选池、最终选卡能保留相关经验，且标签经人工确认；若相关经验在前一步就遗漏，则先改检索，若进入候选池却被排除，则先改选卡。这里的指标只覆盖本批候选池，不代表整个卡库。

【T2】Q 与记忆程度实验保留现场，等待明确恢复

原因：需要分别验证评分收益和经验详细程度的作用，当前按要求暂停。

1. 保留 54 题 Q 回测已完成的 16 次和 82 题记忆标签已完成的 5 次。

2. 暂停期间只整理已有证据，不调用模型补齐，也不训练分类器。

3. 后续恢复仍沿用已登记名单、重复次数和实验规则；先完成各自小批比较，再根据原门槛决定下一步。

当前状态：Q 回测、Q 迁移、记忆标签、分类器及标签追加均暂停。当前结果不足以计算完整小批收益，不能判成成功或失败。

【T3】只保留能解释问题的后续实验

原因：边界提醒已给出零增益，完整建库和大规模迁移仍有成本或依赖。

1. 当前边界提醒版本停止扩大，保留 48 次完整结果与回放。

2. 功能安全对照剩余 547 次暂缓；完整新库、交叉比较及外部评测继续跳过。

3. 后续若改变干预方式，先写清要改变哪一种代码行为、怎样在成对结果中验证；没有新干预不重复跑同一负结果。

当前状态：旧模型 v3.2 不可用，Base/Plus 缺原验证镜像。这些未执行项不记作失败；当前 v4.1 结果也不代替跨模型比较。

返回本周主线

三、实验内容与结果分析

实验导航：【A1】经验拆分　【A2】单处修改　【A3】边界提醒　【A4】Q 学习　【A5】新库探针　【A6】检索检查　用量

【A1】功能与安全经验分开写，会改善结果吗？

结论：当前拆分方式没有提高已保存配对结果的 Joint。 本周对跨周保存的 2433 次结果完成比较分析，原计划 2980 次，剩余 547 次暂缓。这 298 道独立题并非每道都完成全部条件与重复。

实验思路：同一经验分别保持原样、只保留功能信息、只保留安全信息、把功能和安全分栏展示，并增加无卡对照，区分“有没有经验”与“经验怎么写”。

1. 固定 298 道题、模型、验证器和两次独立重复。

2. 首次生成的四个带卡条件共用来源卡编号，再改变经验呈现方式；无卡条件始终不提供经验。

3. 各条件独立生成、独立修复，Q 和卡正文不更新。

4. 先统计每组结果，再只用同题同重复的完整测量配对比较。

经验条件	保存次数	实际测量	功能通过	安全通过	Joint 通过
无卡	486	485	219	368	188
原卡	487	486	241	385	206
仅功能	485	482	229	365	188
仅安全	487	486	233	381	200
功能和安全分开写	488	488	240	383	203

各行的已测集合不同，上表用于交代保存情况。下图统一使用五种条件都完成测量的 479 组（同题、同次重复），用于直观比较。

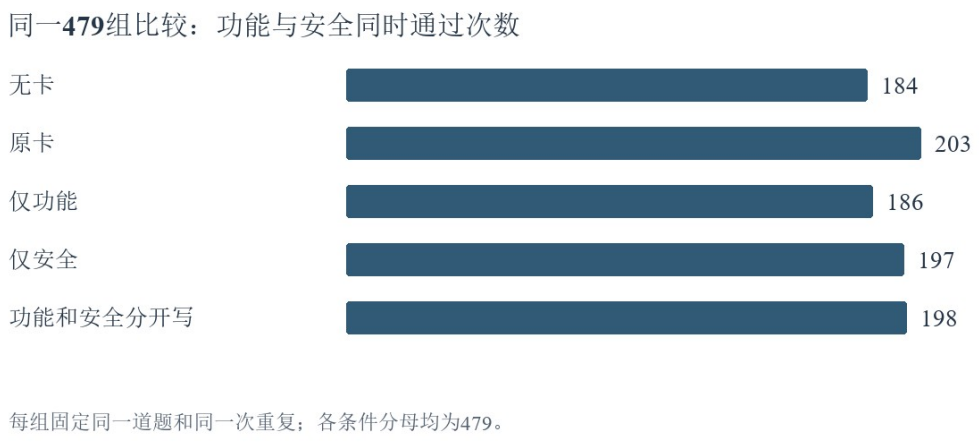


图 1 五种条件共同完成的 479 组比较，单位为 Joint 通过次数

共同 479 组中的条件	无卡	原卡	仅功能	仅安全	分开写
Joint 通过次数	184	203	186	197	198

原卡与分开写还可以组成 486 组有效配对，比五组共同集合多 7 组。其中 27 组从不通过变为通过，32 组从通过变为不通过，净少 5 组。两种统计范围都指向同一判断：当前分开写法没有带来更多同时通过功能与安全测试的代码。这并不等于功能信息与安全信息无需区分；结果要求下一步把“分栏”具体落实到不应改动的代码对象上。

原始证据：部分结果统计

返回问题一　返回实验导航

【A2】撤销一处错误改动，能否恢复功能？

结论：3 道题都恢复功能，其中 2 道同时恢复安全通过。 这属于对保存代码的本地原因验证，不修改原模型成绩。

实验思路：从已阅读的 12 例代表代码中，选择可以单独撤销配置覆盖的 3 题。保持其余代码和测试不变，比较修改前后，判断这处改动是否影响失败。

1. 阅读公开题面、已有代码及验证结果，预先写出单处修改和预测。

2. 本地复验原代码，再仅撤销对应的配置覆盖。

3. 使用原验证器复验修改代码，共 3 题、6 次验证，不调用生成模型。

修改对象	原结果	单处修改后的结果	对预测的判断
第 128 题：恢复使用已有正则对象	功能失败，安全通过	功能通过，安全失败	功能预测成立，安全保留预测不成立
第 353 题：去掉把已有密钥置为空字节的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint
第 359 题：去掉把已有密钥置为 None 的代码	功能失败，安全通过	功能和安全均通过	修改恢复 Joint

这些结果把“可能改坏了配置”变成了具体代码证据：撤销对应改动确实改变测试结果。第 128 题同时说明，功能恢复不是充分目标，还必须保住安全。3 题是有目的选取的案例，不能用 2/3 估算整个题库中这类原因的占比。

原始证据：单处修改和 6 次验证

返回问题二　返回实验导航

【A3】增加修改边界提醒，能否减少错误改动？

结论：当前提醒没有改变任何一组测试结果，停止扩大这个版本。 实验和回放均已完成 48/48 次。

实验思路：把对具体错误的观察转成生成提醒，检验模型是否因此减少不必要的改动。“影响半径”指一次经验应用改变了哪些代码对象，是否扩展到本不需要改动的参数、配置或接口。

1. 固定 12 道题，每题分别使用原提示和边界提醒，两种条件各独立重复两次。

2. 保持模型、题面和验证器一致，只增加预先规定的边界提醒。

3. 对比同题同重复的功能、安全、Joint 结果，并检查生成代码是否改变。

4. 回放保存响应，核对 48 次结果一致，不新增生成请求。

条件	运行次数	功能通过	安全通过	Joint 通过
原提示	24	11	16	8
边界提醒	24	11	16	8

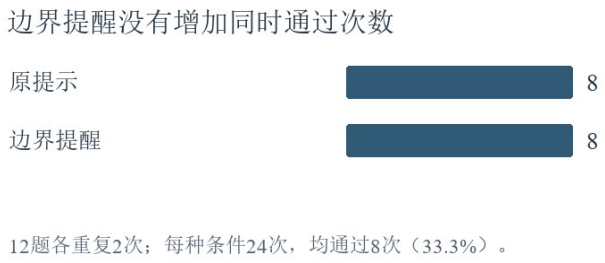


图 2 两种提示各运行 24 次，Joint 通过次数相同

24 组成对比较中，救回 0、损失 0；两次重复的净变化均为 0。7 组代码发生变化，17 组代码相同，但测试结果逐对一致。方案没有通过预定的结果改善与代码行为检查，后续 96 次确认及 1192 次全量均不执行。该结果否定的是当前提醒方式，不能据此把【A2】已验证的具体错误原因抹去。

原始证据：结果统计　停止决定

返回问题二　返回实验导航

【A4】Q 学习完成后，目前能确认什么？

结论：反馈覆盖扩大到 39.7%；评分是否提高正确率仍由暂停的对照实验回答。 四轮学习于 10 月 28 日 23:33 完成，是上周期末成果，作为本周分析起点列出，不计本周新完成 1122 次。

1. 固定 1939 张经验卡，评分从零开始，先运行初始化集 303 题。

2. 在增长集 273 题上顺序学习三轮，每轮后保存评分。

3. 只为符合反馈资格且实际采用的卡更新评分；学习过程中卡正文不变。

4. 冻结评分后原定以 54 题、五种条件、两次重复回测，共 540 次，已保存 16 次后暂停。

学习阶段	完成次数	最终实际测量	最终功能通过	最终安全通过	最终 Joint	获得反馈卡数
初始化 K0	303	301	163	247	148	445
增长第一轮 K1	273	272	149	207	133	610

学习阶段	完成次数	最终实际测量	最终功能通过	最终安全通过	最终 Joint	获得反馈卡数
增长第二轮 K2	273	273	146	206	124	702
增长第三轮 K3	273	273	144	204	126	769

每轮覆盖以 1939 张卡为分母。K0 与增长轮不是同一题集，增长轮内又存在模型重复波动；这些在线学习读数不是固定评分对照。因此，更多卡获得反馈是已发生的变化，“评分使代码更正确”仍未建立。表中完成次数包括保存但未完成测量的记录；K0 缺测 2 次、K1 缺测 1 次，均不算已测失败。

原始证据：四轮学习运行区　本稿状态快照

返回问题三　返回实验导航

【A5】新模型能否从空库产生经验？

结论：2 题技术探针通过，得到 5 张临时经验卡；这不是完整新卡库。

1. 从空经验库开始，沿原 CLE 流程运行固定 2 道题。

2. 检查首次生成代码及验证，保存经验提取结果。

3. 对已保存事件回放，核对代码和卡片内容，不重复调用模型。

指标	结果
独立题数	2（同一题族）
首次 Joint	2/2
临时卡片	5：1 张种子、2 张正向经验、2 张提示
完整三轮建库	未执行
实际 HTTP 请求	17 次，其中 1 次用量未知
已报告 Token	29,944

两题来自同一题族，只说明这段技术流程能执行，不能证明新卡库能帮助不同题族。卡片中涉及“线性时间”的说法尚无对应复杂度验证，不能直接作为已证明知识使用。完整建库暂缓，现有 5 张卡不当成完整新库启动交叉比较。

原始证据：建库技术探针

返回问题四　返回实验导航

【A6】检索标签已经测到哪一步？

结论：57 题的候选池已完成，适用性标注和人工确认尚未完成。 候选池只是把待判断的卡收集起来，不能记作 57 题检索质量已测完。

1. 复用 52 题初步分析，补齐其余 5 题，只使用公开题面。

2. 为 57 题构建共同候选池，保存查询向量和候选卡；这一步不生成解题代码。

3. 先对 2 道固定题的 144 个题卡组合判断适用性，保存标签及理由。

4. 人工确认后，再区分“适用卡未进入候选池”和“已找到但未被选用”。

工作	截止时结果	是否能算正式检索结论
初步题意分析	57/57	否，是准备工作
候选池	57/57	否，还需判断适用性
两题标注前缀	34/144 条已处理，其中 33 条有效标签、1 条失败记录	否，尚未完成
人工确认	0 条	否

最新一条网络中断仍未形成可用标签，不算“卡片不适用”。已保存成功标签保留，不重复付费；同一题卡组合最多一次物理标注请求。先完成前缀的记录整理及原因检查，再接续剩余范围，不因已经建立候选池就发布召回率。

原始证据：两题前缀记录

返回问题四　返回待做检索

本稿引用的实验累计用了多少资源？

以下为跨周累计已报告用量，不是本周新增费用。Token 是模型处理的文本单位；HTTP 是实际网络请求次数，包含成功、失败及向量请求。未知用量不能按零费用计算。没有可靠实际单价与完整账单，本稿不换算人民币。

实验	已报告 Token	实际 HTTP	用量未知或在途 HTTP
Q 学习	75,343,672	10,594	234
冻结 Q 同题回测 · 54 题小批	1,296,336	171	17
功能与安全经验拆分	106,549,386	18,464	434
五档记忆标签 · 82 题小批	358,600	60	5
经验检索质量 · 57 题	116,329	46	3
新模型建库 · 2 题技术探针	29,944	17	1
影响半径 · 边界提醒对照	712,383	48	0

本表不含本次 dsh-tui 文字审阅及 Codex 用量；二者不是解题实验。实验结果统计与文字润色分开保存。

返回本周主线